



计算机工程与应用  
Computer Engineering and Applications  
ISSN 1002-8331, CN 11-2127/TP

## 《计算机工程与应用》网络首发论文

题目: 加权密集扩张卷积网络的随机脉冲噪声去除  
作者: 曹义亲, 符杨逸, 饶哲初  
网络首发日期: 2022-06-23  
引用格式: 曹义亲, 符杨逸, 饶哲初. 加权密集扩张卷积网络的随机脉冲噪声去除  
[J/OL]. 计算机工程与应用.  
<https://kns.cnki.net/kcms/detail/11.2127.TP.20220622.1000.002.html>



**网络首发:** 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

**出版确认:** 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

# 加权密集扩张卷积网络的随机脉冲噪声去除

曹义亲<sup>+</sup>, 符杨逸, 饶哲初

华东交通大学 软件学院, 南昌 330013

**摘 要:** 基于深度学习的图像去噪方法, 大多没有充分利用不同层次的特征信息, 通道合并时都是直接在通道维度上对特征图进行拼接, 并没有考虑到浅层与深层卷积特征各自的重要性。为解决上述问题, 本文提出一种加权密集扩张卷积连接网络模型, 用于去除图像的随机脉冲噪声。首先, 通过使用不同扩张因子的扩张卷积来丰富浅层特征图的多尺度特征信息; 其次, 考虑到浅层与深层卷积特征各自的重要性, 将原始密集块进行改进, 采用加权密集连接结构, 并使用扩张卷积提高感受野; 最后, 采用跳跃连接, 将浅层的多尺度特征信息和不同加权密集扩张卷积块的特征信息进行融合, 充分利用深层卷积特征和浅层卷积特征信息实现随机脉冲噪声的复原。实验结果表明, 所提模型的去噪效果更加突出。

**关键词:** 图像去噪; 深度学习; 密集连接; 扩张卷积; 权重; 随机脉冲噪声

**文献标志码:** A      **中图分类号:** TP391      **doi:** 10.3778/j.issn.1002-8331.2205-0204

## Weighted Dense Dilated Convolutional Network for Random Impulse Noise Removal

CAO Yiqin<sup>+</sup>, FU Yangyi, RAO Zhechu

School of Software, East China Jiaotong University, Nanchang 330013, China

**Abstract:** Among image denoising methods based on deep learning, most of them do not make full use of feature information at different levels, and splicing feature graphs directly on channel dimensions during channel merging, without considering the importance of both shallow and deep convolution features. In order to solve the above problems, this paper proposes a weighted dense dilated convolutional connection network to remove random impulse noise in images. First, the multi-scale feature information of the shallow feature map is enriched by dilation convolution using different expansion factors. Secondly, considering the importance of both shallow and deep convolution features, the original dense block is improved, the weighted dense connection structure is adopted, and the expansion convolution is used to effectively increase the receptive field. Finally, jump connections are used to fuse the shallow multi-scale feature information with the feature information of different weighted dense dilated convolution blocks, and make full use of the high-level and low-level feature information to recover random impulse noise. The experimental results show that the proposed algorithm has a more prominent denoising.

**Key words:** image denoising; deep learning; dense connection; dilated convolution; weight; random impulsive noise

**基金项目:** 国家自然科学基金项目 (61861016); 江西省科技支撑计划重点项目(20161BBE50081)。

**作者简介:** 曹义亲(1964-), 男, 硕士, 教授, CCF 会员, 研究方向为图像处理、模式识别, E-mail: ecjtu\_cyq@163.com; 符杨逸(1996-), 男, 硕士研究生, E-mail: yyfu\_brave@163.com; 研究方向为图像处理; 饶哲初(1997-), 男, 硕士研究生, 主要研究方向为图像处理, E-mail: rjzrc\_dyshg@163.com。

在计算机视觉领域,由于图像传感器往往在恶劣的环境下运行,采集到的图像的质量不佳,加之传输过程中的错误和干扰,给后续图像处理工作带来极大的困难,因此,图像增强和图像去噪就成为图像处理过程中非常重要的组成部分<sup>[1,2]</sup>。脉冲噪声是由于电信号的不稳定性、物理内存存储的损坏、数据传输中系统错误、电磁干扰、相机传感器的故障或老化以及光照条件较差而产生的<sup>[1,3-5]</sup>,会显著降低图像质量。脉冲噪声可以分为两大类<sup>[6]</sup>:椒盐噪声(Salt-Pepper Noise, SPN)<sup>[7]</sup>和随机脉冲噪声(Random-Valued Impulse Noise, RVIN)<sup>[8]</sup>。RVIN噪声像素点的亮度值可以是图像像素点亮度值所允许范围内的任意值,该值与其领域内像素点的亮度值往往相差不大,很难进行区分,因此,RVIN噪声的去除更具有挑战性<sup>[9-11]</sup>。

去除脉冲噪声传统上采用中值滤波算法,通过对噪声像素的邻域像素值进行排序,取中间值替换噪声像素值,但它缺乏图像边缘保持能力。加权中值滤波算法<sup>[12]</sup>是对中值滤波算法的改进,它为了增强图像边缘保持能力,以不同的加权系数体现邻域像素之间的相关性和影响。这些算法存在的问题在于统一处理噪声像素与非噪声像素。文献<sup>[13]</sup>提出开关滤波算法,先对噪声像素进行检测,再替换检测到的噪声像素。Malinski等<sup>[14]</sup>提出一种快速自适应的开关滤波算法,它不仅能有效地保留非噪声像素,还能提高滤波效率。

近年来,随着深度学习的不断发展,卷积神经网络(Convolutional Neural Network, CNN)被应用于图像去噪并取得了非常好的效果。Zhang等人<sup>[15]</sup>提出去噪卷积神经网络 DnCNN(Denoising Convolutional Neural Network),它证明了通过残差学习和批量归一化有助于提高去噪性能。然而, DnCNN只是针对在某一特定噪声水平下的模型,对于不同的噪声水平,需要多个不同的去噪网络。针对这一问题,文献<sup>[16]</sup>提出 FFDNet (Fast and Flexible Denoising Convolutional Neural Network),将噪声图像与噪声水平图拼接作为网络输入以此来处理更加

复杂的噪声,例如不同噪声水平的噪声和空间变化噪声,并且噪声水平图可以作为权重权衡对噪声的抑制和细节的保持。当噪声的估计水平与实际值不匹配时,FFDNet的去噪效果表现并不理想。为克服这一缺陷,CBDNet(Convolutional Blind Denoising Network)<sup>[17]</sup>提出非对称损失函数,当估计噪声水平低于实际噪声水平时引入更多的惩罚,以此来提升算法的去噪性能。上述方法主要用于去除高斯噪声,但将训练的输入图像换成受脉冲噪声污染的图像,也可用于处理脉冲噪声。Jin等<sup>[18]</sup>和Zhang等<sup>[19]</sup>分别使用CNN处理椒盐噪声,Radlak等人<sup>[20]</sup>将开关滤波器与DnCNN相结合提出IDCNN(Impulse Detection Convolutional Neural Network)用于去除随机脉冲噪声。Zhao等<sup>[21]</sup>利用通道注意力机制,自适应地对特征通道进行加权来提取噪声信息。Tian等<sup>[22]</sup>提出ADNet(Attention-guided Denoising Convolutional Neural Network),通过利用注意力机制来深度挖掘复杂背景中的噪声信息。

尽管现有方法有效地提高了算法的去噪性能,但大多数方法中通道的合并都是直接在通道维度上对特征图进行拼接,并没有考虑到浅层与深层卷积特征各自的重要性。在卷积神经网络中,浅层卷积特征保留着丰富的图像边缘和纹理信息,但随着网络层数的增加,提取的深层卷积特征会丢失大量的浅层特征信息,导致算法对于图像结构的还原能力较差。本文针对上述问题,受Yu等<sup>[23]</sup>、Li等<sup>[24]</sup>和跳跃连接<sup>[25]</sup>的启发,设计加权密集连接网络,对密集连接块中各层级特征赋予不同的权重,并结合扩张卷积增加网络的感受野,提升网络的表达能力,指导网络更好地去除随机脉冲噪声。

## 1 相关工作

### 1.1 扩张卷积

感受野是卷积神经网络每一层输出的特征图上的像素点在输入图像上映射的区域大小。为了获取更多的图像信息,一种非常有效的方法,就是扩大感受野。一般有两种方法扩大感受野,第一种是增加网络的深度或宽度,而随着网络层数的增加,训

练也会变得更加困难; 第二种方法是通过提高模型的复杂度, 这涉及到大量的参数。为此, 文献<sup>[26]</sup>提出扩张卷积。扩张卷积与普通卷积相比, 尽管它们的卷积核大小是一样的, 但扩张卷积还有一个扩张因子参数, 主要用来表示扩张的大小。扩张卷积的示意图如图 1 所示。一般情况下, 扩张卷积的感受野大小遵循公式(1):

$$K = (d * (k - 1) + 1) \quad (1)$$

式中,  $K$  代表扩张后的感受野大小,  $d$  代表扩张因子,  $k$  代表原始卷积核大小。

图 1(a)表示为卷积核大小  $3 \times 3$ 、扩张因子为 1 的扩张卷积, 它的感受野大小  $3 \times 3$ , 与普通卷积相同。(b)表示为卷积核大小  $3 \times 3$ 、扩张因子为 2 的扩张卷积, 它的感受野大小  $5 \times 5$ 。(c)表示为卷积核大小  $3 \times 3$ 、扩张因子为 3 的扩张卷积, 它的感受野大小  $7 \times 7$ 。扩张卷积能够在不增加参数的情况下增大感受野。




图 1 扩张卷积原理图

Fig.1 Schematic diagram of dilated convolution

## 1.2 密集连接

在深度学习中, 随着网络层数的加深, 梯度消失问题会更加明显。Huang 等人<sup>[27]</sup>提出密集连接卷积网络 DenseNet, 在图像分类上取得了很大的成功。DenseNet 并不是从加深网络层数和加宽网络结构来提升网络性能, 而是从特征的角度考虑, 通过特征重用和旁路设置, 既大幅度减少了网络的参数量, 又在一定程度上缓解了梯度消失问题。其中的模块为密集块, 结构如图 2 所示, 每一层的输入不仅与前一层的输出有关, 还与之前所有层的输出有关, 其连接公式表示为:

$$X_l = H_l([X_0, X_1, \dots, X_{l-1}]) \quad (2)$$

式中,  $[]$  代表对通道的拼接,  $X_0, X_1, \dots, X_{l-1}$  代表之前所有层的特征图。图 2 中 Transition Layer 表示过渡层, 它放在两个密集块之间, 目的是减少特征图的数量。




图 2 密集块结构示意图

Fig.2 Schematic diagram of dense block structure



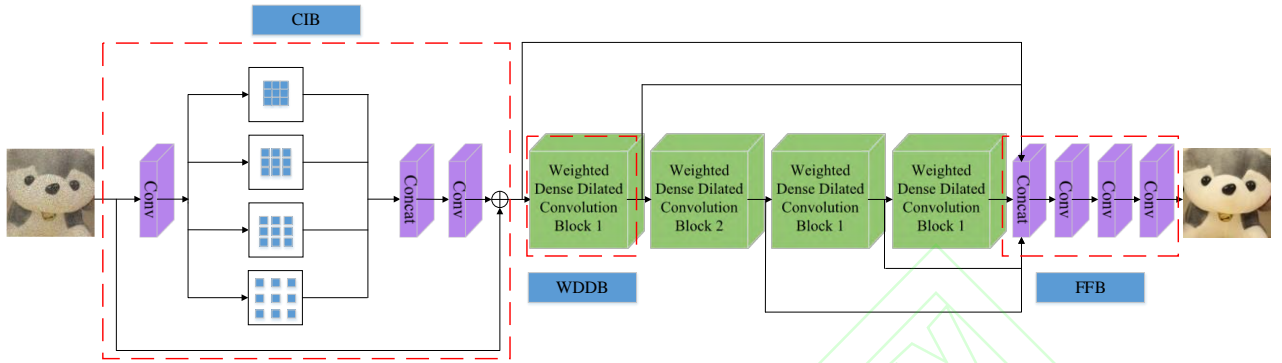



图3 本文网络结构示意图

Fig.3 Network architecture of the proposed



(a)无跳跃连接

(b)含跳跃连接

图4 有无跳跃连接的区别<sup>[28]</sup>Fig.4 The difference between skip connections and without skip connections<sup>[28]</sup>

## 2 网络结构

### 2.1 设计思路

本文提出的网络结构, 由背景信息块(Context Information Block, CIB)、四个加权密集扩张卷积连接块(Weighted Dense Dilated Convolution Block, WDDDB)和特征融合块(Feature Fusion Block, FFB)组成, 如图3所示。多尺度信息对于图像去噪任务十分重要, 为了扩大感受野和获取多尺度信息, 本文提出了CIB。CIB使用不同扩张因子的扩张卷积, 它能在不损坏结构和增加参数的情况下扩大感受野, 然后将不同感受野提取出来的特征进行融合。为了加强特征的传递, 本文设计了四个基于扩张卷积的密集连接块来提取更多的细节纹理和其他特

征。尽管密集连接能够有效的利用特征, 但随着网络层数的加深, 浅层特征会退化, 而浅层特征携带许多图像细节信息, 因此, 在经过四个密集扩张卷积连接块后, 通过跳跃连接将每个密集扩张卷积连接块提取出的特征进行特征融合, 不仅能将浅层卷积特征带到深层卷积特征中, 提升去噪性能, 还能加快网络的训练速度。

卷积神经网络从浅层到深层的过程中, 先是提取浅层卷积特征, 浅层卷积特征包含图像的局部特征细节信息和边缘信息, 随着网络层数的加深, 网络渐渐提取深层卷积特征, 图像的细节信息会在深层卷积特征中丢失, 深层卷积特征包含图像的全局语义信息。本文采用加权密集扩张卷

积连接结构, 其中运用了多重扩张卷积, 多重扩张卷积的一个优点是它能够在单层内将由小扩张因子获得的信息整合至大扩张因子获得的信息中, 再通过结合密集跳跃连接能够在所有层进行多分辨率建模。这种具有密集跳跃连接的快速信息流, 以及各种分辨率之间密集的信息交换, 提供了更灵活的建模局部和全局结构之间关系的能力。在密集跳跃连接时, 为每个特征通道加入权重, 通过学习的方式来自动获取到每个特征通道的重要程度, 加权强化重要信息, 弱化抑制无关的不重要信息。

由于本文网络结构较深, 而跳跃连接能够训练深的神经网络, 因此本文引入它。Li 等<sup>[28]</sup>对复杂的损失表面进行了可视化, 其结果如图 4 所示。图 4 展示了有跳跃连接和无跳跃连接的 ResNet-56 的损失表面, 可以看出具有跳跃连接的神经网络的损失表面更平滑, 因此比没有任何跳跃连接的网络收敛速度更快。

## 2.2 网络结构

本文提出的网络结构有 34 层, 如图 3 所示。假设  $I_N$ 、 $I_C$  分别代表输入的噪声图像和预测的干净图像。CIB 可以用公式表示为:

$$O_{CIB} = f_{CIB}(I_N) \quad (3)$$

式中,  $f_{CIB}$  表示 CIB 的功能,  $O_{CIB}$  为 CIB 的输出。WDDBs 可以定义为:

$$O_{WDDB}^1 = f_{WDDB}^1(O_{CIB}) \quad (4)$$

$$O_{WDDB}^i = f_{WDDB}^i(O_{WDDB}^{i-1}) \quad (5)$$

式中,  $f_{WDDB}^1$  表示为 WDDB 的功能,  $O_{WDDB}^1$  为第一个 WDDB 的输出,  $O_{WDDB}^i$  为第  $i$  个 WDDB 的输出,  $i=2, 3, 4$ 。FFB 可以定义为:

$$I_C = f_{FFB}\left(\left[O_{CIB}, O_{WDDB}^1, O_{WDDB}^2, O_{WDDB}^3, O_{WDDB}^4\right]\right) \quad (6)$$

式中,  $f_{FFB}$  表示为 FFB 的功能, 即结合局部特征和全局特征,  $[ ]$  表示将  $O_{CIB}$ 、 $O_{WDDB}^1$ 、 $O_{WDDB}^2$ 、 $O_{WDDB}^3$ 、 $O_{WDDB}^4$  进行通道拼接,  $I_C$  表示为预测的干净图像。

## 2.3 背景信息块

为了丰富浅层特征图的多尺度特征信息, 本文设计 CIB 模块, 因为浅层特征图携带许多图像的细节特征信息。CIB 一共三层, 有 Conv、Dilated Conv+ReLU 两种类型。第一层 Conv, 使用卷积核大小为  $1 \times 1 \times 32$  生成 32 个特征图, 第二层分别使用扩张因子为 1、2、3、4 的扩张卷积得到特征图, 通过 Concat 层将特征图进行通道拼接, 第三层为 Conv 和跳跃连接, 通过 Conv 将特征信息进行融合, 得到的输出再与输入的噪声图像进行跳跃加和连接, 其结构如图 3 中的 CIB 所示。

## 2.4 加权密集扩张卷积连接块

为了加强特征的传递和有效利用特征, 设计四个加权密集扩张卷积连接块, 如图 5 所示。每个块中包含了 3 种不同的模块, 第一个模块由 ReLU 激活函数和扩张因子为 1 的扩张卷积组成, 第二个模块由 ReLU 激活函数和扩张因子分别为 1、2 的扩张卷积组成, 第三个模块由 ReLU 激活函数和扩张因子分别为 1、2、4 的扩张卷积组成, 然后再通过密集连接方式进行连接。这样设计的目的是避免出现棋盘效应。在密集扩张卷积连接块中, 每一层的输入都来自前面所有层的输出, 即对输出的特征图进行通道合并, 而不做其它操作。因此, 为每个密集连接上加入权重, 能够自适应的计算每张特征图重要性权重, 增强图像信息的特征表达, 权重计算方法如图 6 所示。首先, 为了将信息聚合, 输入特征图分别经过最大池化层和平均池化层得到两个特征向量, 两个特征向量通过相同的两个 FC 层和 ReLU 激活函数, 将输出结果相加, 然后经过 sigmoid 激活函数得到每张特征图的权重, 最后将输入特征图与权重逐通道相乘得到表达能力更强的特征图。




图5 加权密集扩张卷积块示意图

Fig.5 Schematic diagram of weighted dense dilated convolution block




图6 权重示意图

Fig.6 Schematic diagram of weighted

## 2.5 特征融合块

随着网络层数的加深，卷积神经网络逐渐地提取深层卷积特征，深层卷积特征包含更多的是图像的语义信息，但图像的细节信息不足。为了解决这一问题，本文设计了特征融合块，它由 Concat 层和三个 Conv 层组成，Concat 层将 CIB 和四个加权密集扩张卷积块提取的特征图进行通道拼接，再通过 Conv 层融合浅层卷积特征和深层卷积特征，形成信息的互补，有利于提升去噪性能，最后经过两层 Conv 得到去噪后的图像。

## 2.6 损失函数

本文实验采用均方误差(mean square error, MSE)进行训练。损失函数表达式如下：

$$L(\theta) = \frac{1}{2N} \sum_{i=1}^N \|f(I_N) - I_C\|^2 \quad (7)$$

式中， $I_N$  为噪声图像， $I_C$  为干净图像， $f(I_N)$  为预测的干净图像， $N$  为每个训练轮次输入的样本数， $\theta$  为整个模型的参数。

## 3 实验及结果分析

### 3.1 实验平台及参数设置

本文实验的框架为 Pytorch<sup>[29]</sup>，操作系统为 Windows10，CPU 为 Inter Core i7-10700F，GPU 为 NVIDIA GeForce RTX 3060，运行内存为 12GB，选取的优化器为 ADAM optimizer<sup>[30]</sup>（其中  $\beta_1=0.9$ 、 $\beta_2=0.999$ 、epsilon= $1 \times e^{-8}$ ），其学习率设置参考文

献<sup>[22]</sup>, 分别设置为  $1 \times e^{-3}$  (1-30epochs)、 $1 \times e^{-4}$  (31-60epochs)、 $1 \times e^{-5}$  (61-120epochs), 批处理大小为 64。整个训练过程使用 NVIDIA CUDA 11.2 + cuDNN-v8.2 进行加速。

### 3.2 实验数据集

本文选择 Berkeley Segmentation Dataset(BSD500)<sup>[31]</sup> 作为训练集, 并将其中与 CBSD68<sup>[32]</sup>数据集中相同的图像删除, 在剩余的图像中随机选取 400 张大小为  $481 \times 321$  的图像作为训练集, 其余 32 张图像作为验证集。图像中不同区域包含不同的信息<sup>[33]</sup>, 受此启发, 本文对图像进行裁剪, 其裁剪窗口大小为  $40 \times 40$ , 另外, 实验对每张图像进行了随机旋转, 旋转角度分别为  $90^\circ$ 、 $180^\circ$ 、 $270^\circ$ 。

针对随机脉冲噪声图像去噪, 本文选择 CBSD68、Kodak24<sup>[34]</sup>、McMaster<sup>[35]</sup>和 PolyU<sup>[36]</sup>四个数据集作为实验的测试集, 其中 CBSD68 数据集是 BSD68 数据集的彩色版本, Kodak24 主要是室外场景图像的数据集, McMaster 数据集是被广泛使用在去除马赛克的数据集, PolyU 数据集为真实世界数据集。

### 3.3 噪声模型和评价指标

实验过程中, 使用的脉冲噪声模型如式(8)所示。

表 1 Kodak24 数据集上各类算法的实验结果

Table 1 The experimental results of various algorithms on Kodak24

算法	噪声等级				噪声等级			
	0.15	0.25	0.35	0.50	0.15	0.25	0.35	0.50
	PSNR 平均值				FSIMc 平均值			
VMF	28.76	26.99	24.35	19.97	0.970	0.953	0.915	0.812
RSVMF	29.93	24.86	20.44	15.75	0.981	0.947	0.871	0.723
FPGFvmf	30.96	28.06	24.91	20.12	0.982	0.966	0.927	0.818
EDSVMF	28.93	27.78	26.33	22.42	0.969	0.961	0.940	0.858
L0TV	26.78	25.87	25.02	23.96	0.948	0.934	0.919	0.892
AWQD	34.10	31.51	29.48	26.34	0.991	0.984	0.973	0.939
QBSF	29.41	26.97	25.39	23.11	0.974	0.955	0.931	0.877
DnCNN	37.58	35.63	34.12	31.78	0.995	0.991	0.987	0.978
FFDNet	38.93	36.56	34.21	31.23	0.996	0.993	0.989	0.977
ADNet	40.52	36.23	34.03	31.57	0.997	0.994	0.989	0.982
DeQCANet	40.56	37.82	35.44	32.68	0.998	0.995	0.992	0.984
本文算法	<b>41.32</b>	<b>38.61</b>	<b>36.40</b>	<b>33.44</b>	<b>0.998</b>	<b>0.997</b>	<b>0.993</b>	<b>0.987</b>

$$y_i = \begin{cases} z_i, & \text{with probability } \rho \\ x_i, & \text{with probability } 1-\rho \end{cases} \quad (8)$$

式中,  $\rho$  表示图像受噪声污染的概率,  $z_i$  表示

0 - 255 中的任意随机值所替换的像素值,  $x_i$  表示未被污染的像素值。本文使用峰值信噪比(PSNR)和特征相似度(FSIMc)<sup>[37]</sup>作为评价指标来评估去噪效果。PSNR 量化评价了图像视觉效果, FSIMc 利用特征相似性进行图像质量评价。

### 3.4 实验结果与分析

#### 3.4.1 与不同算法的对比实验

针对随机脉冲噪声图像去噪, 选取以下具有代表性的算法: VMF<sup>[38]</sup>、RSVMF<sup>[39]</sup>、FPGFvmf<sup>[40]</sup>、EDSVMF<sup>[41]</sup>、L0TV<sup>[42]</sup>、AWQD<sup>[43]</sup>、QBSF<sup>[44]</sup>、DnCNN<sup>[15]</sup>、FFDNet<sup>[16]</sup>、ADNet<sup>[22]</sup>、DeQCANet<sup>[45]</sup>与本文算法进行比较。其中 VMF、RSVMF、FPGFvmf、EDSVMF、L0TV、QBSF 和 AWQD 为传统算法, DnCNN、FFDNet、ADNet 和 DeQCANet 为深度学习算法, 其参数设置与本文保持一致, 传统算法在 Windows 10 系统中的 MatlabR2020a 环境下运行。



表 2 McMaster 数据集上各类算法的实验结果

Table 2 The experimental results of various algorithms on McMaster

算法	噪声等级				噪声等级			
	0.15	0.25	0.35	0.50	0.15	0.25	0.35	0.50
	PSNR 平均值				FSIMc 平均值			
VMF	30.57	27.22	23.17	17.67	0.981	0.957	0.898	0.756
RSVMF	31.01	24.43	19.51	14.35	0.987	0.944	0.853	0.687
FPGFvmf	33.22	28.43	23.7	17.84	0.990	0.969	0.910	0.762
EDSVMF	31.11	29.36	26.52	20.27	0.982	0.973	0.944	0.811
LOTV	29.51	27.72	26.42	24.51	0.971	0.960	0.945	0.914
AWQD	35.55	32.85	30.28	25.64	0.994	0.989	0.979	0.934
QBSF	29.29	26.89	25.09	21.95	0.975	0.958	0.932	0.858
DnCNN	35.56	33.85	32.73	30.97	0.993	0.990	0.986	0.976
FFDNet	38.17	36.29	34.20	30.92	0.996	0.994	0.990	0.977
ADNet	40.48	35.44	32.86	30.65	<b>0.998</b>	0.994	0.989	0.981
DeQCANet	39.48	36.94	34.42	32.19	<b>0.998</b>	0.996	0.993	0.986
本文算法	<b>41.45</b>	<b>39.26</b>	<b>36.66</b>	<b>33.75</b>	<b>0.998</b>	<b>0.997</b>	<b>0.994</b>	<b>0.988</b>

表 3 CBSD68 数据集上各类算法的实验结果

Table 3 The experimental results of various algorithms on CBSD68

算法	噪声等级				噪声等级			
	0.15	0.25	0.35	0.50	0.15	0.25	0.35	0.50
	PSNR 平均值				FSIMc 平均值			
VMF	27.76	26.04	23.51	19.19	0.910	0.887	0.840	0.725
RSVMF	29.13	24.28	19.95	15.21	0.958	0.912	0.820	0.649
FPGFvmf	29.93	27.28	24.12	19.38	0.958	0.928	0.872	0.741
EDSVMF	28.19	27.13	25.48	21.61	0.927	0.907	0.872	0.768
LOTV	26.25	25.16	24.25	23.01	0.907	0.883	0.857	0.811
AWQD	33.45	30.89	28.81	25.58	0.979	0.962	0.940	0.883
QBSF	28.77	26.33	24.59	22.23	0.955	0.920	0.878	0.795
DnCNN	36.56	34.54	32.81	30.65	0.987	0.979	0.968	0.949
FFDNet	37.91	35.47	33.05	30.42	0.987	0.979	0.968	0.949
ADNet	38.62	35.31	33.15	30.82	0.991	0.982	0.971	0.952
DeQCANet	38.91	36.28	34.01	31.39	0.991	0.985	0.975	0.956
本文算法	<b>39.49</b>	<b>36.73</b>	<b>34.66</b>	<b>32.11</b>	<b>0.992</b>	<b>0.986</b>	<b>0.977</b>	<b>0.960</b>

表 4 PolyU 数据集上各类算法的实验结果

Table 4 The experimental results of various algorithms on the PolyU

算法	噪声等级				噪声等级			
	0.15	0.25	0.35	0.50	0.15	0.25	0.35	0.50
	PSNR 平均值				FSIMc 平均值			
VMF	39.56	32.78	26.78	20.03	0.992	0.966	0.893	0.713
RSVMF	35.53	26.82	21.10	15.54	0.989	0.929	0.801	0.588
FPGFvmf	40.49	33.26	27.03	20.12	0.996	0.973	0.902	0.717
EDSVMF	42.50	38.56	32.87	24.10	0.997	0.991	0.963	0.812
L0TV	39.87	37.74	36.08	33.71	0.995	0.992	0.988	0.976
AWQD	46.25	42.59	39.39	33.02	0.998	0.996	0.993	0.965
QBSF	31.09	28.99	27.64	25.45	0.964	0.944	0.924	0.868
DnCNN	43.02	41.69	42.22	40.55	0.996	0.994	0.990	0.989
FFDNet	46.80	47.17	44.79	40.65	0.998	0.998	0.997	0.991
ADNet	52.03	45.37	42.35	40.16	<b>0.999</b>	0.997	0.996	0.993
DeQCANet	51.87	49.60	46.49	44.02	<b>0.999</b>	<b>0.999</b>	0.997	0.996
本文算法	<b>56.93</b>	<b>53.95</b>	<b>47.82</b>	<b>46.32</b>	<b>0.999</b>	<b>0.999</b>	<b>0.999</b>	<b>0.998</b>

表 5 Kodak24 数据集上各类算法的实验结果

Table 5 The experimental results of various algorithms on Kodak24

算法	噪声等级		噪声等级	
	0.75	0.85	0.75	0.85
	PSNR 平均值		FSIMc 平均值	
VMF	14.10	12.41	0.612	0.553
RSVMF	11.06	9.93	0.551	0.518
FPGFvmf	14.11	12.41	0.611	0.552
EDSVMF	15.55	13.61	0.651	0.596
L0TV	21.85	19.72	0.808	0.733
AWQD	18.90	15.54	0.732	0.619
QBSF	17.05	14.57	0.676	0.597
DnCNN	28.29	25.74	0.950	0.909
FFDNet	27.65	25.21	0.947	0.907
ADNet	27.74	25.83	0.950	0.914
DeQCANet	27.83	25.85	0.952	0.907
本文算法	<b>28.58</b>	<b>26.64</b>	<b>0.955</b>	<b>0.928</b>

表 6 McMaster 数据集上各类算法的实验结果

Table 6 The experimental results of various algorithms on McMaster

算法	噪声等级		噪声等级	
	0.75	0.85	0.75	0.85
	PSNR 平均值		FSIMc 平均值	
VMF	11.78	10.34	0.557	0.515
RSVMF	9.72	8.67	0.522	0.495
FPGFvmf	11.80	10.34	0.556	0.515
EDSVMF	12.75	11.09	0.590	0.550
L0TV	21.38	17.17	0.815	0.701
AWQD	15.74	12.56	0.650	0.552
QBSF	14.02	11.79	0.605	0.536
DnCNN	27.28	24.26	0.945	0.889
FFDNet	26.35	24.03	0.940	0.883
ADNet	26.83	24.35	0.946	0.892
DeQCANet	27.02	24.68	0.948	0.895
本文算法	<b>27.42</b>	<b>25.34</b>	<b>0.950</b>	<b>0.912</b>

表 7 CBSD68 数据集上各类算法的实验结果

Table 7 The experimental results of various algorithms on CBSD68

算法	噪声等级		噪声等级	
	0.75	0.85	0.75	0.85
	PSNR 平均值		FSIMc 平均值	
VMF	13.44	11.83	0.543	0.509
RSVMF	10.67	9.61	0.467	0.441
FPGFvmf	13.46	11.83	0.543	0.509
EDSVMF	14.83	12.95	0.582	0.553
L0TV	20.75	18.39	0.710	0.648
AWQD	18.07	14.82	0.645	0.546
QBSF	16.33	13.90	0.580	0.512
DnCNN	27.18	24.91	0.894	0.832
FFDNet	26.65	24.78	0.882	0.820
ADNet	26.79	24.93	0.892	0.838
DeQCANet	26.96	25.17	0.895	0.845
本文算法	<b>27.48</b>	<b>25.66</b>	<b>0.900</b>	<b>0.854</b>

表 8 PolyU 数据集上各类算法的实验结果

Table 8 The experimental results of various algorithms on the PolyU

算法	噪声等级		噪声等级	
	0.75	0.85	0.75	0.85
	PSNR 平均值		FSIMc 平均值	
VMF	13.07	11.40	0.464	0.417
RSVMF	10.44	9.32	0.408	0.386
FPGFvmf	13.08	11.40	0.464	0.417
EDSVMF	14.45	12.43	0.523	0.477
L0TV	28.72	22.61	0.922	0.814
AWQD	19.25	14.87	0.669	0.594
QBSF	16.88	13.79	0.623	0.595
DnCNN	38.53	34.46	0.981	0.953
FFDNet	36.64	34.58	0.978	0.957
ADNet	35.78	35.06	0.982	0.961
DeQCANet	38.54	35.84	0.986	0.965
本文算法	<b>40.32</b>	<b>37.87</b>	<b>0.989</b>	<b>0.978</b>

表 1-表 8 分别展示了当随机脉冲噪声等级为 0.15、0.25、0.35、0.5、0.75 和 0.85 时, 在数据集 CBSD68、McMaster、Kodak24 和 PolyU 上不同方法的平均 PSNR 值和 FSIMc 值。从表中的结果可以看出, 在传统方法中, VMF、RSVMF、FPGFvmf、EDSVMF 随着噪声密度的增加, 算法的去噪性能迅速下降, 这是因为噪声密度较大时, 用于噪声复原的滤波窗口内的大部分像素可能都是噪声, 导致得到的矢量中值也是噪声; 在噪声等级为 0.15 和 0.25 时, L0TV 获得的结果受噪声等级的大小的影响较小, 原因是 L0TV 为基于数据保真度的正则化模型; 在噪声等级小于等于 0.5 时, AWQD 能够获得较好的 PSNR 和 FSIMc 值。而深度学习方法 (DnCNN、FFDNet、ADNet、DeQCANet 和本文算法) 与传统方法 (VMF、RSVMF、FPGFvmf、EDSVMF、L0TV、AWQD 和 QBSF) 相比, 在各噪声等级均具有更高的 PSNR 和 FSIMc 值, 这说明在图像去噪领域卷积神经网络比传统去噪方法拥有更好的去噪性能。本文提出的算法能够获得较大的 PSNR 和 FSIMc 值, 这说明本文算法在噪声抑制和信息保真这方面能够获得比其它方法更好的效果。

另外, 本文展示了不同算法对四幅图像的去噪结果, 如图 7-图 10 所示。图像分别选自 CBSD68、McMaster、PolyU 和 Kodak24 数据集, 噪声等级分

别为 0.15、0.25、0.35 和 0.5。噪声等级为 0.15 时, 从图 7 可以看出虽然 VMF、L0TV、FPGFvmf 和 EDSVMF 去噪效果好, 但是人的头部变得模糊, 其图像的细节与纹理均丢失了。图 8 和图 9 中发现经 ADNet 处理的图像会出现颜色伪影。图 9 和图 10 给出在中度噪声污染和高度噪声污染情况下各种算法的去噪结果, 可以看出深度学习算法 (DnCNN、FFDNet、ADNet、和 DeQCANet) 的优势, 它们能在有效去除噪声的同时保留图像的边缘、纹理细节等, 而其他传统方法中 RSVMF、QBSF 不能充分地去除噪声, L0TV、EDSMF 得到的图像过于平滑, 其图像边缘、纹理和细节被严重破坏, 本文算法能更好地去除噪声的同时保留图像的边缘和纹理等细节特征, 这是因为本文首先丰富了浅层特征图多尺度特征信息, 浅层特征包含图像的局部特征细节信息和边缘信息, 再通过给不同特征通道加权, 加强图像的重要信息, 弱化不重要信息, 同时通过密集跳跃连接减少卷积过程中的语义与细节信息损失。本文算法得到的四幅图像在质量和视觉效果上比其他算法都更为出色, 能够很好地实现随机脉冲噪声图像去噪。

本文所针对的噪声是随机脉冲噪声, 在训练时换成高斯噪声的图像, 也能够对高斯噪声进行去除。






图7 噪声等级为 0.15 时, 不同算法的去噪结果图

Fig.7 Denoised results by various methods with 15% impulse noise




图8 噪声等级为 0.25 时, 不同算法的去噪结果图

Fig.8 Denoised results by various methods with 25% impulse noise






图9 噪声等级为 0.35 时, 不同算法的去噪结果图

Fig.9 Denoised results by various methods with 35% impulse noise




图10 噪声等级 0.5 时, 不同算法的去噪结果图

Fig.10 Denoised results by various methods with 50% impulse noise

### 3.4.2 加权密集扩张卷积块数量的影响

考虑到加权密集扩张卷积块 (WDDb) 的数量对去噪效果的影响, 为了得到 WDDb 的最佳数量, 本文分别设计了包含 2、3、4、5 和 6 个 WDDb 的去噪网络, 实验训练设置相同, 选择 Kodak24、McMaster、CBSD68 作为测试集, PSNR 和 FSIMc 值评估去噪性能。实验结果如表 9 所示, 在 Kodak24

和 CBSD68 数据集中, 当 WDDb 的数量为 4 时, PSNR 和 FSIMc 值达到了最佳, 而在 McMaster 数据集中, WDDb 的数量为 6 时, PSNR 和 FSIMc 值达到了最佳, 相比 WDDb 数量为 4 时, PSNR 值只增加了 0.06db, 但随着 WDDb 数量的增加, 网络的计算量会增加, 耗时随之增加, 因此, 本文选择包含 4 个 WDDb 的去噪网络。

表 9 加权密集扩张卷积块数量的实验结果

Table 9 The experimental Results on Weighted Dense Dilated Convolutional Block Numbers

数据集	块数					块数				
	2	3	4	5	6	2	3	4	5	6
	PSNR 平均值					FSIMc 平均值				
Kodak24	34.95	36.08	<b>36.40</b>	36.32	36.16	0.991	0.992	<b>0.993</b>	<b>0.993</b>	0.992
McMaster	35.00	35.98	36.66	36.68	<b>36.72</b>	0.991	0.992	<b>0.994</b>	<b>0.994</b>	<b>0.994</b>
CBSD68	33.61	34.48	<b>34.66</b>	34.60	34.48	0.972	0.976	<b>0.977</b>	0.976	0.976

### 3.4.3 不同扩张因子取值及其组合策略

为了得到扩张因子取值的最佳组合, 本文设计了五种组合。组合 1 的扩张因子分别为 1、2、3、4, 组合 2 的扩张因子分别为 1、2、3、5, 组合 3 的扩张因子分别为 1、2、3、6, 组合 4 的扩张因子分别为 2、3、4、5, 组合 5 的扩张因子分别为 3、4、5、6。选择 Kodak24、McMaster、CBSD68 作为测试集, PSNR 和 FSIMc 值评估去噪性能。实验结果如表 10 所示。从表 10 可以看出在四个数据

集上组合 1 获得了最佳的 PSNR 和 FSIMc 值, 相比于其他组合, 在数据集 Kodak24 上其 PSNR 值提高了 0.33db-0.69db, FSIMc 值提升了 0.003; 在数据集 McMaster 上其 PSNR 值提高了 0.5db-1.92db, FSIMc 值提升了 0.002-0.004; 在数据集 CBSD68 上其 PSNR 值提高了 0.15db-0.36db, FSIMc 值提升了 0.008; 在数据集 PolyU 上其 PSNR 值提高了 1.04-3.05db。因此, 本文最终选择组合 1。

表 10 不同扩张因子取值组合的实验结果

Table 10 The experimental Results of combinations of different expansion factors

数据集	组合					组合				
	1	2	3	4	5	1	2	3	4	5
	PSNR 平均值					FSIMc 平均值				
Kodak24	<b>38.61</b>	38.28	38.22	37.92	38.21	<b>0.998</b>	0.995	0.995	0.995	0.995
McMaster	<b>39.26</b>	38.76	38.73	37.34	38.67	<b>0.998</b>	0.996	0.996	0.994	0.996
CBSD68	<b>36.73</b>	36.58	36.52	36.37	36.52	<b>0.992</b>	0.984	0.984	0.984	0.984
PolyU	<b>53.95</b>	52.91	52.86	50.90	52.80	<b>0.999</b>	0.999	0.999	0.999	0.999

### 3.4.4 参数与耗时情况

选择深度学习算法与本文算法进行试验对比, 在网络参数方面, 网络输入为 3 通道的

500×500 的图片, 整个网络的参数量和计算复杂度如表 11 所示。在运行时间方面, 采用相同的环境对大小为 500×500 的噪声图像进行去噪。运行



时间对比结果如表 11 所示。

实验结果表明, 在运行时间方面, DnCNN 的耗时最短, 与 DnCNN、ADNet 和 DeQCANet 相比, 本文算法耗时增长, 在网络参数与计算量上, 由于本文的网络结构较深, 导致算法的参数

和计算量相应增加。但本文算法相较于其他算法有更好的去噪性能, 而且在这样的基础下, 本文算法的运行时间相对其他算法只增加了 0.01 秒左右, 说明本文算法与其他深度学习算法相比仍具有一定的优势。

表 11 不同去噪算法的参数与耗时比较

Table 11 Parameters and time comparisons of different denoising algorithms

方法	DnCNN	ADNet	DeQCANet	本文算法
参数	0.55M	0.52M	0.48M	0.91M
FLOPs	1.46G	1.36G	1.27G	2.41G
运行时间 (秒)	0.0033	0.0036	0.0080	0.0168

### 3.5 消融实验

为了验证本文提出的加权密集扩张卷积连接网络对脉冲噪声去除是否具有改善效果, 本文分别设计了密集普通卷积连接网络、密集扩张卷积连接网络以及本文提出的网络。上述前两个网络的实验训练设置与本文提出的方法相同, 并将 CBSD68、McMaster、Kodak24 数据集作为测试集, 以 PSNR 和 FSIMc 值评估去噪性能。表 12 给出了三个网络在测试集上的 PSNR 和 FSIMc 的平均值。

根据表 12 中的结果可以得出, 在噪声等级分别为 0.15、0.25、0.35 和 0.5 时, 本文算法在三个测试集上的 PSNR 和 FSIMc 值都取得了最高值, 与普通卷积相比, 本文方法的 PSNR 值提高了 0.2db-1.36db; 与使用扩张卷积相比, PSNR 值提高了 0.1db-0.68db; 使用扩张卷积与普通卷积相比, PSNR 值提高了 0.02db-0.68db, 说明使用扩张卷积对模型去噪性能也有一定的提升。

图 11 给出了在噪声等级为 0.5 时, 普通卷积与扩张卷积的去噪结果图。从图中可以看出, 普通卷积在对字母 B 的恢复丢失了边缘细节信息, 而扩张卷积对字母 B 的恢复强于普通卷积, 这说明了结合扩张卷积能够提升网络的表达能力。

为了了解本文网络学习到的不同特征通道的权重, 使用 grad-cam<sup>[46]</sup>方法来直观展示特征通道加权在突出特征方面的作用, 其对比结果如图 12 所示。图中热力图的分布区域体现了对图片的关注度, 图中的 b2 相比于 a2, 其热力图的分布区域有明显的集中, 关注度的范围也更加集中; 图中的 b3 相比于 a3, 其热力图的亮度有着明显的变化, 关注度高的区域和其他区域区别明显。两种热力图的变化都根据权重强化了图片的重要信息, 弱化抑制相对次要的信息。

实验结果验证了加权密集连接的有效性, 以及本文算法对随机值脉冲噪声去除具有明显改善效果。



图 11 普通卷积与扩张卷积的去噪结果图

Fig.11 Denoised results of convolution and dilated convolution






图 12 扩张卷积和加权扩张卷积结果热力图对比

Fig.12 Comparison of the heat maps of dilated convolution and weighted dilated convolution

表 12 Kodak24、McMaster、CBSD68 数据集上消融实验的结果

Table 12 The experimental results of different modules on Kodak24, McMaster and CBSD68										
数据集		Kodak24			McMaster			CBSD68		
算法	噪声等级	普通卷积	扩张卷积	加权扩张	普通卷积	扩张卷积	加权扩张	普通卷积	扩张卷积	加权扩张
PSNR	0.15	41.08	41.16	<b>41.32</b>	41.03	41.19	<b>41.45</b>	39.36	39.39	<b>39.49</b>
	0.25	38.26	38.51	<b>38.61</b>	37.90	38.58	<b>39.26</b>	36.53	36.59	<b>36.73</b>
	0.35	36.17	36.19	<b>36.40</b>	36.24	36.55	<b>36.66</b>	34.48	34.50	<b>34.66</b>
	0.50	33.23	33.34	<b>33.44</b>	33.11	33.60	<b>33.75</b>	31.91	31.90	<b>32.11</b>
FSIMc	0.15	0.997	0.997	<b>0.998</b>	0.997	<b>0.998</b>	<b>0.998</b>	0.991	<b>0.992</b>	<b>0.992</b>
	0.25	0.995	0.996	<b>0.997</b>	0.995	0.995	<b>0.997</b>	0.984	0.985	<b>0.986</b>
	0.35	0.992	0.992	<b>0.993</b>	0.993	0.993	<b>0.994</b>	0.976	0.976	<b>0.977</b>
	0.50	0.985	0.986	<b>0.987</b>	0.986	0.987	<b>0.988</b>	0.957	0.959	<b>0.960</b>

4 结论

为了更好地去除随机脉冲噪声，本文结合密集连接和扩张卷积的优点，提出一种加权密集扩张卷积连接的去噪网络模型。该模型能够充分地利用不同层次的特征，保留图像细节信息，并在密集连接时，通过对不同特征通道加权，反映浅层与深层卷积特征的重要性，增强重要特征信息的表达能力，

充分挖掘特征信息。实验结果表明，所提模型能够有效地提高图像随机脉冲噪声的去除效果。但是新网络模型较相关模型去噪耗时有所增加，未来的工作将继续探索在进一步提升去噪效果的同时，减少网络深度，降低耗时。

参考文献：

[1] Boncellet C. Image noise models[M]. The Essential Guide to Image Processing, 2009: 143-167.

- [2] Faraji H, MacLean W. CCD noise removal in digital images[J]. *IEEE Transactions on Image Processing*, 2006, 15: 2676–2685.
- [3] Liu C, Szeliski R, Kang B, Zitnick C L, Freeman W T. Automatic Estimation and Removal of Noise from a Single Image[J]. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2008, 30: 299–314.
- [4] Smolka B, Malik K, Malik D. Adaptive rank weighted switching filter for impulsive noise removal in color images[J]. *Real-Time Image Processing*, 2012, 10: 289–311.
- [5] Malinski L, Smolka B. Self-tuning fast adaptive algorithm for impulsive noise suppression in color images[J]. *Real-Time Image Processing*, 2020, 17: 1067–1087.
- [6] Nadeem M, Hussain A, Munir A, Habib M, Tahir Naseem M. Removal of random valued impulse noise from gray-scale images using quadrant based spatially adaptive fuzzy filter[J]. *Signal Processing*, 2020, 169:107403.
- [7] Dong Y, Chan R H, Xu S. A detection statistic for random-valued impulse noise[J]. *IEEE Transactions on Image Processing*, 2007, 16(4): 1112–1120.
- [8] Lü Q, Guo M, Pei Z. DeGAN: Mixed noise removal via generative adversarial networks[J]. *Applied Soft Computing*, 2020, 95: 106478.
- [9] Jin K H, Ye J C. Sparse and low-rank decomposition of a Hankel structured matrix for impulse noise removal[J]. *IEEE Transactions on Image Processing*, 2018, 27(3): 1448–1461.
- [10] Xu Q, Li Y H, Guo Y J, et al. Random-valued impulse noise removal using adaptive ranked-ordered impulse detector[J]. *Journal of Electronic Imaging*, 2018, 27(1): 013001. DOI: 10.1117/1.JEI.27.1.013001.
- [11] Mafi M, Rajaei H, Cabrerizo M, et al. A robust edge detection approach in the presence of high impulse noise intensity through switching adaptive median and fixed weighted mean filtering[J]. *IEEE Transactions on Image Processing*, 2018, 27(11): 5475–5490.
- [12] Roy A, Singha J, Manam L, et al. Combination of Adaptive Vector Median Filter and Weighted Mean Filter for Removal of High-density Impulse Noise from Color Images[J]. *IEEE Transactions on Image Processing*, 2017, 11(6): 352–361.
- [13] Wangac Y, Fub J, Adhamia R, et al. A Novel Learning-based Switching Median Filter for Suppression of Impulse Noise in Highly Corrupted Color Image[J]. *The Imaging Science Journal*, 2016, 64(1): 15–25.
- [14] Malinski L, Smolka B. Fast adaptive switching technique of impulsive noise removal in color images[J]. *Real-Time Image Processing*, 2019, 16: 1077–1098.
- [15] Zhang K, Zuo W, Chen Y, Meng D, Zhang L. Beyond a Gaussian Denoiser: Residual Learning of Deep CNN for Image Denoising[J]. *IEEE Transactions on Image Processing*, 2017, 26: 3142–3155.
- [16] Zhang K, Zuo W, Zhang L. FFDNet: toward a fast and flexible solution for CNN-based image denoising[J]. *IEEE Transactions on Image Processing*, 2018, 27(9): 4608–4622.
- [17] Guo S, Yan Z F, Zhang K, Zuo W M, Zhang L. Toward convolutional blind denoising of real photographs[C]//*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019: 1712–1722.
- [18] Jin L H, Zhang W H, Ma G Z, Song E. Learning deep CNNs for impulse noise removal in images[J]. *Journal of Visual Communication and Image Representation*, 2019, 62:193–205.
- [19] Zhang W H, Jin L H, Song E, Xu X Y. Removal of impulse noise in color images based on convolutional neural network[J]. *Applied Soft Computing*, 2019, 82(105558):1–11.
- [20] Radlak K, Malinski L, Smolka B. Deep learning based switching filter for impulsive removal in color images[J]. *Sensors*, 2020, 20(10): 2782.
- [21] Zhao Y Y, Jiang Z Q, Men A D, Ju G D. Pyramid Real Image Denoising Network[J]. *arXiv:1908.00273*, 2019.
- [22] Tian C, Xu Y, Li Z, Zuo W, Fei L, Liu H. Attention-guided CNN for image denoising[J]. *Neural Networks*, 2020, 124: 117–129.
- [23] Yu K, Wang X, Dong C, et al. Path-Restore: Learning Network Path Selection for Image Restoration[J]. *arXiv:1904.10343*, 2019.
- [24] Li X, Wang W H, Hu X L, Yang J. Selective Kernel Networks[C]//*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition(CVPR)*, 2019: 510–519.
- [25] He K M, Zhang X Y, Ren S Q, Sun J. Deep residual learning for image recognition[C]//*Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, Las Vegas, June 26–July 1, 2016. Piscataway: IEEE*, 2016: 770–778.
- [26] Yu F, Koltun V. Multi-scale Context Aggregation by Dilated Convolutions[C]//*Proceedings of the International Con-*

- ference on Learning Representations(ICLR), 2016.
- [27] Huang G, Liu Z, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017: 2261-2269.
- [28] Li H, Xu Z, Taylor G, Studer C, Goldstein T. Visualizing the loss landscape of neural nets[C]//Proceedings of the Conference and Works hop on Neural Information Processing Systems(NIPS), Montreal, Canada, 2018: 6389-6399.
- [29] Paszke A, Gross S, Massa F, Leter A, Bradbury J, Chanan G, Killeen T, Lin Z, Gimelshein N, Antiga L, et al. Pytorch: An imperative style, high-performance deep learning library[C]//In Advances in Neural Information Processing Systems, Vancouver, Canada, 2019: 8024-8035.
- [30] Kingma DP, Ba J. Adam: A method for stochastic optimization[J]. arXiv:1412.6980, 2014.
- [31] Arbelaez P, Maire M, Fowlkes C, et al. Contour detection and hierarchical image segmentation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2010, 33(5): 898-916.
- [32] Martin D, Fowlkes C, Tal D, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics[C]//Proceedings of the IEEE International Conference on Computer Vision. ICCV 2001. IEEE, 2001, 2: 416-423.
- [33] Zoran D, Weiss Y. From learning models of natural image patches to whole image restoration[C]//Proceedings of the IEEE International Conference on Computer Vision, 2011: 479-486.
- [34] Franzen R. Kodak lossless true color image suite[J]. source: <http://r0k.us/graphics/kodak>, 1999, 4(2).
- [35] Li X, Gunturk B, Zhang L. Image demosaicing: A systematic survey[C]//Visual Communications and Image Processing 2008. International Society for Optics and Photonics, 2008, 6822: 68221J.
- [36] Xu J, Li H, Liang Z, Zhang D, Zhang L. Real-world noisy image denoising: A new benchmark[J]. arXiv: 1804.02603, 2018.
- [37] Zhang L, Zhang L, Mou X, Zhang D. FSIM: A feature similarity index for image quality assessment[J]. IEEE Transactions on Image Processing, 2011, 20(8): 2378-2386.
- [38] Astola J, Haavisto P, Neuvo Y. Vector median filters[J]. Proceedings of the IEEE, 1990, 78(4): 678-689.
- [39] Clelebi M E, Aslandogan Y A. Robust switching vector median filter for impulsive noise removal[J]. Journal of Electronic Imaging, 2008, 17(4): 043006.
- [40] Smolka B, Chydzinski A. Fast detection and impulsive noise removal in color images[J]. Real-Time Imaging, 2005, 11(5-6): 389-402.
- [41] Xu J, Wang L, Shi Z. A switching weighted vector median filter based on edges detection[J]. Signal Processing, 2014, 98: 359-369.
- [42] Yuan G, Ghanem B. 10tv: A new method for image restoration in the presence of impulse noise[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Boston, MA, USA, 2015: 5369-5377.
- [43] Jin L, Zhu Z, Song E, Cu X. An effective vector filter for impulse noise reduction based on adaptive quaternion color distance mechanism[J]. Singal Processing, 2019, 155: 334-345.
- [44] Wang G, Liu Y, Zhao T. A quaternion-based switching filter for color image denoising[J]. Signal Processing, 2014, 102: 216-225.
- [45] Cao Y Q, Fu Y Y, Zhu Z L, Rao Z C. Color Random Valued Impulse Noise Removal Based on Quaternion Convolutional Attention Denoising Network[J]. Signal Processing Letters, 2021, 29: 369-373.
- [46] Sekvaraju R R, Cogswell M, Das A, et al. Grad-cam: visual explanations from deep networks via gradient-based locational[C]//Proceedings of the IEEE international conference on computer vision, Venice, October 22-29, 2017. Berlin, Heidelberg: Springer, 2017: 618-626.