



计算机科学与探索

Journal of Frontiers of Computer Science and Technology

ISSN 1673-9418, CN 11-5602/TP

《计算机科学与探索》网络首发论文

题目: DnRFD: 用于图像去噪的递进式残差融合密集网络
作者: 曹义亲, 饶哲初, 朱志亮, 张红斌
网络首发日期: 2021-04-30
引用格式: 曹义亲, 饶哲初, 朱志亮, 张红斌. DnRFD: 用于图像去噪的递进式残差融合密集网络. 计算机科学与探索.
<https://kns.cnki.net/kcms/detail/11.5602.tp.20210429.1309.006.html>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式 (包括网络呈现版式) 排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊 (光盘版)》电子杂志社有限公司签约, 在《中国学术期刊 (网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊 (网络版)》是国家新闻出版广电总局批准的网络连续型出版物 (ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

DnRFD：用于图像去噪的递进式残差融合密集网络

曹义亲¹, 饶哲初¹, 朱志亮^{1,2+}, 张红斌¹

1. 华东交通大学 软件学院, 南昌 330013

2. 中国科学院 软件研究所, 北京 100190

+ 通信作者 E-mail: rj_zzl@ecjtu.edu.cn

摘要：基于深度学习的去噪方法能够获得比传统方法更好的去噪效果,但是现有的深度学习去噪方法往往存在网络过深导致计算复杂度过大的问题.针对这个不足,提出一种用于去除高斯噪声的递进式残差融合密集网络 DnRFD.该网络首先采用密集块来学习图像中的噪声分布,在充分提取图像局部特征的同时大幅降低网络参数;然后利用递进策略将浅层卷积特征依次与深层特征短线连接形成残差融合网络,提取出更多针对噪声的全局特征;最后,将各密集块的输出特征图进行融合后输入给重建输出层,得到最后的输出结果.实验结果表明,在高斯白噪声等级为 25 和 50 时,该网络都能获得的较高的峰值信噪比均值和结构相似性均值,并且去噪平均速度相较于 DnCNN 方法提升了一倍,优于 FFDNet 方法两倍.总的来说,该网络整体去噪性能优于相关对比算法,可有效去除图像中的高斯白噪声和自然噪声,同时能更好地还原图像边缘与纹理细节.

关键词：图像去噪; 深度学习; 密集块; 残差学习; 递进式残差融合

文献标志码：A **中图分类号：**TP391

DnRFD: A Progressive Residual Fusion Dense Network for Image Denoising

CAO Yiqin¹, RAO Zhechu¹, ZHU Zhiliang^{1,2+}, ZHANG Hongbin¹

1. School of Software, East China Jiaotong University, Nanchang 330013, China

2. Institute of Software, Chinese Academy of Science, Beijing 100190, China

Abstract: The denoising method based on deep learning can achieve better denoising effect than the traditional method, but the existing deep learning denoising methods often have the problem of excessive computational complexity caused by too deep network. To solve this problem, a progressive residual fusion dense network (DNRFD) is proposed to remove Gaussian noise. Firstly, dense blocks are used to learn the noise distribution in the image, and the network parameters are greatly reduced while the local features of the image are fully extracted. Then, a progressive strategy was used to connect the shallow convolution features with the deep features to form a residual fusion network to extract more global features for noise. Finally, the output characteristic images of each dense block

基金项目：国家自然科学基金项目 (61861016); 江西省科技支撑计划重点项目(20161BBE50081); 江西省青年科学基金项目(20202BAAL212006); 江西省教育厅科学技术研究项目 (GJJ190359)。

This work is supported by the National Natural Science Foundation of China (61861016), the Key Project of Jiangxi Science and Technology Support Plan (20161BBE50081), and the Youth Science Foundation Project of Jiangxi Province (20202BAAL212006), Science and Technology Research Project of Education Department of Jiangxi Province(GJJ190359).

are fused and input to the reconstructed output layer to get the final output result. The experimental results show that, when the Gaussian white noise level is 25 and 50, the network can achieve higher mean PSNR and mean structural similarity, and the denoising average speed is doubled compared with DNCNN method, and twice better than FFDNET method. In general, the overall denoising performance of the network is better than that of the correlative comparison algorithm, which can effectively remove the white Gaussian noise and natural noise in the image, and can restore the edge and texture details of the image better.

Key words: Image denoising; Deep learning; Dense block; Residual learning; Progressive fusion

图像在生成和传输的过程中难免会受到噪声的污染,严重影响图像的进一步分析与处理。目前常见的噪声主要有4种:高斯噪声、泊松噪声、乘性噪声以及脉冲噪声,其中高斯噪声是最常见、也是最具有代表性的一种噪声。高斯噪声是指概率密度函数服从高斯分布的一类噪声。高斯噪声的等级是指高斯分布的方差。本文主要针对高斯噪声的去噪算法进行研究。图像去噪是各种图像处理算法中的重要步骤,有助于对图像内容进行进一步的区分和解释,在计算机视觉领域有着重要意义。

图像去噪^[1]就是从被污染的图像中去除噪声并还原图像。传统的去噪算法可以分为空间域滤波^[2]和频率域滤波^[3]。空间域滤波是将图像像素点与滤波函数进行卷积操作,不同的滤波算法有着不同的函数;频率域滤波则主要是将图像在频率域内的信息与算法函数利用傅里叶变换^[4]进行相乘操作。传统方法能够获得一定的去噪效果,但是在处理中、高噪声图像时效果不理想,且容易丢失图像细节。针对这个不足,许多研究人员提出利用图像先验模型来进行去噪。Buades 等人^[5]提出了非局部均值 NLM(Non-Local Means)的去噪方法。该方法充分利用了图像中的冗余信息,在去噪的同时能最大程度地保持图像的细节特征。Dabov 等人^[6]提出的 BM3D(Block Method of 3-Dimension)算法融合了非局部去噪方法和小波变换域去噪方法的思想,得到了非常好的去噪效果。Knaus 等人^[7]提出的 PID(Progressive Image Denoising)算法将图像去噪作为一种简单的物理过程,通过确定性退火逐步降低噪声,在实现较好去噪效果的前提下,还能够保证没有基于局部块类方法常见的伪像。Gu 等人^[8]结合非局部的思想和低秩逼近理论,提出加权核范数最小

化的去噪方 WNNM(weighted nuclear norm minimization method)。尽管这些基于图像先验模型的方法^[5-11]能够获得较好的去噪效果,但是当噪声密度增大时,这些方法的去噪性能将大幅降低。

近年来,随着深度学习研究的迅速发展,卷积神经网络在机器视觉领域的地位也越来越重要。越来越多的基于深度学习的图像去噪算法被提出,其中最为代表的就是 Zhang 等人^[12]在 2017 年提出的 DnCNN 算法,其去噪性能和细节处理能力相较于之前的算法均有大幅度提升。但基于深度学习的去噪算法是从整幅图像中提取特征,输出与输入图像尺寸保持一致,这就导致其网络参数量巨大、特征提取不够充分。Lefkimmiatis^[13]在 2018 年提出了通用去噪网络(UDN)。该网络是一种新型的网络体系结构,它具有两种变体,第一种网络将卷积层作为核心组件,其行为类似于局部变分方法,而第二种网络则依赖非局部滤波层,该层使网络能够利用自然图像固有的非局部自相似性。这两个网络都带来了非常有竞争力的结果,可以直接与最新技术相媲美,尽管它们的优点是是当前性能最佳的网络相比,所涉及的要少得多。但在耗时方面还是与 DnCNN 相差不大。

本文针对现有的深度学习去噪方法往往存在网络过深导致计算复杂度过大的问题,结合密集块(Dense Block)和残差学习^[14]的优势以及递进融合的策略,提出一种递进式残差融合密集网络,并将其用于高斯噪声的去除。与 DnCNN 在网络中仅简单串联卷积层进行去噪的方法不同的是,本文提出的方法在网络中布置密集连接的密集块,每一层都将之前的特征图作为输入,且结合递进思想将浅层卷积特征图依次与每个密集块提取出的深层卷积

特征图短线连接形成残差块, 使得网络能够更好地预测噪声分布。密集短接的结构则能够有效地降低网络的计算复杂度, 减少大量的网络参数, 缩短算法计算时间。

1 相关工作

1.1 密集块

卷积神经网络由输入层、隐藏层、输出层三部分组成。隐藏层的主要结构为线性卷积和激活函数去线性化操作的交替序列, 主要功能为对输入进行特征映射。在图像去噪领域, 卷积神经网络相较于其他传统方法的优势在于隐藏层能够更好地提取图像特征, 权值共享则极大地降低了网络模型的计算量, 有效的减少了网络的参数个数, 使模型处理效率更高。本文从如何提取更多的图像特征, 同时也能够极大的降低模型计算参数的角度考虑, 综合设计了密集网络, 其中的核心模块即为密集块^[15] (Dense Block)。其结构如图 1 所示, 其中的 Bottleneck 模块的结构如图 2 所示。




Fig.1 Dense Block modular structure

图 1 Dense Block 模块结构




Fig.2 Bottleneck structure

图 2 Bottleneck 结构

在密集块结构中, 层与层之间都通过短接线连接起来, 每一层的输入都来自前面所有层的输出, 该连接可以用公式表示为:

$$X_l = H_l([X_0, X_1, \dots, X_{l-1}]) \quad (1)$$

式中: X_l 表示 l 层的输出特征图, $[X_0, X_1, \dots, X_{l-1}]$ 表示将 0 到 $l-1$ 层的输出特征图做通道的合并, 即直接堆叠通道, 而不对通道进行其它操作。 H_l 则表示将合并后的特征图依次输入到 Bottleneck 中。因为每一层的输入都是前面所有层的输出叠加, 融合了前者所有提取出的特征图, 所以在后面几层的输入通道都会比较大。为了减少输入的 Feature map 数量, 在 Bottleneck 中都设计一个卷积核为 1×1 的卷积层, 既能使得参数更少、减少网络的计算量, 同时又融合各个通道的特征, 使其与梯度的传递更加高效, 噪声分布的学习更加全面。

1.2 残差学习

残差学习的设计初衷是为了解决伴随着网络深度增加的卷积神经网络性能下降以及训练精度下降的问题。残差网络通过学习残差映射的方法, 使得网络的训练精度不会随着网络深度的增加而降低, 解决了网络的退化问题。

结合图像去噪领域, 通过跳连式的网络结构让残差网络学习信息量相对较少的噪声图像, 再由含噪声图像减去网络的预测噪声图像, 得到潜在的纯净图像, 该过程用公式表示表达为:

$$y = x + n \quad (2)$$

式中 y 表示的是含噪声图像, x 表示的是原始的纯净图像, n 表示的是加性噪声。并且在浅层卷积特征提取时, 通过密集块的设计, 提取了丰富的图像特征, 为之后的噪声分布学习奠定了基础。

2 递进式残差融合密集网络(Residual Fusion DenseNet, RFD)的设计

2.1 设计思路

本文受 Huang 等人^[16]提出的 DenseNet 网络结构的启发, 通过密集网络来丰富提取图像的特征, 并利用密集短接的结构降低网络的计算复杂度, 减

少网络参数数量。通过对郭恒意等人^[17]提出的基于残差密集块的去噪网络的实验复现研究,发现其网络并不能够充分地利用浅层卷积特征。所以本文结合递进思想,在加深网络的同时设计了三个残差块,分别将浅层卷积特征与深层密集网络提取出的特征进行融合,使得深层的密集网络能够充分利用浅层特征对噪声分布进行学习。而对密集网络研究发现其网络结构并没有将全局特征进行融合学习。本文进一步受 Zhang 等人^[18]提出的 RDN 网络结构启发,在重建输出层之前设计了 Concat 层,在此层

对之前所有密集网络提取出的特征进行融合操作,使得网络充分学习了局部特征和全局特征,以此来达到更好的去噪效果。

2.2 网络结构

本文提出的网络结构模型主要包括 3 个结构完全相同的 Dense Block 模块,在 Dense Block 模块中每个卷积层后都有线性修正单元 ReLU 作为激活函数,尽量避免梯度消失,且使得网络具有稀疏性,并且减少了参数的相互依存关系。完整的递进式残差融合密集网络的结构模型如图 3 所示。

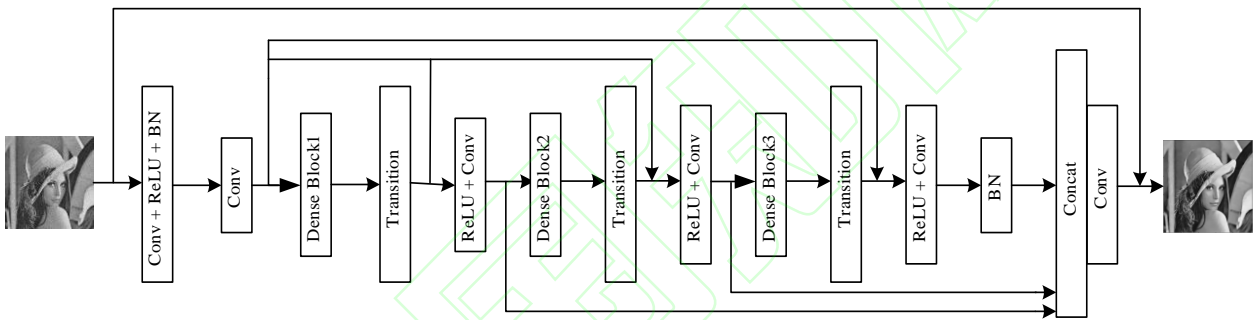


Fig.3 The whole structure of the DnRFD
图 3 递进式残差融合密集网络整体结构

第一层为 Conv+ReLU,卷积层的卷积核大小为 3*3,个数为 64。这一层的主要功能是对输入的含噪声图像进行浅层卷积的特征提取。第二层为 Conv,卷积核大小为 3*3,个数为 24。负责将特征图通道调整到合适的大小,以便输入 Dense Block 模块中不会输出过多的特征图,增加网络计算负担。第三至十二层为整体结构的核心部分,包含了三个 Dense Block 模块、三个残差块,以及两个模块之间的 Translation 层和 ReLU+Conv 层。在 Dense Block 模块中,所有 Bottleneck 的卷积核大小均为 1*1、3*3,个数分别为 48、12。每个 Bottleneck 都能在新的融合特征输入后,进行图像中的噪声分布学习。而在 Translation Layer 中的卷积核大小均为 1*1,个数为 24,目的是为了进一步压缩网络参数,融合通道特征形成新的特征。第十三层为 Concat 层,将第一个 Dense Block 模块以及第二个 Dense Block 模块的输出特征图与第三个 Dense Block 模块

的特征融合,加强了网络对全局特征的学习。第十四层为单个 3*3 卷积核的重建输出层,不仅融合了上一层的全局特征,且使得输出的尺寸与输入保持一致,以便于残差学习能够将预测噪声从含噪图像中抽离,得到纯净图像作为网络的输出。

3 基于 RFD 的图像去噪算法

本文提出的算法具体流程如图 4 所示。训练过程中将原始图像裁剪为大小相同的图像块,然后将这些原始图像块加上噪声输入到设计好的网络中,通过损失函数进行反向传播调节参数,最终使得网络达到收敛状态。测试阶段,将含噪声图像输入到已经收敛的网络中,可直接输出相应的预测去噪图像。本文算法采用的损失函数表达式如下:

$$L_{loss} = \frac{1}{2N} \sum_{i=1}^N \|R(y_i, \Theta) - (y_i - x_i)\|_F^2 \quad (3)$$

式中 $R(y_i, \Theta)$ 为噪声输入的估计残差图像, y_i

为输入的含噪图像, x_i 为纯净图像, $(y_i - x_i)$ 得到的是标准的残差图像。 N 为一个 Batch 的输入样本数量。在训练过程中不断迭代, 将损失函数降低,

也就是将估计残差与标准残差之间的误差降低, 这样预测的去噪图像才能更接近原纯净图像, 获得更好的去噪效果。

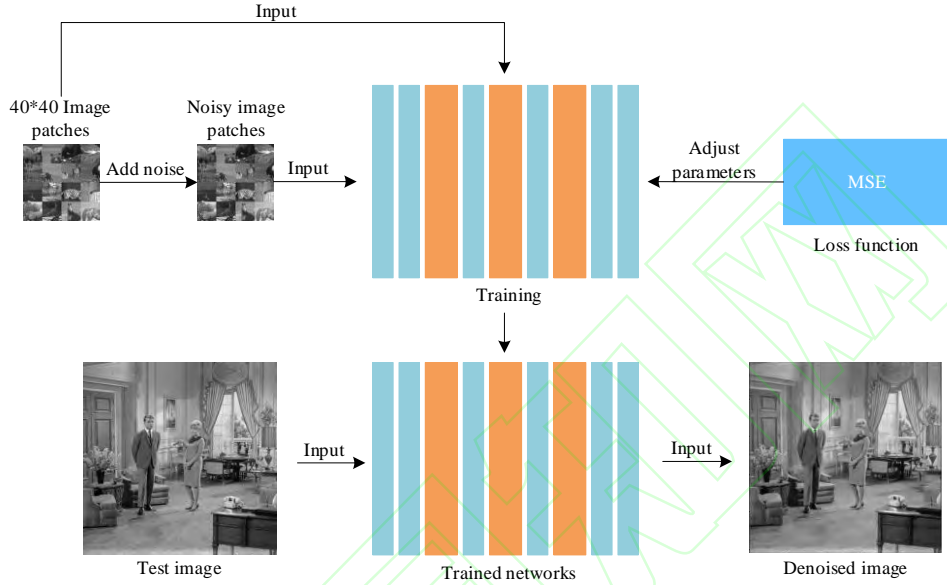


Fig.4 The overall framework of image denoising method based on RFD.

图 4 基于 RFD 的图像去噪方法整体框架

4 实验结果

4.1 度量标准

实验采用的评价标准包括主观评价和客观评价。主观评价即为人为肉眼观测图像, 评价模型输出图像的去噪效果。客观评价^[19]采用峰值信噪比 (PSNR) 和结构相似性 (SSIM)。

PSNR 是基于均方误差^[20] (MSE) 的图像质量评价指标, PSNR 值越大代表着图像的质量越好。实验中, PSNR 的值越大, 表示去噪图像和原图像之间的相似性越高, 去噪效果越好。PSNR 的计算公式为:

$$MSE = \frac{1}{H * W} \sum_{j=1}^H \sum_{k=1}^W (M(j, k) - N(j, k))^2 \quad (4)$$

$$PSNR = 10 \log_{10} \left(\frac{(2^n - 1)^2}{MSE} \right) \quad (5)$$

式中: M 和 N 表示的是预测值和真实值; j 和 k 表示的是图像中的所有像素点。 H 和 W 则分别代表的是图像的高度和宽度, n 取值为 8。

结构相似性 (SSIM) 是一种衡量两幅图像相似

度的评价指标。基于图像的亮度、对比度和结构对其进行相似性的估计。均值作为亮度的估计, 标准差作为对比度的估计, 协方差作为结构相似程度的度量。SSIM 的计算公式为:

$$SSIM(M, N) = \frac{(2\mu_m\mu_n + c_1)(2\sigma_{mn} + c_2)}{(\mu_m^2 + \mu_n^2 + c_1)(\sigma_m^2 + \sigma_n^2 + c_2)} \quad (6)$$

式中: μ_m 表示的是图像 M 的均值, μ_n 表示的是图像 N 的均值。 σ_m^2 和 σ_n^2 则分别表示的是图像 M 和 N 的方差。 σ_{mn} 代表的是图像 M 和 N 的协方差。 c_1 和 c_2 是用来维持稳定的常数。SSIM 的数值范围在 0 到 1 之间, SSIM 值越大, 两幅图像越相似。当 SSIM 值为 1 时, 则代表参与比较的两幅图像完全相似。

4.2 实验参数设定

实验的训练集选取了 400 张 180*180 的灰度图像, 图像的种类包括了自然风景、动物、人物建筑等。为了便于网络训练尽快收敛, 将裁剪框尺寸 patch size 设置为 40, 滑动步长 Stride 设为 10, 裁剪了其中 380 张图像得到了 215552 张 40*40 的子

图像块, 以此作为训练集, 剩余的 20 张图像作为验证集, 通过不同测试集的测试验证网络的鲁棒性和实用性。实验的测试集则随机选取自 Set12^[21], Set68^[22]中。

实验参数设定: 批处理大小为 64, 每轮次训练 3725 个样本数据, epoch 为 150, 训练期间学习率固定为 0.001。计算机的 CPU 配置为 InterCorei7, GPU 为 GTX1080Ti*2, 运行内存为 11GB, 操作系统为 Windows10, 在 pytorch 深度学习框架上训练、验证和测试神经网络, 该框架能够使用 GPU 加速训练, 节省训练时间, 用于训练、测试的软件为 PyCharm, Python 版本为 3.6。

4.3 实验和结果

本文为了客观地评价算法的去噪效果, 选取了 NLM^[5]、BM3D^[6]、WNNM^[8]、DnCNN^[12]、FFDNet^[23]这五种对比算法来进行对比实验, 实验的测试集随机选取自 Set12, Set68 中, 在向测试图像加入的高斯白噪声等级 $\sigma = 25$ 和 $\sigma = 50$ 时, 分别从主观和客观的角度对各算法的去噪能力进行比较。

当高斯白噪声等级 $\sigma = 25$ 时, 随机选取了 6 幅测试图像, 原图如图 5 所示。表 1 为含噪测试图像经各算法去噪后的 PSNR 值。从表中可以看出, 本文算法的 PSNR 均值为 32.623dB, 相对其他算法提升了 0.043~2.462dB。本文算法处理后的图像 PSNR 均值对于传统去噪算法 NLM、BM3D 高出了 0.619~2.462dB, 对于聚类低秩去噪算法 WNNM 高出了 0.39dB, 对于深度学习去噪算法 DnCNN 高出了 0.098dB, FFDNet 算法高出了 0.043dB。表 2 为 6

幅含噪测试图像经各算法去噪后的 SSIM 值。从表中可以看出, 本文算法的 SSIM 均值为 0.956 高于所有对比算法, 相对提升了 0.003~0.151。而经本文算法处理后的前 5 幅去噪图像 SSIM 值都高于所有对比算法, 仅最后一幅图像的 SSIM 值比 FFDNet 算法低了 0.0294。表 3 是不同算法对 6 幅测试图像的去噪平均耗时。可以看出本文算法对于 256*256 像素的图像处理耗时均值为 0.093S, 对于 512*512 像素的图像耗时均值为 0.389S, 对于 418*312 像素的图像耗时均值为 0.228S, 总测试耗均值为 0.237S。虽然 DnCNN、FFDNet 算法的去噪效果与本文算法相差不大, 但是去噪平均耗时却超出本文算法将近 1~2 倍。



Fig.5 Test pictures for $\sigma = 25$.

图 5 高斯白噪声等级 $\sigma = 25$ 的测试原图

Table 1 The PSNR results obtained by different algorithms when the noise level is 25.

表 1 噪声等级为 25 时, 不同算法得到的 PSNR 结果

Methods	House	Pepper	Ship	Man	Landscape	Airplane	Average
NLM ^[5]	30.532	28.380	27.921	27.996	30.661	35.476	30.161
BM3D ^[6]	32.860	30.162	29.910	29.623	32.542	36.932	32.004
WNNM ^[8]	33.230	30.400	30.030	29.770	32.710	37.260	32.233
DnCNN ^[12]	32.930	30.660	30.150	30.030	33.110	38.270	32.525
FFDNet ^[23]	33.060	30.720	30.210	30.040	33.130	38.320	32.580
Ours	33.083	30.799	30.222	30.049	33.198	38.389	32.623

Table 2 The SSIM results obtained by different algorithms when the noise level is 25.
表 2 噪声等级为 25 时, 不同算法得到的 SSIM 结果

Methods	House	Pepper	Ship	Man	Landscape	Airplane	Average
NLM ^[5]	0.820	0.820	0.730	0.740	0.820	0.900	0.805
BM3D ^[6]	0.860	0.870	0.800	0.810	0.890	0.950	0.863
WNNM ^[8]	0.861	0.870	0.802	0.810	0.890	0.960	0.866
DnCNN ^[12]	0.961	0.973	0.951	0.940	0.960	0.920	0.951
FFDNet ^[23]	0.862	0.879	0.812	0.8220	0.896	0.969	0.873
Ours	0.962	0.976	0.954	0.942	0.963	0.940	0.956

Table 3 The processing times of different algorithms when the noise level is 25.
表 3 噪声等级为 25 时, 不同算法的处理时间 (单位: 秒)

Methods	256*256		256*256	512*512		512*512	418*321		418*321	Overall
	House	Pepper	Mean	Ship	Man	Mean	Landscape	Airplane	Mean	Mean
NLM ^[5]	0.051	0.034	0.043	0.166	0.157	0.162	0.080	0.094	0.087	0.097
BM3D ^[6]	1	0.8	0.9	3.6	3.6	3.6	2.2	2.3	2.250	2.25
WNNM ^[8]	134.925	131.224	133.075	552.875	596.001	574.438	361.181	323.310	342.246	349.920
DnCNN ^[12]	0.176	0.173	0.175	0.678	0.668	0.673	0.417	0.405	0.411	0.419
FFDNet ^[23]	0.480	0.336	0.408	1.107	0.904	1.006	0.527	0.499	0.513	0.642
Ours	0.099	0.087	0.093	0.398	0.381	0.389	0.238	0.218	0.228	0.237




Fig.6 Performance comparison on House image when the noise level is 25
图 6 噪声等级为 25 时, 不同算法处理 House 图的结果



Fig.7 Performance comparison on Man image when the noise level is 25
图 7 噪声等级为 25 时, 不同算法处理 Man 图的结果

图 6 和图 7 分别为 House、Man 的网络输出图像去噪效果对比图, 图中绿线框表示的是选取的局部放大区域, 红色线框则对应为绿线框内的放大内容。从图中可以看出, NLM 和 BM3D 去噪算法对图像边缘细节的处理较差, 本文算法在去噪效果和边缘细节处理能力上均为表现优异。

当高斯白噪声等级 $\sigma = 50$ 时, 随机选取了 6 幅测试图像, 原图如图 8 所示。表 4 为测试图像经各算法去噪后的 PSNR 值, 可以看出本文算法的 PSNR 均值相较于其他对比算法提高了 0.022dB~

2.532dB。表 5 为 6 幅含噪测试图像经各算法去噪后的 SSIM 值, 其中 6 幅测试图像的 SSIM 值均高于其他对比算法, 均值达到了 0.916, 相较于其他对比算法提高了 0.005~0.279。

图 9 和图 10 分别为 Lena、Room 的网络输出图像去噪效果对比图, 从整体来看, DnCNN、FFDNet 算法的视觉去噪效果与本文算法相当, 但从局部放大的区域来看, 本文算法更能还原原图像的边缘细节以及纹理细节。



Fig.8 Test pictures for $\sigma = 50$.

图 8 测试原图

Table 4 The PSNR results obtained by different algorithms when the noise level is 50.

表 4 噪声等级为 50 时, 不同算法得到的 PSNR 结果

Methods	Starfish	Butterfly	Lena	Room	Desert	Coral	Average
NLM ^[5]	22.843	23.853	26.643	24.048	27.211	24.549	24.858
BM3D ^[6]	24.842	25.662	28.962	21.099	28.483	25.674	25.785
WNNM ^[8]	25.430	26.320	29.250	26.640	28.560	25.920	27.020
DnCNN ^[12]	25.703	26.871	29.435	26.884	28.833	26.211	27.323
FFDNet ^[23]	25.680	26.920	29.439	27.040	28.840	26.290	27.368
Ours	25.706	26.932	29.452	27.094	28.854	26.303	27.390

Table 5 The SSIM results obtained by different algorithms when the noise level is 50.

表 5 噪声等级为 50 时, 不同算法得到的 SSIM 结果

Methods	Starfish	Butterfly	Lena	Room	Desert	Coral	Average
NLM ^[5]	0.630	0.720	0.680	0.570	0.62	0.600	0.637
BM3D ^[6]	0.740	0.820	0.810	0.710	0.73	0.690	0.751
WNNM ^[8]	0.760	0.830	0.810	0.710	0.72	0.690	0.753
DnCNN ^[12]	0.930	0.950	0.920	0.900	0.85	0.910	0.911
FFDNet ^[23]	0.775	0.858	0.821	0.734	0.731	0.727	0.774
Ours	0.932	0.953	0.921	0.920	0.860	0.912	0.916

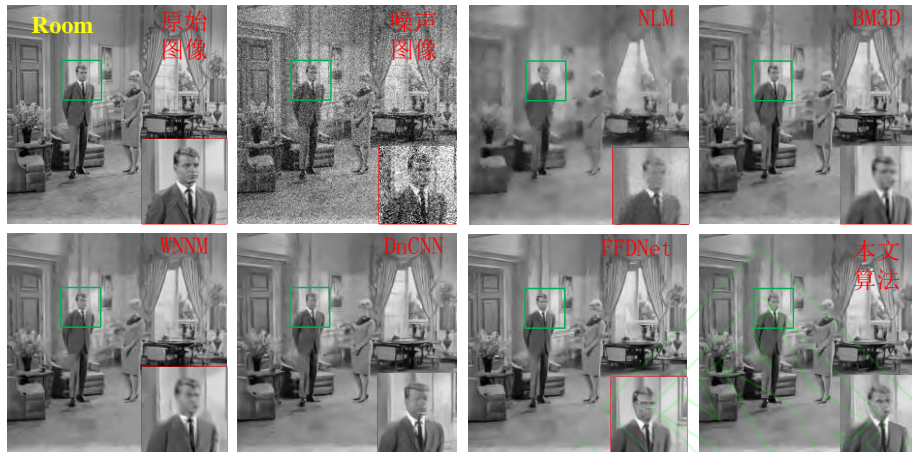


Fig.9 Performance comparison on Room image when the noise level is 50.

图 9 噪声等级为 50 时, 不同算法处理 Room 图的结果




Fig.10 Performance comparison on Lena image when the noise level is 50.

图 10 噪声等级为 50 时, 不同算法处理 Lena 图的结果

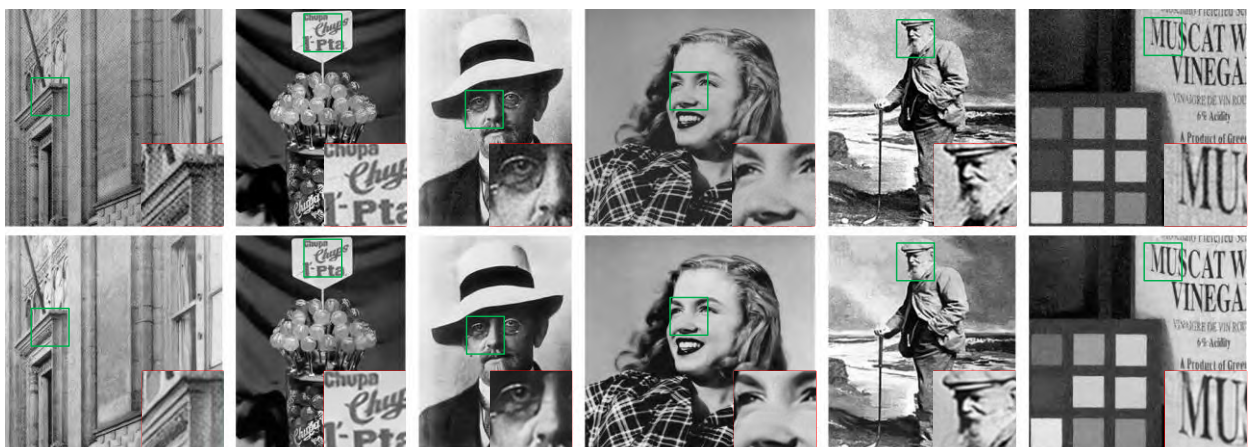


Fig.11 Performance comparison on natural images.

图 11 本文算法处理自然图像的结果



Fig.12 Performance comparison on colorl images.

图 12 本文算法处理彩色图像的结果

为了验证算法的泛化能力,本文进一步对自然噪声图像和彩色噪声图像进行了去噪实验,图 11 上半部分为 6 幅来自数据集 RNI6^[24]带有自然噪声的图像,图 11 下半部分的 6 幅图像为经本文算法处理后的去噪图像。图 12 上半部分为 5 幅来自数据集 Kodak24, 高斯噪声等级为 25 的彩色噪声图像,下半部分的图像为经本文算法处理后的去噪图像。红色框线内对应绿线框内的局部放大信息,可以看出噪声对图像质量影响较为严重。从图像中可以看到,本文算法可以较好地适用于自然噪声图像和彩色噪声图像的去噪,不仅有效去除了噪声,而且很好地保留了图像纹理信息以及边缘细节。

5 总结与展望

本文主要针对现有的深度学习去噪方法存在网络过深、网络参数大导致去噪速度慢的问题,结合密集块和残差学习的优势以及递进融合的策略,提出一种递进式残差融合密集网络,并将其用于高斯噪声的去除。实验结果表明,本文提出的方法获得的去噪效果明显优于传统的 NLM、WNNM、BM3D 等方法。虽然相比于近些年去噪效果表现优异的 DnCNN、FFDNet 算法,本文的方法在评价指标方面没有明显提升,但是本文方法的去噪速度要明显优于 DnCNN 算法和 FFDNet 算法。尽管本文方法能够取得较好的去噪效果,但是该方法仍然存

在一些不足。首先,该方法的主要目标是在保证去噪效果的同时加快去噪速度,与相关算法对比,本方法的去噪速度得到了较大幅度提升,但去噪效果提升幅度不及去噪速度,仍有提升的空间。后期将结合噪声的特性,引入注意力机制对该网络做进一步的改进。其次,该方法虽然能够用于彩色图像噪声的去除,但是由于网络的主要结构是处理单通道图像,因此在处理彩色图像时不可避免地会忽略彩色图像通道间的相关性,因此可能会导致去噪后的结果出现伪影或新的噪声。后期将针对如何同时保留图像的结构特征、细节特征和颜色特征的问题,利用四元数相关理论对该网络做进一步改进,从而获得更好的去噪效果。

参考文献:

- [1] Tian C, Fei L, Zheng W, et al. Deep learning on image denoising: An overview[J]. Neural Networks, 2020.
- [2] Getis A, Griffith D A. Comparative spatial filtering in regression analysis[J]. Geographical analysis, 2002, 34(2): 130-140.
- [3] Armstrong J. Peak-to-average power reduction for OFDM by repeated clipping and frequency domain filtering[J]. Electronics letters, 2002, 38(5): 246-247.
- [4] Candan C, Kutay M A, Ozaktas H M. The discrete fractional Fourier transform[J]. IEEE Transactions on signal processing, 2000, 48(5): 1329-1337.
- [5] Buades A, Coll B, Morel J M. A non-local algorithm for image denoising[C]//2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition

- (CVPR'05), San Diego, June 20-June 26, 2005. Piscataway: IEEE, 2005, 2: 60-65.
- [6] Dabov K, Foi A, Katkovnik V, et al. Image denoising by sparse 3-D transform-domain collaborative filtering[J]. IEEE Transactions on image processing, 2007, 16(8): 2080-2095.
- [7] Knaus C, Zwicker M. Progressive image denoising[J]. IEEE transactions on image processing, 2014, 23(7): 3114-3125.
- [8] Gu S, Zhang L, Zuo W, et al. Weighted nuclear norm minimization with application to image denoising[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, Columbus, June 23-June 28, 2014. Piscataway: IEEE, 2014: 2862-2869.
- [9] Chen Qiang, Zheng Yuhui, Sun Quansen, Xia Deshen. De-noising of Image Similarity and Anisotropic Diffusion Image[J]. Journal of Computer Research and Development, 2010,47(01):33-42.
陈强,郑钰辉,孙权森,夏德深.片相似性各项异性扩散图像去噪[J].计算机研究与发展,2010,47(01):33-42.
- [10] Dou Nuo, Zhao Ruizhen, Cen Yigang, Hu Shaohai, Zhang Yongdong. Superresolution reconstruction of noisy images based on sparse representation[J]. Journal of Computer Research and Development,2015,52(04):943-951.
窦诺,赵瑞珍,岑翼刚,胡绍海,张勇东.基于稀疏表示的含噪图像超分辨率重建方法[J].计算机研究与发展, 2015, 52(04): 943-951.
- [11] Wang Hongyan, Wang Tuo, Pan Mian, Wang Zumin. Image Denoising Algorithm Based on Gamma Norm Minimization[J]. Journal of Communications,2020,41(10):222-230.
王洪雁,王拓,潘勉,汪祖民.基于伽马范数最小化的图像去噪算法[J].通信学报,2020,41(10):222-230.
- [12] Zhang K, Zuo W, Chen Y, et al. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising[J]. IEEE Transactions on Image Processing, 2017, 26(7): 3142-3155.
- [13] Lefkimmiatis S. Universal denoising networks: a novel CNN architecture for image denoising[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, Salt Lake City, June 18-June 22, 2018. Piscataway: IEEE, 2018: 3204-3213.
- [14] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, Las Vegas, June 26-July 1, 2016. Piscataway: IEEE, 2016: 770-778.
- [15] Huang G, Liu S, Van der Maaten L, et al. Condensenet: An efficient densenet using learned group convolutions[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, Salt Lake City, June 18-June 22, 2018. Piscataway: IEEE, 2018: 2752-2761.
- [16] Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition, Honolulu, July 21-July 26, 2017. Piscataway: IEEE, 2017: 4700-4708.
- [17] Guo Hengyi, Jia Zhentang. Image denoising method based on convolutional neural network combined with residual-dense block [J]. Computer Engineering and Design, 2020,41(07):1998-2003.
郭恒意,贾振堂.结合残差密集块的卷积神经网络图像去噪方法[J].计算机工程与设计,2020,41(07):1998-2003.
- [18] Zhang Y, Tian Y, Kong Y, et al. Residual dense network for image restoration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020.
- [19] Tong Yubing, Zhang Qishan, Qi Yunping. Image quality evaluation model based on PSNR and SSIM [J].Journal of Image and Graphics,2006(12):1758-1763.
佟雨兵,张其善,祁云平.基于 PSNR 与 SSIM 联合的图像质量评价模型[J].中国图象图形学报, 2006(12): 1758-1763.
- [20] Hahn J, Hausman J, Kuersteiner G. Estimation with weak instruments: Accuracy of higher - order bias and MSE approximations[J]. The Econometrics Journal, 2004, 7(1): 272-306.
- [21] ZHANG K, ZUO W, ZHANG L. FFDNet: Toward a fast and flexible solution for CNN based image denoising[J]. IEEE Transactions on Image Processing, 2017, 27(9): 4608-4622.
- [22] Cheng Y, Liu Z. Image denoising algorithm based on structure and texture part[C]//2016 12th International Conference on Computational Intelligence and Security (CIS), Wuxi, December 16-December 19, 2016. Piscataway: IEEE, 2016: 147-151.
- [23] Zhang K, Zuo W, Zhang L. FFDNet: Toward a fast and flexible solution for CNN-based image denoising[J]. IEEE Transactions on Image Processing, 2018, 27(9): 4608-4622.
- [24] Gnanadurai D, Sadasivam V. An efficient adaptive thresholding technique for wavelet based image denoising[J]. International Journal of Signal Processing, 2006, 2(2): 114-119.



曹义亲 (1964-), 男, 江西九江, 硕士, 教授, CCF 会员。主要研究方向为图像处理, 模式识别。

CAO Yiqin(1964-), male, Jiangxi jiujiang, M.S., Professor, Member of China Computer Federation. His main research interests include image processing, pattern recognition.



饶哲初 (1997-), 男, 江西丰城, 硕士研究生。主要研究方向为图像处理。

RAO Zhechu (1997-), male, master student, Jiangxi fengcheng. His main research interest is image processing.



朱志亮 (1988-), 男, 湖北天门, 博士, 讲师, CCF 会员。主要研究方向为图像信息处理、虚拟现实与人机交互。

ZHU Zhilian(1988-), male, Hubei tianmen, Ph.D., Lecture. Member of China Computer Federation. His main research interests include image information processing, virtual reality and human-computer interaction.



张红斌 (1979-), 男, 江苏如皋, 博士, 副教授, CCF 会员。主要研究方向为计算机视觉, 自然语言处理, 推荐系统。

ZHANG Hongbi (1979-), male, Jiangsu rugao, Ph.D., Associate Professor. Member of China Computer Federation. His main research interests include Computer vision, natural language processing, recommendation systems.