

## 多分辨率上下文聚合网络的单幅图像去雨方法

谢强强<sup>1,2)</sup>, 张海<sup>1,2)</sup>, 盖杉<sup>1,2)\*</sup>

<sup>1)</sup>(南昌航空大学信息工程学院 南昌 330063)

<sup>2)</sup>(江西省图像处理与模式识别重点实验室 南昌 330063)

(gaishan@nchu.edu.cn)

**摘要:** 雨天等恶劣天气将造成图像质量的严重退化, 进而影响计算机视觉算法的准确性. 为了更好地提取多尺度雨痕特征, 恢复图像含有的重要细节信息, 提出一种基于多分辨率上下文聚合网络的单幅图像去雨方法. 首先利用混洗操作将单一分辨率输入图像转化为多空间分辨率的输入图像, 在低空间分辨率中使网络迅速扩大接受场, 而在高空间分辨率下提取更加精细的雨痕特征, 并将低分辨率提取的雨痕特征自上而下地聚合到高空间分辨率中, 引导网络提取多尺度雨痕信息; 然后采用多分辨率特征增强块细化不同分辨率下图像的细节, 防止去雨图像中的细节损失或模糊, 利用局部残差密集连接和挤压-激励网络增强网络的特征提取能力和效率; 最后采用构造的混合损失函数, 在获取较高评价指标数值的同时提高人类对去雨图像的视觉感知. 实验结果表明, 所提方法在 Rain100H, Rain100L, Rain12 合成数据集和真实雨数据集上取得显著的去雨效果, 与现有方法比较, 该方法的定性指标和定量指标得到明显提升, 具有较高的细节保持度.

**关键词:** 单幅图像去雨; 混洗操作; 多空间分辨率; 残差网络

中图法分类号: TP391.41

DOI: 10.3724/SP.J.1089.2022.18887

## Multi-Resolution Context Aggregation Network for Single Image Rain Removal

Xie Qiangqiang<sup>1,2)</sup>, Zhang Hai<sup>1,2)</sup>, and Gai Shan<sup>1,2)\*</sup>

<sup>1)</sup>(School of Information Engineering, Nanchang Hangkong University, Nanchang 330063)

<sup>2)</sup>(Key Laboratory of Jiangxi Province for Image Processing and Pattern Recognition, Nanchang 330063)

**Abstract:** Severe weather such as rain will cause serious degradation of image quality and affect the accuracy of computer vision algorithms. In order to better extract the features of multi-scale rain streaks and restore the important detailed feature information of the image, a new single image rain removal based on multi-resolution context aggregation network is proposed. Firstly, the shuffling operation is used to convert a single resolution input image into a multi-spatial resolution input, which enables the network to rapidly expand the acceptance field at the low spatial resolution and extract more refined rain streak features at high spatial resolution. The low-resolution rain streak features are aggregated from top to bottom into high spatial resolution, and the network is guided to extract multi-scale rain streak information. Secondly, the multi-resolution feature enhancement block is used to refine the details of the image at different resolutions to prevent the loss or blurring of the details in the rain-removed image. This method uses local residual densely connect blocks and squeeze-excitation network to enhance the ability and efficiency of the network to extract features. Finally, the mixed loss function constructed in this paper is used to obtain higher evalua-

收稿日期: 2021-01-14; 修回日期: 2021-04-13. 基金项目: 国家自然科学基金(62061032); 江西省杰出青年基金(20192ACB21032).  
谢强强(1997—), 男, 硕士研究生, CCF 学生会员, 主要研究方向为计算机视觉、图像处理; 张海(1996—), 男, 硕士研究生, CCF 学生会员, 主要研究方向为深度学习、图像处理; 盖杉(1980—), 男, 博士, 教授, 硕士生导师, CCF 会员, 论文通信作者, 主要研究方向为机器学习、图像处理.

tion index values while improving the human visual perception of rain removal images. The experimental results show that proposed method achieves significant rain removal effects on the Rain100H, Rain100L, and Rain12 synthetic datasets and real rain datasets. Compared with the existing algorithms, the proposed method can achieve significant improvement in qualitative and quantitative indicators and has a high degree of detail retention.

**Key words:** single image rain removal; shuffling operation; multi-spatial resolution; residual network

雨天是一种常见的恶劣天气状况, 不仅影响人类的视觉效果和感知, 而且会对智能化科技在人类社会的应用产生影响, 如视频监控<sup>[1]</sup>和特征提取<sup>[2]</sup>等. 雨痕的堆叠严重影响机器和人工智能对物体的判断和识别, 会导致机器和人工智能做出一系列错误的操作, 降低计算机视觉系统的精度. 在计算机视觉的室外任务中, 去除雨痕是一个重要且具有挑战性的研究课题. 然而, 由于雨痕层和背景层的复杂组合, 图像去雨仍然是一个不定问题.

大多数去雨方法假设有雨图像是雨痕层和背景层的线性组合, 数学表达式为  $O = B + S$ . 其中,  $B$  为干净背景层;  $S$  为雨痕层;  $O$  为合成有雨图像. 图像去雨方法的目的是将背景层从有雨的图像中分离出来, 本文利用全局残差网络, 将输入图像  $O$  与提取出的雨痕  $S$  相减, 得到干净的背景图像  $B$ .

近年来, 如何设计更为有效的图像去雨方法成为众多学者的研究重心. 这些方法可以分为 2 类: 传统的基于图像先验的方法和基于卷积神经网络的方法. 基于图像先验的方法通过稀疏编码方法<sup>[3-4]</sup>、高斯混合模型方法<sup>[5-6]</sup>和基于低秩表示方法<sup>[7-8]</sup>将雨痕层和背景层分离出来. Deng 等<sup>[3]</sup>考虑雨条纹内在的方向和结构信息, 建立了包含稀疏项的全局稀疏模型用于图像去雨. Luo 等<sup>[4]</sup>利用具有强互斥性的字典学习, 通过判别稀疏编码将背景层从非线性复合有雨图像中准确分离. Li 等<sup>[5]</sup>利用基于补丁的高斯混合模型处理雨痕层和背景层, 通过高斯混合模型捕获雨痕的分布, 从而将它们与背景层区分开. Chang 等<sup>[8]</sup>利用图像层中局域和非局域稀疏性适应混合雨痕的分布, 通过仿射将有雨图像转换为雨痕具有垂直外观的空间, 然后利用低秩特性去除雨条纹.

虽然上述传统的基于图像先验的方法取得了显著效果, 但是仍然无法将雨痕从雨图中完全分离出来. 现实生活中雨痕的分布具有多样性和不适应性, 无法满足高斯分布, 并且字典学习也无法完全拟合所有雨痕特性. 因此, 传统方法不能有效地提取并去除全部雨痕, 或者将背景层的特征信息当成

雨痕去除, 导致图像细节损失和对比度失衡. 此外, 传统方法需要手动调整模型的参数以及复杂的优化算法, 这极大地增加了研究人员的工作量.

卷积神经网络在低水平的计算机视觉任务中取得显著的效果, 如图像超分辨率<sup>[9]</sup>和图像去噪<sup>[10]</sup>等. 因此, 越来越多的研究者利用神经网络进行图像去雨, 并获得了比传统方法更好的性能. Fu 等<sup>[11]</sup>首先将深度学习引入单幅图像去雨中, 通过低通滤波器将雨图像分解为低频基础层和高频细节层, 然后利用卷积层和全局残差结构从高频细节层中提取出雨条纹. Yang 等<sup>[12]</sup>提出多任务深度学习架构, 用于学习雨条纹的二值图、雨线图和背景图. 此外, 为了处理雨条纹的堆叠和不同特征的雨痕, 构建循环雨痕检测和上下文扩张网络, 能够自动检测雨痕区域, 逐步去除雨痕. Wang 等<sup>[13]</sup>提出空间注意力网络, 结合时间先验和人工检测, 利用水平和垂直方向的邻域信息模拟雨带的物理性质, 然后通过非局部的上下文信息去除雨痕. Zhang 等<sup>[14]</sup>利用多尺度卷积和局部残差构建残差感知雨痕密度分类器, 自动确定雨痕密度标签, 并根据估计的雨痕标签引导多流密集连接网络有效地去除相应的雨条纹. 基于卷积神经网络的方法比传统的方法更加有效, 提高了从单幅图像中去除雨条纹的性能, 但是仍然存在很大的改进空间. 雨痕在图像中具有不同的尺度和方向, 无法提取多尺度雨痕特征, 导致背景层上存在少量的雨条纹. 利用池化操作提取多尺度信息, 容易造成雨痕和细节信息丢失.

为了解决上述去雨方法中存在的问题, 并且保持去雨效果和计算机资源消耗之间的动态平衡, 本文提出一种端到端的多分辨率上下文聚合网络 (multi-resolution contextual aggregation network, MR-CAN) 的单幅图像去雨方法. MR-CAN 利用多分辨率输入图像提取不同尺度的雨痕特征. 本文的主要工作如下.

(1) 设计一种多分辨率上下文聚合网络, 通过混洗操作将单一分辨率的输入图像转化为多分辨率输入图像, 利用注意力机制筛选出低分辨率提取

的雨痕特征, 并将上下文信息自上而下地融合到高分辨率分支中.

(2) 采用局部残差密集连接块和局部残差, 提高参数的利用率和信息的流动性. 同时, 采用多分辨率特征增强块提高不同分辨率图像的细节, 达到去除雨痕且保持细节纹理的目的.

(3) 引入混合损失函数, 采用结构相似损失函数  $L_{SSIM}$ , 提升图像的亮度和对比度,  $L_1$  范数和  $L_2$  范数损失函数最小化去雨图像和无雨图像像素空间的差值.

## 1 相关工作

### 1.1 混洗操作

卷积神经网络使用线性插值方法进行上采样, 但是容易造成不适定问题并且增加计算复杂度. Shi 等<sup>[15]</sup>提出混洗操作将低分辨率特征每个像素的通道数转化为高分辨率图像的特征尺寸, 整合提取的特征信息用于增强输入图像分辨率. Gu 等<sup>[16]</sup>通过自顶向下的自引导策略进行图像去噪, 利用反混洗操作代替池化操作输入不同分辨率的特征信息, 以减少特征损失并提高网络运行效率. 受此启发, 本文提出了 MR-CAN 并将其应用于单幅图像去雨任务, 取得了显著的效果.

### 1.2 注意力机制

随着深度学习技术的快速发展, 提出了许多先进的图像去雨方法<sup>[17-20]</sup>. 不同的特征信息对生成的去雨图像贡献不同, 而且某些提取的特征对网络的作用相对较弱, 因此减少这些信息在传输过程中的比例, 可以提高去雨的准确率和训练效率. 在网络中通过可对提取的特征赋予权重, 使网络具有人类视觉系统注意重要信息的功能. Hu 等<sup>[19]</sup>提出挤压-激励(squeeze and excitation, SE)网络融合空

间和通道信息, 将所有特征通道赋予权重, 使网络具有忽略无关信息和关注关键信息的能力. 此外, 由于不同的雨痕具有不同的特征信息, 使用批量归一化<sup>[20]</sup>会降低去雨效果. 本文的分离实验证明, 取消批量归一化可以获得更好的性能.

## 2 本文方法

下面详细介绍 MR-CAN 的整体结构以及定义的混合损失函数和模型算法.

### 2.1 MR-CAN 整体框架

本文提出的基于 MR-CAN 单幅图像的去雨方法采用自上而下的特征提取、传递与融合结构, 更好地利用图像的多尺度特征, 提取不同尺度的雨痕信息. 卷积神经网络在低的空间分辨率中可以使网络迅速扩大接受场, 而在高的空间分辨率下能够提取更加精细的雨痕特征. 因此, 本文将包含大规模信息的低分辨率分支提取的特征传入高分辨率分支中, 用于引导雨痕特征提取. 使用反混洗操作对输入进行降维, 将单一分辨率输入转化为多空间分辨率输入. 在每层中使用 SE 网络, 用于筛选提取的大规模雨痕信息, 在去雨性能和计算机资源消耗之间寻求更好的平衡. 在全分辨率子网络中, 采用全局残差结构和多分辨率特征增强块. 全局残差引导网络只提取雨痕特征, 保护背景特征完整性; 多分辨率特征增强块用于提高去雨图像在不同分辨率下的细节信息. 此外, 本文在不同分辨率分支中添加一个或多个局部残差密集连接块, 用于增强模型提取特征的能力和流动性; 设计基于结构相似损失函数、像素空间损失函数和均方误差损失函数的混合损失函数, 利用随机梯度下降优化方法提高网络去雨效果. MR-CAN 的结构如图 1 所示.




图 1 MR-CAN 整体框架

## 2.2 上下文聚合子网络

输入图像在不同尺度上具有更加丰富的细节和纹理, 跨尺度网络利用不同尺寸的区域提取不同大小的特征信息. 卷积神经网络通常的策略是采用池化操作扩大接收域, 降低输入图像的特征尺寸, 但池化操作容易导致信息丢失. 相比池化操作, 反混洗操作在降低特征尺寸的同时能够增加特征通道的数量, 将减少的特征信息用于拓展通道数量及避免信息损失. 因此, 本文采用如图2所示的




图2 池化操作和混洗操作对比

MR-CAN 上层子网络在非常低的空间分辨率下工作, 提取大规模信息. 上层子网络包含2个卷积层、局部残差密集连接块和SE网络. 首先使用 $1\times 1$ 卷积层增加输入特征的通道数, 然后传入局部残差密集连接块中进行特征提取. 局部残差密集连接块如图3所示, 由3个 $3\times 3$ 卷积和参数校正线性单元(parametric rectified linear unit, PReLU)激活函数组成, 利用密集连接和局部残差连接, 每层与其余层均为全互连接的模式. 在局部残差密集连接块输出和当前层输入之间建立残差连接, 防止低空间分辨率下提取的大规模信息损失. SE网络如图4所示, 使用全局池化层将特征尺寸转化为 $1\times 1\times C$ ,  $C$ 为当前层特征的通道数, 然后传入2层全连接层和Sigmoid函数中得到每个通道特征映射的权重, 最后与输入特征相乘形成通道注意力




图3 局部残差密集连接块




图4 挤压和激励注意力块

反混洗操作对输入图像降维. 假设输入图像 $O$ 的尺寸为 $M\times N\times C$ , 通过池化操作将输入图像尺寸降为 $\frac{M}{k}\times\frac{N}{k}\times C$ , 反混洗操作为 $\frac{M}{k}\times\frac{N}{k}\times C\times k^2$ . 其中,  $M$ 和 $N$ 分别为特征的长度和宽度,  $C$ 为特征通道数,  $k$ 为下采样倍数. 本文将输入的3通道RGB图像通过反混洗操作下采样8倍、4倍和2倍, 将不同分辨率提取的雨痕自上而下地传入全分辨率子网络.

机制. 中间层子网络 and 上层子网络的结构相似, 唯一不同之处在于高空间分辨率使用 $3\times 3$ 的卷积核融合低空间分辨率提取的特征信息. 使用混洗操作使低分辨率提取的特征尺寸与高分辨率特征尺寸保持一致, 利用简单的连接操作融合特征信息.

## 2.3 全分辨率子网络

在全分辨率子网络中, 本文增加了6个具有跳跃连接的局部残差密集连接块, 在局部残差密集连接块之间建立密集连接, 增强模型提取和分析上下文聚合子网络融合的特征信息. 不同分辨率的特征图提供不同的感受野, 有助于在不同尺度上重建图像, 保护不同分辨率图像细节. 本文通过多分辨率特征增强模块确保来自不同分辨率的特征细节被嵌入到最终结果中. 多分辨率特征增强模块包含一个 $3\times 3$ 的前端卷积, 将前端卷积的输出通过反混洗操作下采样8倍、4倍、2倍和0倍, 与上下文聚合结构下采样倍数相同. 使用局部残差密集连接块提取特征信息, 然后将特征图利用混洗操作上采样到原始图像的大小, 并将它们与前端卷积层输出融合, 具体过程如图5所示. 最后使用 $3\times 3$ 卷积层恢复输出图像的通道数和全局残差结构输出去雨图像.

## 2.4 损失函数

由于雨痕层和背景层混合在一起, 使用单一损失函数无法取得预期的性能.  $L_1$ 范数和 $L_2$ 范数损失函数被广泛应用于去雨方法训练网络模型, 使去雨图像和干净无雨图像之间误差最小. 虽然 $L_1$ 范数和 $L_2$ 范数损失函数处理去雨图像和无雨图




图 5 多分辨率特征增强块

像像素之间的差异,可以获得很好的峰值信噪比(peak signal to noise ratio, PSNR)<sup>[21]</sup>,但获取的去雨图像与人类视觉感知相关性很差.因此,在获取高 PSNR 数值的同时,本文引入  $L_{SSIM}$  结构相似度损失函数,以保证良好的视觉效果.假设本文的训练集有  $N$  个训练样本  $(B_i, R_i)$ ,  $i=1, 2, 3, \dots, N$ ,  $R_i$  是有雨图像,  $B_i$  是对应的  $R_i$  无雨图像.  $L_1$  和  $L_2$  范数损失函数公式分别为

$$L_1 = \frac{1}{N} \sum_{i=1}^N |B_i - f(R_i)| \quad (1)$$

$$L_2 = \frac{1}{N} \sum_{i=1}^N (B_i - f(R_i))^2 \quad (2)$$

其中,  $f(R_i)$  为本文去雨的预测结果.使用结构相似度(structural similarity, SSIM)<sup>[22]</sup>计算有雨和无雨图像之间的误差,结构相似度损失函数公式为

$$L_{SSIM} = 1 - SSIM(B, f(R)) \quad (3)$$

本文提出的混合损失函数定义为

$$L_{total} = \lambda_1 L_1 + \lambda_2 L_2 + \lambda_3 L_{SSIM} \quad (4)$$

其中,超参数  $\lambda_1, \lambda_2, \lambda_3$  表示  $L_1, L_2, L_{SSIM}$  在混合损失函数中所占的比例,通过混合损失函数可以有效地去除雨条纹,获得清晰纹理结构的去雨图像.

## 2.5 网络算法

本文首先利用上下文聚合子网络将单一分辨率输入转化为多空间分辨率输入,将提取的雨痕信息自上而下地传入高空间分辨率用于获取多尺度雨痕信息,使用 SE 网络筛选提取的雨痕信息提高去雨效率和准确率.其次,在全分辨率子网络中使用多分辨率特征增强块保护图像的细节和纹理.最后,利用混合损失函数获取较高的评价指标和视觉效果.

本文 MR-CAN 算法步骤如下.

输入. 有雨图像和无雨图像成对样本.

输出. MR-CAN 生成的去雨图像.

初始化. 网络训练迭代次数  $L$ , 每批数据量的

大小为  $m$ , 混合损失函数中  $L_1$  范数、 $L_2$  范数和  $L_{SSIM}$  损失函数所占权重为  $\lambda_1, \lambda_2, \lambda_3$ .

Step1. 输入  $m$  个小批量有雨图像  $\{x^{(1)}, x^{(2)}, \dots, x^{(m)}\}$  和无雨图像  $\{y^{(1)}, y^{(2)}, \dots, y^{(m)}\}$ , 其中  $x^{(i)}$  对应  $y^{(i)}$ .

Step2. MR-CAN 输出预测无雨图像  $\{y_1^{(1)}, y_2^{(2)}, \dots, y_m^{(m)}\}$ .

Step3. 基于式(4)使用混合损失函数计算去雨图像  $y_i^{(i)}$  和无雨背景层  $y^{(i)}$  之前的误差.

Step4. 通过反向传播计算梯度,使用 Adam 随机梯度下降算法更新网络参数,即  $\theta_L = \text{Adam}(\nabla \theta_L(L_{total}), \theta_L)$ .

## 3 实验结果与分析

将本文提出的 MR-CAN 方法在合成数据集 Rain100H<sup>[12]</sup>, Rain100L<sup>[12]</sup>, Rain12<sup>[23]</sup>和真实数据集上与现有的去雨方法进行比较,以证明其有效性.

### 3.1 实验配置

#### 3.1.1 数据集

由于现实世界中无法获取干净无雨图像和有雨图像的成对样本,因此所有的去雨方法都是在合成雨数据集上进行训练.本文选取 3 种不同类型的合成数据集,用于测试网络对不同雨痕的拟合效果. Rain100H 数据集集中的雨痕密度较大,由 1 800 幅训练样本图像和 100 幅测试样本图像组成. Rain100L 数据集集中的雨痕分布比较均匀,包含 200 幅训练样本图像和 100 幅测试样本图像. Rain12 数据集集中的雨痕分布和真实世界雨痕类似,包含 12 幅有雨图像.此外,本文引入了 Yang 等<sup>[12]</sup>提供的真实世界雨图像数据集,用于验证本文方法对真实世界图像的鲁棒性.

#### 3.1.2 评价指标

在图像去雨中广泛使用 PSNR 和 SSIM 作为评价指标,用于测量合成数据集上去雨图像和无雨图像像素之间的差异. PSNR 和 SSIM 作为客观评价指标,数值越大,表示去雨效果越好,去雨图像和无雨图像越接近.此外,本文引入自然图像质量



评价器(natural image quality evaluator, NIQE)<sup>[24]</sup>客观地评价真实去雨图像的效果, 数值越低, 表示图像质量越好. 另外, 本文还从主观视觉效果角度评价去雨性能.

### 3.1.3 实验环境配置

本文方法所有的实验均在基于 Python 脚本语言的 PyTorch 框架进行, 并在配置为 Ubuntu16.04 版本的 Linux 系统, 拥有 Intel(R)核心(TM) i7-8700H CPU, 128 GB RAM, NVIDIA GTX TitanV, 12 GB VRAM 的服务器上训练. 在训练过程

中, 将输入图像裁剪成尺寸为  $120 \times 120$  的训练图像补丁, 每次训练样本数为 12, 采用 PReLU 激活函数进行非线性运算. 本文的实验迭代轮数设置为 150 次, 初始学习率为  $1 \times 10^{-3}$ , 每达到 40, 80, 120 迭代轮数, 学习率乘以 0.2 进行衰减. 由于  $L_1$  和  $L_2$  损失函数最小化像素之间的差异,  $L_{SSIM}$  损失函数能够获得很好的视觉效果. 为了平衡每个损失函数在训练过程中发挥的作用, 本文将超参数设置为  $\lambda_1 = \lambda_2 = \lambda_3 = 1$ . 具体的网络模型参数设置、输入和输出尺寸如表 1 所示.

表 1 MR-CAN 参数设置、输入和输出尺寸

阶段	类型	参数	输入尺寸	输出尺寸
上层	反混洗操作	/8	3×120×120	192×15×15
	卷积层	1×1Conv, Stride 1, Padding 0	192×15×15	
	局部残差密集连接层	(3×3Conv, Stride 1, Padding 1)×3	256×15×15	256×15×15
	卷积层	3×3Conv, Stride 1, Padding 1	448×15×15	
	注意力层	AdaptiveAvgPool( ) FC1(256/16), FC2(256)	256×15×15	
中层	反混洗操作	/4	3×120×120	48×30×30
	卷积层	1×1Conv, Stride 1, Padding 0	48×30×30	
	卷积层	3×3Conv, Stride 1, Padding 1	192×30×30	
	局部残差密集连接层	(3×3Conv, Stride 1, Padding 1)×3	128×30×30	128×30×30
	卷积层	3×3Conv, Stride 1, Padding 1	176×30×30	
	注意力层	AdaptiveAvgPool() FC1(128/16), FC2(128)	128×30×30	
下层	反混洗操作	/2	3×120×120	12×60×60
	卷积层	1×1Conv, Stride 1, Padding 0	12×60×60	
	卷积层	3×3Conv, Stride 1, Padding 1	96×60×60	
	局部残差密集连接层	(3×3Conv, Stride 1, Padding 1)×3	64×60×60	64×60×60
	卷积层	3×3Conv, Stride 1, Padding 1	76×60×60	
	注意力层	AdaptiveAvgPool() FC1(64/16), FC2(64)	64×60×60	
全分辨率子网络	卷积层	1×1Conv, Stride 1, Padding 0	3×120×120	
		3×3Conv, Stride 1, Padding 1	48×120×120	
	局部残差密集连接层 ×6	(3×3Conv, Stride 1, Padding 1)×3		32×120×120
		(3×3Conv, Stride 1, Padding 1)×3		
		(3×3Conv, Stride 1, Padding 1)×3	32×120×120	
		(3×3Conv, Stride 1, Padding 1)×3		
		(3×3Conv, Stride 1, Padding 1)×3		
		(3×3Conv, Stride 1, Padding 1)×3		
	卷积层	3×3Conv, Stride 1, Padding 1	32×120×120	3×120×120
	局部残差密集连接层 ×4	(3×3Conv, Stride 1, Padding 1)×3	192×15×15	192×15×15
		(3×3Conv, Stride 1, Padding 1)×3	48×30×30	48×30×30
(3×3Conv, Stride 1, Padding 1)×3		12×60×60	12×60×60	
(3×3Conv, Stride 1, Padding 1)×3		3×120×120	3×120×120	
输出	卷积层	3×3Conv, Stride 1, Padding 1	15×120×120	3×120×120

### 3.2 合成数据集和真实数据集的评价

将本文的 MR-CAN 方法与现有经典的去雨方法(CNN<sup>[11]</sup>, DDN<sup>[25]</sup>, JORDER<sup>[12]</sup>, LPNet<sup>[26]</sup>, DRN<sup>[27]</sup>)在合成数据集和真实数据集上进行定量和定性比较. 采用 PSNR, SSIM 和 NIQE 作为定量的评价指标, 通过判断数值的高低更加直观地比较去雨方法的性能. 本文所有的对比实验都是按照原文作者提供的代码和参数进行, 确保对比的客观性和公平性. 表 2 展示了本文和其他去雨方法在 Rain100H, Rain100L, Rain12 合成数据集上评价指标的对比. 从表 2 中可以清楚地看出, 本文方法在

评价指标上优于其他方法. 在 3 个数据集上, MR-CAN 比其他方法在 SSIM 指标上分别高出 0.043~0.567, 0.007~0.165, 0.011~0.065; 在 PSNR 指标上分别高出 1.80~15.62 dB, 0.91~12.45 dB, 0.63~7.88 dB. 本文方法在评价指标上取得了最优的结果, 得益于多空间分辨率输入、增强和混合损失函数最小化去雨图像与无雨图像像素之间的差异. 此外, 本文将 100 幅大小为 512×512 的有雨图像在 GPU 上测试平均运行时间, 从表 2 中可以观察到, 本文方法运行时间最短, 证明了其在单幅图像去雨的高效性和有效性.

表 2 单幅图像去雨在合成数据集上平均 PSNR 和 SSIM 结果

方法	Rain100H		Rain100L		Rain12		时间/s
	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	
CNN <sup>[11]</sup>	0.304	11.44	0.810	23.70	0.901	28.89	2.80
DDN <sup>[25]</sup>	0.781	23.95	0.938	32.04	0.911	34.81	0.19
JORDER <sup>[12]</sup>	0.674	22.15	0.968	35.24	0.950	36.14	0.18
LPNet <sup>[26]</sup>	0.821	24.40	0.961	34.95	0.951	35.05	0.12
DRN <sup>[27]</sup>	0.828	25.26	0.965	34.26	0.955	34.81	0.14
MR-CAN	<b>0.871</b>	<b>27.06</b>	<b>0.975</b>	<b>36.15</b>	<b>0.966</b>	<b>36.77</b>	<b>0.07</b>

注. 粗体表示最优结果.

为了证明 MR-CAN 方法去雨图像的视觉效果和对图像细节的保持性能, 将其和其他方法进行可视化比较, 并将局部细节信息放大, 观察它们能否在去除雨痕的同时, 尽可能地保持图像细节. 本文从 3 个合成数据集中挑选 5 幅去雨图像进行比较, 如图 6~图 10 所示, 本文 MR-CAN 方法不仅能够有效地剔除图像中的雨痕, 而且具有更加清晰的纹理和更少的伪影, 其他去雨方法仍然存留大部分雨痕无法去除, 或者无法清楚地保存背景特征, 使图像变得光滑和模糊. 从图 6 可以看出, 本文 MR-CAN 方法可以有效地保存蘑菇的边缘纹理, 而其他方法处理后蘑菇边缘纹理仍然有雨痕覆盖或纹理过于模糊和光滑. 从图 7 可以看出, 本文 MR-CAN 方法可以将远处的天空和雪山恢复得更加自然, 而其他方法留下许多伪影, 导致提取的背景层与现实世界不一致. 从图 8 可以看出, 本文提出的 MR-CAN 方法能够有效地最大化地保护图像色彩的对比度和饱和度, 而其他方法使图像色彩失真和对比度失调. 从图 9 可以看出, 本文 MR-CAN 方法可以清楚地保存文字特征, 视觉上能更加直观地分辨出每个字符的内容. 从图 10 可以看出, 背景网格颜色及方向与雨痕分布相似, 当背景纹

理复杂度较高, 尤其是背景纹理样式与雨痕类似时, 本文 MR-CAN 方法可以有效地识别雨痕层和背景层, 在最大程度地去除雨痕的同时保留背景细节纹理, 而其他对比方法将雨痕层与网格线条混淆, 导致线条纹理丢失和覆盖. 上述实验可视化结果证明, 本文方法可以有效地去除图像中的雨痕, 同时保护图像的细节纹理和色彩对比度, 而且可以作为其他计算机视觉方法的预处理, 有利于提取有雨图像中的文字和检测物体.

合成数据集雨痕和真实雨痕有很大的差距, 通过更改线条的尺寸和方向, 可以模拟不同特征的雨痕. 为了测试本文 MR-CAN 方法在现实世界的应用价值和模型的鲁棒性, 将在 Rain100H 数据集上训练的模型用于对真实世界雨图像的测试. 从图 11 和图 12 可以看到, 本文 MR-CAN 方法可以有效地提取和去除真实世界的雨线, 保护图像的纹理细节和色彩对比度. 而其他方法仍然存在部分雨痕或过度模糊的背景. 图 13 中雨线成股流下, 部分方法无法准确识别雨痕并进行去除, 而本文 MR-CAN 方法在去除成股雨线时, 保护了背景的清晰度和树叶的结构纹理. 对图 11 和图 12 测量 NIQE 指标验证真实图像去雨恢复的质量, 结

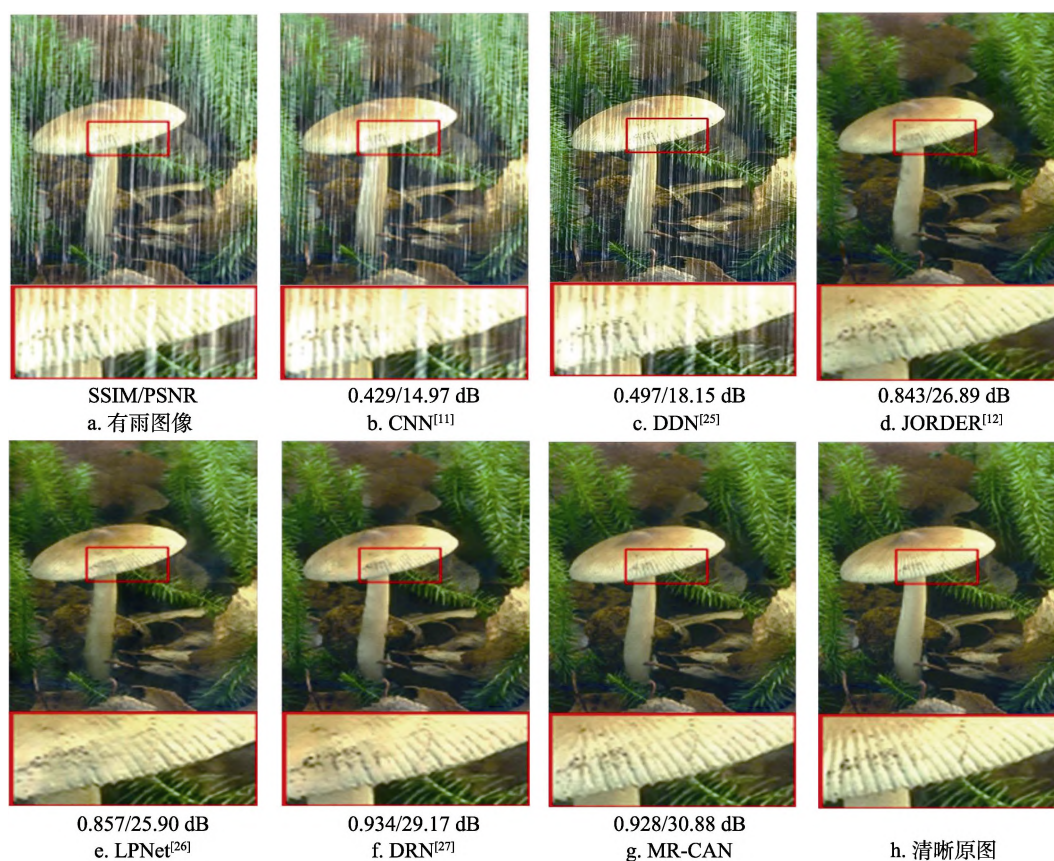


图 6 不同方法在蘑菇边缘纹理上的去雨效果对比

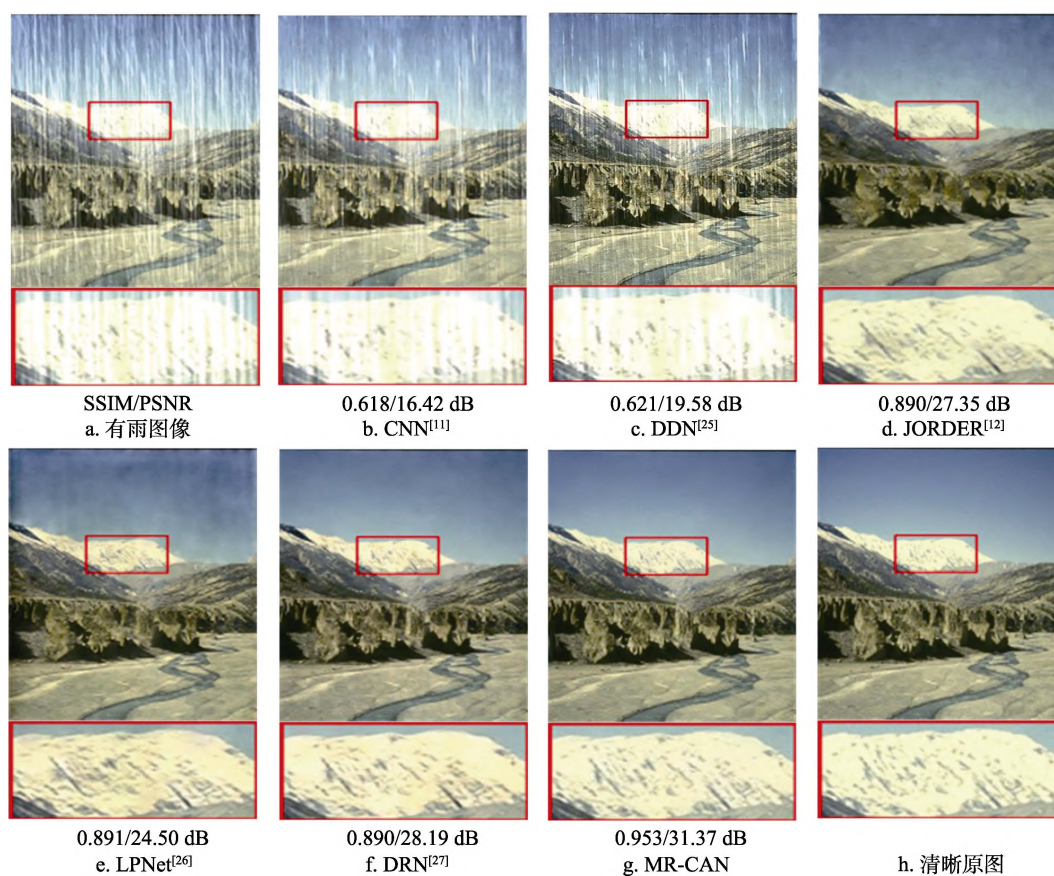


图 7 不同方法在雪山远景上的去雨效果对比



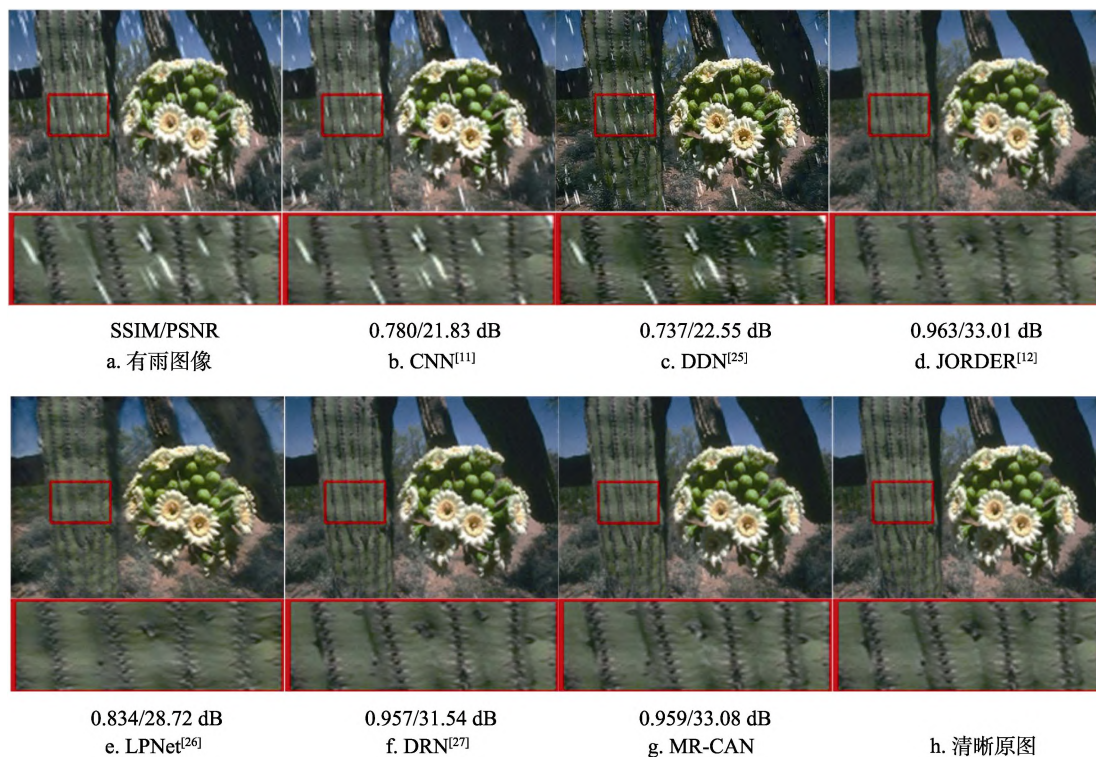


图 8 不同方法在仙人掌色彩上的去雨效果对比

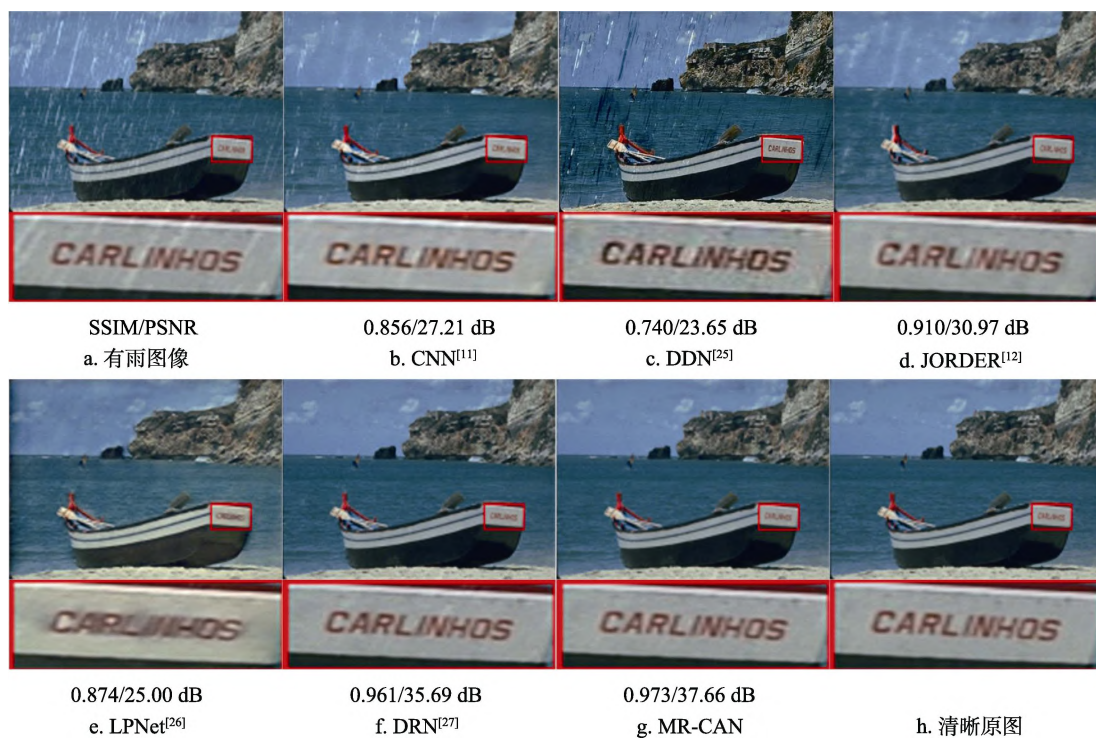


图 9 不同方法在字符细节上的去雨效果对比

果表明, 本文 MR-CAN 方法输出的图像质量最好. 通过上述可视化实验结果和 NIQE 数值对比, 证明了其对真实世界雨痕的拟合性、迁移性和鲁棒性, 以及图像恢复的质量和现实生活中的应用价值.

### 3.3 分离实验分析

本文采用混合损失函数, 在获取较高评价指标的同时, 保持去雨图像的亮度和色彩, 符合人类视觉效果. 在 Rain100L 和 Rain12 合成数据集上测






图 10 不同方法在网格背景上的去雨效果对比

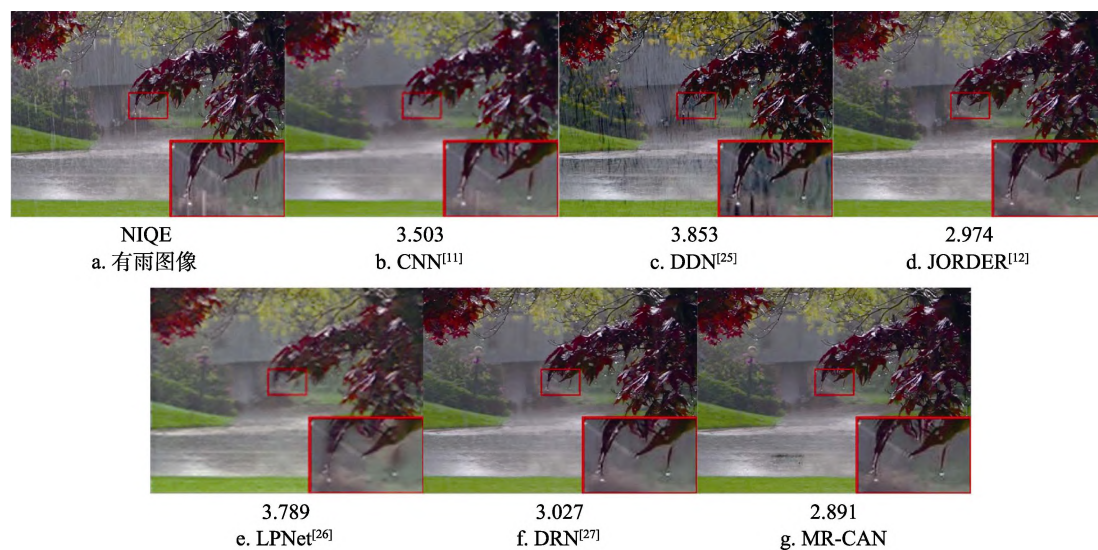


图 11 不同方法在树叶上的去雨效果对比

量 PSNR 和 SSIM, 验证本文使用的混合损失函数的有效性. 如表 3 所示, 由  $L_1$  范数、 $L_2$  范数和  $L_{SSIM}$  损失函数构成的混合损失函数, 相较于单一损失函数和 2 个混合损失函数, 在 2 个数据集上都取得了最高的评价指标, 验证了本文提出的混合损失函数的合理性. 在本文提出的网络架构中, 每个子模块都是网络重要的组成部分. 局部残差模

块增强了信息的流动性, 防止梯度消失或爆炸. SE 网络对提取的雨痕信息赋予权重, 使网络专注于权值较高的雨痕特征, 提高去雨的效率和准确率. 多分辨率特征增强模块用于增强不同分辨率下图像的细节信息. 如表 4 所示, 将不同的子模块进行组合, 在 Rain100L 数据集上测量 PSNR 和 SSIM. 本文的网络结构在对比的网络结构中组合评价指

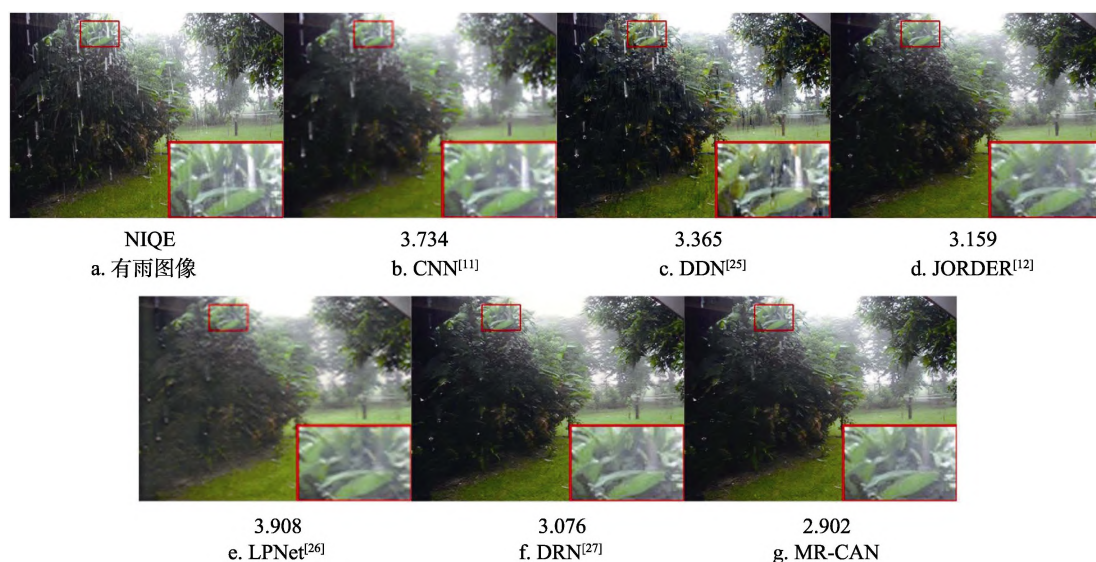


图 12 不同方法在成股雨痕上的去雨效果对比

标数值最高,证明了 MR-CAN 中每个子模块都是不可或缺的一部分. 因为雨痕具有不同的特征信息,因此在 MR-CAN 中放弃使用批量归一化. 如表 5 和图 13 所示,使用批量归一化的评价指标低于 MR-CAN 方法,并且批量归一化导致去雨图像中存在部分雨痕无法去除. 本文使用混洗操作和反混洗操作代替上采样和池化层,防止提取的雨痕信息丢失. 表 6 所示为 2 种方法的分离实验,结果表明,使用混洗操作在图像去雨中更加有效,能够获得较高的评价指标. 本文通过混洗操作自上而下地将不同尺度的特征信息传入主网络,用于获取多尺度雨痕信息. 表 7 表明,MR-CAN 从上到下逐层取消,评价指标也不断下降. 从图 14 中可以观察到,雨痕具有不同的尺度,在取消“上+中+下”层的图像中雨痕残留明显,逐渐增加网络的层数残留的雨痕逐渐减少. 实验结果证明了采用多尺度策略在图像去雨的有效性.

表 3 不同损失函数在 Rain100L 和 Rain12 上 SSIM 和 PSNR 的比较

损失函数	Rain100L		Rain12	
	SSIM	PSNR/dB	SSIM	PSNR/dB
$L_2$	0.959	34.31	0.950	34.82
$L_1$	0.961	34.40	0.953	34.90
$L_1 + L_{SSIM}$	0.965	34.83	0.958	35.22
$L_2 + L_{SSIM}$	0.971	35.25	0.961	35.62
$L_1 + L_2 + L_{SSIM}$	<b>0.975</b>	<b>36.15</b>	<b>0.966</b>	<b>36.77</b>

注. 粗体表示最优结果.

表 4 不同组合在 Rain100L 上的评估

序号	局部残差	SE 注意力	增强块	SSIM	PSNR/dB
1	√	×	×	0.964	34.20
2	×	√	×	0.966	34.45
3	×	×	√	0.963	34.17
4	√	√	×	0.969	35.11
5	√	×	√	0.967	34.75
6	×	√	√	0.973	35.40
7	√	√	√	<b>0.975</b>	<b>36.15</b>

注. 粗体表示最优结果.

表 5 采用/不采用归一化在 Rain100L 上的评估

方法	SSIM	PSNR/dB
使用归一化	0.942	<b>33.14</b>
MR-CAN	0.975	<b>36.15</b>

注. 粗体表示最优结果.

表 6 不同下采样/上采样方法在 Rain100L 上的评估

方法	SSIM	PSNR/dB
池化层/上采样	0.968	35.52
反混洗/混洗	<b>0.975</b>	<b>36.15</b>

注. 粗体表示最优结果.

表 7 采用/不采用多尺度组合在 Rain100L 上的评估

多尺度组合否	SSIM	PSNR/dB
取消“上+中+下”层	0.957	33.91
取消“上+中”层	0.961	34.41
取消上层	0.970	35.57
MR-CAN	<b>0.975</b>	<b>36.15</b>

注. 粗体表示最优结果.






图13 采用/不采用归一化在 Rain100L 上定性比较



图14 采用/不采用多尺度组合在 Rain100L 上定性比较

## 4 结 语

本文提出一种基于 MR-CAN 的单幅图像去雨方法, 利用反混洗操作获取多分辨率特征输入, 将低分辨率提取的雨痕特征自上而下地融合到高分辨率分支中, 用于指导网络提取多尺度雨痕特征信息。首先, 通过局部残差连接、SE 网络和局部残差密集连接块来提高去除雨痕的准确率和速率。其次, 利用多分辨率特征增强模块保护去雨图像在不同分辨率下的细节信息。最后, 采用混合损失函数, 在获取较高评价指标的同时, 保证输出的去雨图像更加符合人类的视觉感知。将本文方法 MR-CAN 与其他方法在 Rain100H, Rain100L, Rain12 和真实雨图像数据集上进行对比。实验结果表明, 本文方法不仅可以有效地去除雨痕层, 还可以很好地保持图像的细节纹理和色彩对比度, 同时在 PSNR 和 SSIM 等评价指标上表现出优势。如何将半监督学习策略引入单幅图像去雨中将是下一步需要思考和改进的方向。

## 参考文献(References):

- [1] Zhang Y Y, Wang L J, Qi J Q, *et al.* Structured Siamese network for real-time visual tracking[C] //Proceedings of the European Conference on Computer Vision. Heidelberg: Springer, 2018: 355-370
- [2] Tanfous A B, Drira H, Amor B B. Sparse coding of shape trajectories for facial expression and action recognition[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(10): 2594-2607
- [3] Deng L J, Huang T Z, Zhao X L, *et al.* A directional global sparse model for single image rain removal[J]. Applied Mathematical Modelling, 2018, 59: 662-679
- [4] Luo Y, Xu Y, Ji H. Removing rain from a single image via discriminative sparse coding[C] //Proceedings of the IEEE International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2015: 3397-3405
- [5] Li Y, Tan R T, Guo X J, *et al.* Rain streak removal using layer priors[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2016: 2736-2744
- [6] Li Y, Tan R T, Guo X J, *et al.* Single image rain streak decomposition using layer priors[J]. IEEE Transactions on Image Processing, 2017, 26(8): 3874-3885
- [7] Chen Y L, Hsu C T. A generalized low-rank appearance model for spatio-temporally correlated rain streaks[C] //Proceedings of the IEEE International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2013: 1968-1975
- [8] Chang Y, Yan L X, Zhong S. Transformed low-rank model for line pattern noise removal[C] //Proceedings of the IEEE International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2017: 1735-1743
- [9] Huang Detian, Huang Weiqin, Yun Haijiao, *et al.* Application of regularization technique and low-rank matrix in super-resolution algorithm via sparse representation[J]. Journal of Computer-Aided Design & Computer Graphics, 2018, 30(5): 868-877(in Chinese)  
(黄德天, 黄炜钦, 云海姣, 等. 正则化技术和低秩矩阵在稀疏表示超分辨率算法中的应用[J]. 计算机辅助设计与图形学学报, 2018, 30(5): 868-877)
- [10] Guo Qiang, Zhang Caiming, Zhang Yunfeng, *et al.* Low-rank image denoising based on minimum variance estimator[J]. Journal of Computer-Aided Design & Computer Graphics, 2015, 27(12): 2237-2246(in Chinese)  
(郭强, 张彩明, 张云峰, 等. 基于最小方差估计的图像低秩去噪[J]. 计算机辅助设计与图形学学报, 2015, 27(12): 2237-2246)
- [11] Fu X Y, Huang J B, Ding X H, *et al.* Clearing the skies: a deep network architecture for single-image rain removal[J]. IEEE Transactions on Image Processing, 2017, 26(6): 2944-2956



- [12] Yang W H, Tan R T, Feng J S, *et al.* Deep joint rain detection and removal from a single image[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2017: 1685-1694
- [13] Wang T Y, Yang X, Xu K, *et al.* Spatial attentive single-image deraining with a high quality real rain dataset[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2019: 12262-12271
- [14] Zhang H, Patel V M. Density-aware single image de-raining using a multi-stream dense network[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2018: 695-704
- [15] Shi W Z, Caballero J, Huszár F, *et al.* Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2016: 1874-1883
- [16] Gu S H, Li Y W, van Gool L, *et al.* Self-guided network for fast image denoising[C] //Proceedings of the International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2019: 2511-2520
- [17] He K M, Zhang X Y, Ren S Q, *et al.* Deep residual learning for image recognition[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2016: 770-778
- [18] Huang G, Liu Z, van der Maaten L, *et al.* Densely connected convolutional networks[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2017: 2261-2269
- [19] Hu J, Shen L, Sun G, *et al.* Squeeze-and-excitation networks[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2018: 7132-7141
- [20] Ioffe S, Szegedy C. Batch normalization: accelerating deep network training by reducing internal covariate shift[C] //Proceedings of the 32nd International Conference on International Conference on Machine Learning. New York: ACM Press, 2015: 448-456
- [21] Wang Z, Bovik A C, Sheikh H R, *et al.* Image quality assessment: from error visibility to structural similarity[J]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612
- [22] Garg K, Nayar S K. Photorealistic rendering of rain streaks[J]. ACM Transactions on Graphics, 2006, 25(3): 996-1002
- [23] Huynh-Thu Q, Ghanbari M. Scope of validity of PSNR in image/video quality assessment[J]. Electronics Letters, 2008, 44(13): 800-801
- [24] Blau Y, Michaeli T. The perception-distortion tradeoff[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2018: 6228-6237
- [25] Fu X U, Huang J B, Zeng D D, *et al.* Removing rain from single images via a deep detail network[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2017: 3855-3863
- [26] Fu X Y, Liang B R, Huang Y, *et al.* Lightweight pyramid networks for image deraining[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 31(6): 1794-1807
- [27] Cai L W, Li S Y, Ren D W, *et al.* Dual recursive network for fast image deraining[C] //Proceedings of the IEEE International Conference on Image Processing. Los Alamitos: IEEE Computer Society Press, 2019: 2756-2760