

# 基于卷积神经网络的单幅图像超分辨率重建算法综述

曹春阳 胡 诚 徐洪雨 徐晨光 邓承志

(江西省水信息协同感知与智能处理重点实验室, 江西 南昌 330099)

**摘要:** 近年来, 单幅图像超分辨率重建技术成为机器视觉领域的研究热点。随着深度学习的发展, 卷积神经网络在单幅图像超分辨率重建方面取得了前所未有的成功。文章对典型的图像超分辨率重建的卷积神经网络模型进行综合论述, 比较分析了不同模型之间的异同点和优缺点, 并对基于卷积神经网络的单幅图像超分辨率重建方法的未来研究方向进行展望。

**关键词:** 超分辨率重建; 单幅图像; 深度学习; 卷积神经网络 文献标识码: A 中图分类号: TP391

文章编号: 2096-4137 (2022) 12-105-07 DOI: 10.13535/j.cnki.10-1507/n.2022.12.36

## A review of super-resolution reconstruction of single image based on convolutional neural networks

CAO Chunyang, HU Cheng, XU Hongyu, XU Chenguang, DENG Chengzhi

(Jiangxi Province Key Laboratory of Water Information Cooperative Sensing and Intelligent Processing, Nanchang 330099, China)

**Abstract:** In recent years, single image super-resolution reconstruction technology has become a research hotspot in the field of machine vision. With the development of deep learning, convolutional neural network has achieved unprecedented success in single image super-resolution reconstruction. In this paper, the typical convolutional neural network model of image super-resolution reconstruction is discussed comprehensively, and the similarities and differences between different models are compared and analyzed. Finally, the future research direction of single image super-resolution reconstruction method based on convolutional neural network is prospected.

**Keywords:** super resolution reconstruction; single image; deep learning; convolutional neural network

单幅图像超分辨率重建 (SISR) 作为计算机视觉的一个经典问题, 旨在从输入的低分辨率 (LR) 图像恢复其对应的高分辨率 (HR) 图像。SISR 由于其本身的病态性和较高的实用价值, 至今仍是计算机视觉领域中一个活跃而富有挑战性的研究课题。相较于传统通过硬件的改善来提高图像的分辨率, 卷积神经网络的使用取得了更好的重建效果。现有的基于卷积神经网络的 SISR 方法大多是在假定退化模型的情况下设计的, 这种退化模型被认为是 SISR 的一般退化模型, LR 图像被建模为以下退化过程的输出:

$$y = (x \otimes k) \downarrow_s + n \quad (1)$$

其中,  $x \otimes k$  表示将模糊核  $k$  和对应的高分辨率图像  $x$  进行卷积操作,  $\downarrow_s$  是一个带有尺度因子  $s$  的后续下采样操作,  $n$  通常是带有标准偏差  $\sigma$  (噪声等级) 的加性噪声。

SISR 方法可以分为 3 大类。第 1 类是基于插值的方法, 如最近邻插值、双线性插值和双三次插值, 这些方法简单有效但性能有限。第 2 类是基于模型的优化方法, 得益于强大的图像先验信息, 这种方法可以十分方便地获得相对高质量的 HR 图像, 但这种方法的重建过程比较耗费时间。卷积神经网络 (CNN) 降噪先验和基于模型的优化方法相结合, 尽管获得了不错的重建效果, 但仍暴露出一些缺点, 如需要人

工调参、不是端到端学习等。第 3 类是判别学习方法, 作为一种替代学习方法, 判别学习方法因其良好的重建效果和效率而受到人们的关注。随着深度学习的急速发展, 近年来将 CNN 应用到 SISR 的研究急剧上升。

近年来, 针对基于 CNN 的 SISR 大体分为 2 个方面:

一是对网络模型进行改进和优化, 虽然一些基于 CNN 的 SISR 模型取得了不错的结果, 但所设计的网络模型大多用于单一的简单退化 (如双三次退化), 而针对现实场景的多种退化问题, 这种单一模型往往缺乏可扩展性。由于图像的真实退化复杂多样, 当所假设的退化与实际的退化不一致时, 学习到的 CNN 模型的重建效果可能并不理想, 从而使其在真实场景中的有效性降低。二是力求获得更为真实的训练数据集, 使训练的模型泛化能力达到进一步加强。在本文中, 重点分析几种经典的基于 CNN 的单幅图像超分辨率重建方法在模型和训练数据集上的研究, 并对比分析了其优缺点和对低分辨率图像的重建效果。

## 1 基于 CNN 的网络模型

### 1.1 SRCNN

作为将 CNN 应用到 SISR 的开山之作, SRCNN 网络结构并不复杂, 通过 3 层网络就实现了单幅图像的超分辨率重




图1 SRCNN网络结构




图2 FSRCNN和SRCNN的网络结构对比图

建，网络结构如图1所示。

SRCNN 网络主要分为 3 个步骤。

(1) 特征块提取，即利用 CNN 提取图像块的特征，公式表示如下：

$$F_1(Y) = \max(0, W_1 \times Y + B_1) \quad (2)$$

式中， $W_1$  和  $B_1$  表示滤波器和偏差，这里的  $W_1$  大小为  $c \times f_1 \times f_1 \times n_1$ ，其中表示输入图像的通道数量，图1中输入图像为灰度图像，即  $c$  为 1。 $f_1$  表示滤波器的大小，滤波器的数量用  $n_1$  表示。从式(2)看， $W_1$  对输入图像  $Y$  进行  $n_1$  次卷积操作， $f_1 \times f_1$  表示每个卷积核的大小。由于进行了  $n_1$  次卷积，则输出特征图的数量为  $n_1$ 。 $B_1$  表示  $n_1$  维向量，该向量的元素与滤波器相关联。

(2) 非线性映射，也就是将第一步的  $n_1$  维特征向量映射到相较于  $n_1$  更高维的  $n_2$  维。公式如下：

$$F_2(Y) = \max(0, W_2 \times F_1(Y) + B_2) \quad (3)$$

式中， $W_2$  的大小是  $n_1 \times 1 \times 1 \times n_2$ ，而  $B_2$  是  $n_2$  维的向量。每个输出的二维向量表示用于重建的高分辨率补丁。这里做非线性映射是为了增加层数。

(3) 重构，即在第二步的基础上进行卷积操作，相当于传统意义上的平均处理。公式如下：

$$F(Y) = W_3 \times F_2(Y) + B_3 \quad (4)$$

式中， $W_3$  的大小是  $n_2 \times f_3 \times f_3 \times c$ ，而  $B_3$  是一个  $c$  维向量。

借助于双三次（bicubic）插值方法，SRCNN 先将输入的 LR 图像通过双三次插值放大到所需尺寸，接着进行非线性映射，具体操作是通过三个卷积层来实现，最后重建出 HR 图像。SRCNN 虽然相较于传统的方法有很大的优势，但也存在一些问题有待改进：①训练收敛比较缓慢；②对小图像区域的内容过分依赖；③网络只针对某一尺寸的图像有效。针对 SRCNN 存在的一些问题，后来提出的 FSRCNN 对其作了部分改进。

FSRCNN 改进的地方主要有 3 方面：①针对 SRCNN 需要通过双三次插值方法放大尺寸，FSRCNN 通过一个反卷积层将图像放大到目标尺寸；②利用比较小的卷积核和更多的映射层来改变特征维数；③共享映射层。两种网络结构对比图如图2所示。

FSRCNN 网络主要包括特征提取、收缩、非线性映射、扩张、反卷积。其中特征提取是利用卷积层处理输入图像，不同于 SRCNN 中  $9 \times 9$  的大卷积核，而是选用较小的  $5 \times 5$  的卷积核。收缩是采用  $1 \times 1$  的卷积核进行降维操作，其目的是为了降低计算的复杂度。非线性映射主要是为了获得较

大的感受野,并且降低计算量,主要是采用小的卷积核串联去替代大卷积核。在 SRCNN 中的非线性映射利用的是  $5 \times 5$  的卷积核,这样就会使计算量很大。扩张是采用小卷积核进行扩维操作,这里采用  $1 \times 1$  卷积核,类似于收缩的逆过程。由于低维的图像特征重建效果并不理想,因此通过扩张操作对特征进行扩维。最后是反卷积层,即卷积的逆操作,也就是进行上采样操作。相较于 SRCNN,FSRCNN 在收缩层和扩张层中利用比较小的卷积核进行卷积操作,从而摒弃了大的卷积核,因此,在训练速度上有很大的提升。

### 1.2 VDSR

残差网络的提出,解决了以往无法训练深度网络的弊病,基于这样的背景,VDSR 应运而生。考虑到 LR 图像和 HR 图像所携带的低频信息极为相近,即它们之间具有极大的相似性。若在对网络进行训练时,继续学习这部分相似的低频信息,将会消耗非必要的时间,也就是说只需对 HR 图像和 LR 图像之间的高频信息进行学习,残差结构的思想特别适合解决此类问题。VDSR 的一大特点就是引入了残差结构,其网络结构如图 3 所示。

VDSR 网络将插值后的低分辨率图像作为输入并学习图像细节,再将插值后的图像与学习到的图形细节信息相加形成全局残差学习,从而进行超分辨率的重建。VDSR 网络相

对 SRCNN 网络主要有 3 方面优点:①更深的网络结构使其具备更大的感受野;②将残差学习引入超分辨率重建,使网络收敛速度更快,提高了学习率;③在卷积之前对图像进行补零操作,使得所有的输出特征图的大小保持不变。

### 1.3 SRDenseNet

不同于 VDSR 中的残差块,SRDenseNet 将更为复杂的稠密块(Dense Block)应用在 SISR 问题上,获得了很好的效果。SRDenseNet 网络可分为 4 部分:①通过一个卷积层去学习底层的图像特征;②学习高层图像特征,具体做法是采用 DenseNet 结构中的多个稠密块去学习,DenseNet 网络如图 4 所示;③学习上采样的滤波参数,这里采用反卷积层去学习;④通过一个卷积层获得 HR 图像。

DenseNet 是一个具备稠密块的卷积神经网络。其在稠密块中将每一层的特征都输入给之后的卷积层,这样就可以串联起所有层的特征,而不是像 VDSR 那样利用残差结构简单相加。有效避免了梯度消失问题,并在一定程度上加强特征传播,利用特征复用减少了训练参数。

### 1.4 EDSR

EDSR 是针对 SRResNet 网络的改进,其最大的特点是删除冗余模块,以便可以扩展模型的大小,以提高重建结果的质量。EDSR 的网络结构如图 5 所示。




图3 VDSR网络结构




图4 DenseNet网络结构

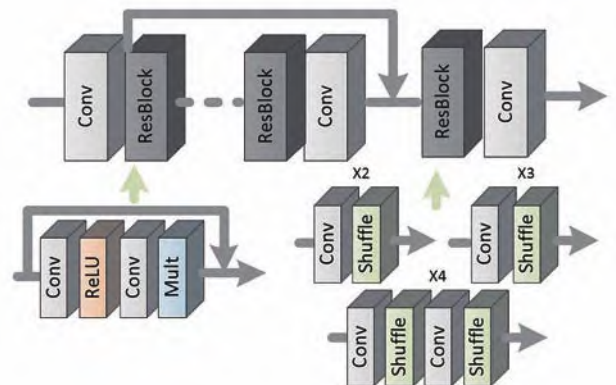


图5 EDSR网络结构

相较于 SRResNet, EDSR 删掉了批规范化处理 (Batch Normalization, BN)。残差网络 (ResNet) 最早是为了解决分类和检测等高层计算机视觉问题, 显然, 如果直接把残差块应用到 SISR 问题上, 并不能取得较好的效果。在去掉批规范化操作后, BN 层不再占用内存资源, 这就相当于给卷积层预留了足够多的计算资源, 这样 EDSR 就可以通过添加更多的卷积层来提取图像特征, 从而获得更多的图像细节, 实现更高精度的超分辨率重建。在 EDSR 的模型训练过程中,

首先对低倍上采样模型进行训练,将得到的训练参数迁移到高倍上采样模型,从而大大减少了训练所需的时间,提升了训练效果,使之获得更好的重建效果。

### 1.5 RDN

RDN 将 VDSR 中的残差结构和 SRDenseNet 中的密集块相结合，提出了残差密集块（Residual Dense Blocks，RDBs），其网络结构如图 6 所示。

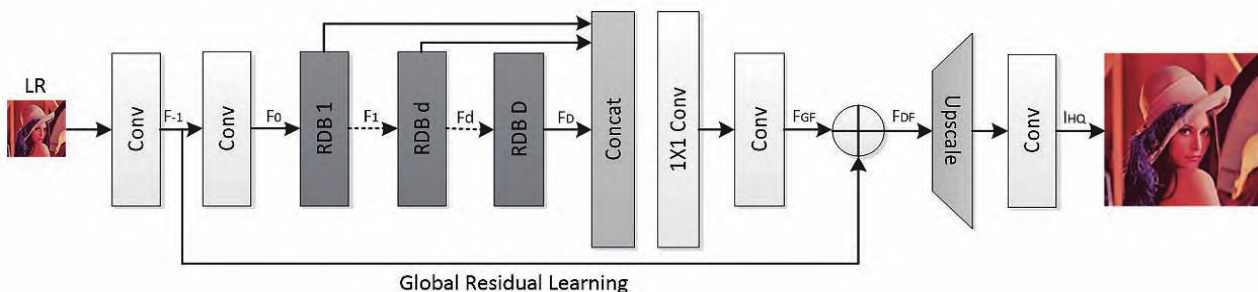


图6 RDN网络结构

表1 5种基于CNN的SR算法重建效果对比

| 数据集   | 尺寸 | SRCNN        | VDSR        | SRDenseNet  | EDSR        | RDN         |
|-------|----|--------------|-------------|-------------|-------------|-------------|
|       |    | PSNR/SSIM    | PSNR/SSIM   | PSNR/SSIM   | PSNR/SSIM   | PSNR/SSIM   |
| Set5  | x2 | 36.62/0.953  | 37.56/0.959 | \           | 38.11/0.960 | 38.24/0.961 |
|       | x3 | 32.74/0.908  | 33.67/0.922 | \           | 34.65/0.928 | 34.71/0.930 |
|       | x4 | 30.48/0.863  | 31.35/0.885 | 32.02/0.893 | 32.46/0.897 | 32.47/0.899 |
| Set14 | x2 | 32.42/0.906  | 33.02/0.913 | \           | 33.92/0.920 | 34.01/0.921 |
|       | x3 | 29.27/0.821  | 29.77/0.832 | \           | 30.52/0.846 | 30.57/0.847 |
|       | x4 | 27.48/0.751  | 27.99/0.766 | 28.50/0.778 | 28.80/0.788 | 28.81/0.787 |
| B100  | x2 | 31.34/0.887  | 31.89/0.896 | \           | 32.32/0.901 | 32.34/0.902 |
|       | x3 | 28.40/0.786  | 28.82/0.798 | \           | 29.25/0.809 | 29.26/0.809 |
|       | x4 | 26.90/0.710  | 27.28/0.726 | 27.53/0.734 | 27.71/0.742 | 27.72/0.742 |
| U-100 | x2 | 29.50/0.8946 | 30.76/0.914 | \           | 32.93/0.935 | 32.89/0.935 |
|       | x3 | 26.24/0.7989 | 27.14/0.828 | \           | 28.80/0.865 | 28.80/0.865 |
|       | x4 | 24.52/0.721  | 25.18/0.752 | 26.05/0.782 | 26.64/0.803 | 26.61/0.803 |



RDN 主要包括浅层特征提取网络 (SFENet)、残差密集块 (RDBs)、密集特征融合 (DFF)、上采样网络 (UPNet) 4 个模块。其中 SFENet 模块主要表示前 2 个卷积层; RDBs 模块主要将残差结构和密集连接模块进行了整合, 将两者集合起来, 形成了残差密集块; DFF 模块包含全局特征融合和全局残差学习两部分, 全局特征融合表示对 F1、F2、...FD 特征的利用, 全局残差学习表示 F-1 和 FGF 的加和操作。UPNet 模块表示网络最后的上采样和卷积操作, 实现了输入图像的放大操作。

相较于 DenseNet block, RDN 中的 RDBs 模块去掉了 DenseNet 每个块中的 BN 操作以及每个块中的池化操作, 并且残差密集块将 d-1 层的图像特征信息和 1 到 d 层的图像信息进行局部特征融合, 使图像特征信息得到更好的利用。相较于在 SRDenseNet 整个网络结构中, 仅仅利用每个稠密块的最后一个输出, 每个残差密集块的输出最终将在整个 RDN 中连接和使用。

针对 SRDenseNet 中使用的密集跳跃连接模块, RDN 主要在以下 3 方面对其进行了改进: ①由于局部特征融合的使用, RDB 模块可以实现更高的增长率; ②增加了连续存储机制, 使以前的 RDB 模块和当前的 RDB 模块直接接触; ③通过局部残差学习在 RDB 中的应用, 增加了信息和梯度的流动。

## 2 基于 CNN 的 SISR 算法对比分析

表 1 显示了上述分析的基于 CNN 的 5 种经典的 SISR 方法在 4 个图像处理中常用的数据集 (set5、set14、BSD100、Urban100) 上的 PSNR (峰值信噪比) 和 SSIM (结构相似性) 结果。

从表 1 中可以看出, VDSR 相较于 SRCNN, 由于具备更深的网络结构, 且加入残差结构, 在不同放大因子下, 其重建效果均优于 SRCNN。SRDenseNet 由于将稠密块应用在 SISR 问题上, 获得了较好的 PSNR 和 SSIM 值。VDSR 模型和 SRDenseNet 模型的实验结果表明, 通过加深网络模型或使用更复杂的模型可以获取更好的重建效果。

EDSR 由于具备更深的网络层, 相较于 SRDenseNet, 其 PSNR 和 SSIM 值进一步提高。RDN 通过将 VDSR 中的残差块和 SRDenseNet 中的稠密块相结合, 获得较好的重建效果。对比几种网络训练参数数量和峰值信噪比 (PSNR) 之间的关系绘制如图 7 所示。

可见 VDSR 由于将残差学习思想引入超分辨率重建中, 相较于 SRCNN, 在训练参数数量接近的情况下, 获得了更

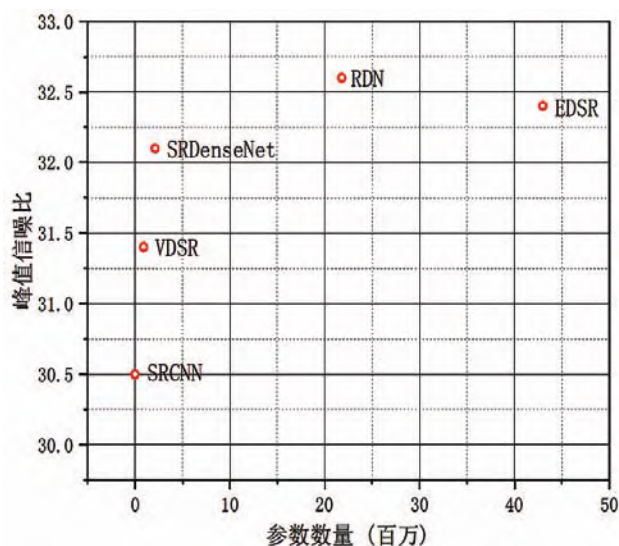


图7 不同网络模型的PSNR值和参数数量之间的关系

好的重建效果。从图 7 可以看出, RDN 和 EDSR 获得了较高的 PSNR 值, 即重建效果较好, 但相对训练参数较多, 即模型复杂度相对较高。以上 5 种典型网络的内部结构及优缺点如表 2 所示。

## 3 结语

迄今, 卷积神经网络的使用极大地提高了单幅图像的超分辨率重建效果, 使更多的图像细节为人所获取, 极大地推动了单幅图像超分辨率重建技术在遥感图像、医学成像等领域的使用。本文主要研究了几种经典的基于 CNN 的单幅图像超分辨率重建网络。针对其不足之处总结如下:

(1) 现有的基于 CNN 的 SISR 方法大多是在模拟数据集上进行训练和评估的, 其中 LR 图像是通过对其对应的 HR 图像应用简单的均匀退化 (即双三次下采样) 生成的。但现实中的 LR 图像的退化情况比较复杂。因此, 用模拟数据训练的 SISR 模型应用于实际场景时效果不佳。

(2) 现有的基于 CNN 的 SISR 方法大多通过直接叠加更多的卷积层的方法来加深网络以获得更好的重建效果, 没有对输入的 LR 图像的多尺度特征进行充分利用。

基于 CNN 的单幅图像超分辨率重建技术涉及到理论知识、网络模型以及实际的应用场合, 本文只是对几种典型的重建网络进行研究和分析。一方面, 虽然随着网络的加深, 重建效果有所改善, 但其网络结构越来越复杂, 这就使得计算量增加, 重建速度变慢。另一方面, 力求找到更接近真实低分辨率图像的数据集去训练网络模型, 这样使得网络的泛

表2 不同网络模型的内部结构及优缺点

| 方法         | 网络结构      | 网络复杂度 | 训练难度     | 重建效果     |
|------------|-----------|-------|----------|----------|
| SRCNN      | 直连模型      | 较低    | 参数多，难度大  | 精度最高，有伪影 |
| VDSR       | 残差学习      | 较高    | 参数较少，难度小 | 精度较高，有伪影 |
| SRDenseNet | 密集跳跃连接    | 高     | 参数较多，难度大 | 精度高，有伪影  |
| EDSR       | 残差块、内存块   | 较高    | 参数较少，难度小 | 精度较高，有伪影 |
| RDN        | 残差密集块、反馈块 | 最高    | 参数较少，难度小 | 精度最高，有伪影 |

化能力加强，能够应对更为真实的场景，这也是目前的主流方向。但制作真实低分辨率图像的数据集需要耗费大量的人力物力，使得重建技术的成本提高，降低了实用价值。若想将SISR真正应用于实际场景，或许对单幅图像进行盲SR重建是一大的趋势，即不再依靠高低分辨率图像来训练模型，而是学习不成对图像的特征与表示，或者是充分学习单幅图像周围像素点，以供未知降质图像完成重建。

**基金项目：**2013年江西省大学生创新创业训练计划资助项目（201311319034）；2012年江西省大学生创新创业训练计划资助项目（201211319001）；江西省研究生创新专项资金项目（YC2021-S184）；2021年南昌工程学院大学生创新创业训练计划资助项目（2021026）；2022年江西省大学生创新创业训练计划资助项目（S202211319025）；2019年国家大学生创新创业训练计划资助项目（201911319016）。

**作者简介：**曹春阳（1996-），男，湖北黄冈人，江西省水信息协同感知与智能处理重点实验室硕士研究生，研究方向：图像处理；邓承志（1980-），通讯作者，男，江西赣州人，博士，江西省水信息协同感知与智能处理重点实验室教授，硕士生导师，研究方向：遥感影像处理、机器视觉等。

参考文献

[1]南方哲，钱育蓉，行艳妮，等. 基于深度学习的单图像超分辨率重建研究综述[J]. 计算机应用研究，2020，37（2）：321-326.

[2]张芳，赵东旭，肖志涛，等. 单幅图像超分辨率重建

技术研究进展[J/OL]. 自动化学报，2022:1-21.

[3]He K, Zhang X, Ren S, et al. Deep residual learning for im-age recognition[C]. Proceedings of the 29th IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, NV, USA: IEEE, 2016: 770-778.

[4]Huang G, Liu Z, Weinberger K Q. Densely connected convolutional networks[C]. Proceedings of the 30th IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, HI, USA: IEEE, 2017. 2261-2269.

[5]Ren S, Jain D K, Guo K, et al. Towards efficient medical lesion image super-resolution based on deep residual networks[J]. Signal Processing: Image Communication, 2019（75）:1-10.

[6]Kim J, Kwon Lee J, Mu Lee K. Accurate image super-resolution using very deep convolutional networks[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1646-1654.

[7]曲延云，陈蓉，李翠华，等. 深度学习单帧图像超分辨率重建研究综述[J]. 厦门大学学报（自然科学版），2021，60（3）:555-570，641-642.

[8]赵丽玲，孙权森，张泽林. 基于深度学习特征字典的单帧图像超分辨率重建[J]. 数据采集与处理，2018，33（4）:740-750.

（下转第128页）

正得到有效解决,车企自身则需要能够从技术角度出发,更多地针对能满足人们实际出行需要的具有更高实用性的车型进行研究。

(2) 随着我国双积分相关政策的逐渐落实,一定程度上有效驱动新能源汽车的整体市场发展,各大车企为有效减少购买积分给自身利润带来的损失,会主动加大产品的研发力度,产品线的丰富程度会进一步增加,进而有效提高对消费者购买的吸引力。但是,双积分政策的落地也有其自身问题,受到补贴减少、政策落地时间紧迫以及新能源企业外资股比的放开等因素影响,一些车企能够占领市场的时间相对较少,毕竟未来的汽车工业在实际发展过程中,新能源汽车将成为重要的走向。从政策角度出发推动整体行业的产业升级以及生产结构调整,对于新能源汽车企业技术的发展来讲是十分重要的挑战。

(3) 随着电动车市场发展速度的进一步加快,在实际消费过程中,关注点也会更多地转向充电、电耗、续航里程、动力及安全等因素,这对电动车企业技术的发展提出了更高要求,也是有效推动新能源汽车技术发展的重要外部力量,同时,也是新能源汽车重要的技术进步趋向。

#### 4 结语

综上所述,我国在实际发展新能源汽车的过程中,技术

力量不足是限制行业整体发展的重要因素。而要真正推动各车企加大技术研发的力度,则需要充分发挥政策的力量,形成良好的市场导向,使得新能源汽车产品能够更好地适应市场。

**作者简介:** 丁晓春(1972-),男,山东聊城人,聊城市高新技术创业服务中心中级工程师,研究方向:电器。

#### 参考文献

- [1] 陈保山. 国内新能源汽车行业的汽车技术发展趋势——评《新能源汽车关键技术》[J]. 热带作物学报, 2021, 42(3): 912.
- [2] 李国彬. 新能源汽车的发展现状与未来前景研究[J]. 内燃机与配件, 2019(14): 221-222.
- [3] 董潭. 我国新能源汽车行业发展分析及建议[J]. 广西质量监督导报, 2019(3): 101-102.
- [4] 唐葆君, 王翔宇, 王彬, 等. 中国新能源汽车行业发展水平分析及展望[J]. 北京理工大学学报(社会科学版), 2019, 21(2): 6-11.
- [5] 陈浩东. 浅谈国内新能源汽车发展方向[J]. 时代汽车, 2019(3): 84-85.

(责任编辑: 肖央然)

(上接第110页)

[9] 汪锐. 基于深度学习的单帧图像超分辨率重建算法研究[D]. 西安: 西安电子科技大学, 2019.

[10] Wang X, Yu K, Dong C, et al. Recovering realistic texture in image super-resolution by deep spatial feature transform[C]. 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2018: 606-615.

[11] Pan Z, Ma W, Guo J, et al. Super-resolution of single remote sensing image based on residual dense back-projection networks[J]. IEEE Transactions on Geoscience and Remote Sensing, 2019, 57(10): 7918-7933.

[12] Lim B, Son S, Kim H, et al. Enhanced deep residual networks for single image super-resolution[C]. Proceedings of the 30th IEEE Conference on Computer

Vision and Pattern Recognition Workshops. Honolulu, HI, USA: IEEE, 2017: 1132-1140.

[13] Zhang Y, Tian Y, Kong Y, et al. Residual dense network for image super-resolution[C]. Proceedings of the 31st IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, UT, USA: IEEE, 2018. 2472-2481.

[14] Zhang K, Zuo W, Zhang L. Deep plug-and-play super-resolution for arbitrary blur kernels[C]. 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2019: 1671-1681.

[15] 李佳星, 赵勇先, 王京华. 基于深度学习的单幅图像超分辨率重建算法综述[J]. 自动化学报, 2021, 47(10): 2341-2363.

(责任编辑: 肖央然)