

doi:10.19665/j.issn1001-2400.2019.05.003

一种对称残差 CNN 的图像超分辨率重建方法

刘树东, 王晓敏, 张 艳

(天津城建大学 计算机与信息工程学院, 天津 300384)

摘要: 基于卷积神经网络的图像超分辨率重建方法具有很高的重建性能。但该类方法存在网络参数多、训练难度大、梯度消失和网络退化等问题。针对这些问题,提出一种基于对称残差卷积神经网络的图像超分辨率重建方法。通过将对称融入到残差块中,采用对称连接实现局部特征融合,提取尽可能多的有价值特征;残差块外采用跳跃连接实现全局特征融合,以提高图像的重建质量。该方法使用峰值信噪比和结构相似度作为评价指标,在 Set5、Set14 和 BSD100 标准数据集上进行 2 倍、3 倍和 4 倍因子重建后的结果大部分优于比较方法,平均峰值信噪比和结构相似度值较比较方法均有提高。实验结果表明,该方法重建的图像纹理更清晰,细节更丰富,具有较好的主观视觉效果。

关键词: 超分辨率重建;卷积神经网络;深度学习;对称残差网络

中图分类号: TP391 **文献标识码:** A **文章编号:** 1001-2400(2019)05-0015-09

Symmetric residual convolution neural networks for the image super-resolution reconstruction

LIU Shudong, WANG Xiaomin, ZHANG Yan

(School of Computer and Information Engineering, Tianjin Chengjian University, Tianjin 300384, China)

Abstract: The image super-resolution reconstruction methods based on the convolutional neural network have high reconstruction performance, but they have many network parameters and are difficult to train. Also, they are prone to problems such as gradient disappearance and network degradation. To solve these problems, a super-resolution image reconstruction method based on the symmetric residual convolution neural network is proposed. This method integrates symmetry into residual blocks. It realizes local feature fusion by adopting the symmetric connection and extracts as many valuable features as possible. To improve the quality of image reconstruction, the global feature fusion is realized by skip connection. In this method, the peak signal to noise ratio (PSNR) and structural similarity (SSIM) are used as evaluation indexes. The results by the proposed reconstruction method on Set5, Set14, and BSD100 are superior to those by most of other methods in comparison. The average PSNR and SSIM values are improved compared with those methods. Experimental results show that the image reconstructed by this method has clearer textures, richer details and a better subjective visual effect.

Key Words: super-resolution reconstruction; convolution neural network; deep learning; symmetric residual network

图像超分辨率(Super-Resolution, SR)重建是图像复原中的一个重要分支^[1],是一种由低分辨率图像恢复对应高分辨率图像的方法。随着图像超分辨率在卫星成像^[2]、医学成像^[3]、安全和监视^[4]、图像生成^[5]等计算机视觉任务和图像处理领域取得的突出成就,利用超分辨率技术重建出更高分辨率、更清晰的图像成为

收稿日期:2019-01-16

网络出版时间:2019-07-02

基金项目:天津市企业科技特派员项目(18JCTPJC60000)

作者简介:刘树东(1965—),男,教授,E-mail: liushudong@tcu.edu.cn.

通信作者:张 艳(1982—),女,副教授,E-mail: zhangyan@tcu.edu.cn.

网络出版地址: <http://kns.cnki.net/kcms/detail/61.1076.TN.20190701.1627.004.html>

万方数据

<http://journal.xidian.edu.cn/xdxb>

目前图像复原领域的研究热点。

图像超分辨率重建最早是由文献[6]在 20 世纪 60 年代提出的。随着超分辨率技术的广泛应用,越来越多的学者开始对其进行探究。图像超分辨率重建方法主要有 3 种:基于插值的方法^[7]、基于重建的方法^[8]和基于学习的方法^[9-10]。基于差值的超分辨率重建方法计算简单,容易实现,但对自然图像的先验知识具有较大的依赖性,对图像细节恢复效果较差,容易出现边缘效应。基于重建的方法根据已知的退化模型得到低分辨率图像,通过提取低分辨率图像中关键的像素点信息对高分辨率图像的生成进行约束,结合高分辨率图像中的先验知识得到相应的重建结果。但由于获得的先验知识有限,因此对于复杂的图像无法恢复出更多细节信息,重建性能有限。基于学习的方法通过建立高、低分辨率图像两者之间的映射关系,然后利用学习获得的先验知识来完成高分辨率图像的重建。与其他重建方法相比,基于学习的图像超分辨率方法可以从训练样本中学习到所需的细节信息,并对测试样本进行估计,可获得相对较好的重建效果。目前基于学习的方法主要有基于稀疏表示、近邻嵌入和深度学习的方法。文献[11-12]提出一种基于稀疏表示和字典学习的方法,通过学习低分辨率图像块和对应高分辨率图像块的超完备字典进行图像重建。但由于对超完备字典的学习要求较高,实用性较差,文献[13-14]将稀疏字典和领域嵌入进行结合,提出了锚定领域回归算法和改进后的锚定领域回归(A+)算法,计算效率得到了提高,但图像细节恢复效果较差。

随着深度学习的飞速发展,基于深度学习的方法与传统方法^[15-16]相比有显著的优势。卷积神经网络(Convolutional Neural Network,CNN)作为深度学习的代表性算法之一,由于其高效的学习能力,在超分辨率领域得到了广泛的应用^[17-18]。文献[9]采用 3 层卷积神经网络(Super-Resolution Convolutional Neural Network, SRCNN)进行图像超分辨率重建。该网络结构简单,容易实现,但由于卷积层数少、感受野小以及泛化能力差等缺陷,无法提取到图像深层次的特征,导致重建性能有限。文献[19]提出的卷积网络将网络深度提升到了 20 层,并引入了残差学习,提高了特征提取能力。同时,文献[20]还提出了深度递归卷积网络,采用递归学习实现了深度网络的参数共享,降低网络的训练难度。虽然文献[19-20]提出的两种方法取得了较好的重建性能,但是随着网络的加深,梯度消失和网络退化也会越明显。文献[21]提出了深度拉普拉斯金字塔网络,采用级联结构逐步学习,逐步优化,取得了很好的重建效果。文献[22]提出了一种深度残差递归网络,通过循环残差的方式减少训练参数,降低网络训练难度,有效缓解了梯度消失现象。文献[23]提出的深度残差编码解码网络,采用对称方式跳跃连接卷积与反卷积层,使训练收敛速度更快,达到更高质量的局部最优,但随着网络深度的增加,梯度消失或网络退化现象仍然存在。

笔者针对上述方法的不足,将对称跳跃连接引入到卷积神经网络,提出了一种基于对称残差的卷积神经网络模型,以进一步提高图像重建的质量。通过在残差块内建立对称短跳连接,实现块内信息充分利用,提取更丰富的局部特征,同时,在残差块外建立长跳连接,实现全局特征融合,以弥补深度网络图像细节信息退化严重的损失。针对损失函数的选择,采用处理异常点更稳定的平均绝对值误差(Mean Absolute Error, MAE)函数进行训练。

1 相关工作

文献[23]提出的深度残差编码解码网络是一种对称网络结构,将卷积神经网络中的卷积和反卷积操作运用于图像复原。首先,对称跳跃连接有助于图像信息直接反向传播,从而缓解了梯度消失的现象,使深度网络训练更加容易,提高了网络的恢复性能。随着卷积神经网络深度的增加,残差网络中的残差结构可以有效缓解深度网络引起的梯度消失和网络退化现象,网络架构越深,其丰富抽象特征的提取和网络性能越好。

文献[24]提出的 152 层深度残差网络(Residual Network, ResNet)利用非线性网络可以拟合任意函数的特性,使用包含少数隐层的浅层网络拟合自定义的残差函数 $F(x)$: $= H(x) - x$,残差函数再与恒等映射 x 相加, x 表示网语的输入,构成基本的残差单元,实现期望的特征映射关系 $H(x)$ ^[25]。研究表明,这种方式更易于优化^[6,26-30]。如图 1 所示,残差结构在解决梯度消失问题的同时,避免了因网络加深而导致的额外参数引入,在深层网络中使用跳跃连接的方式将




图 1 残差结构图

卷积层连接,实现了不同卷积层中特征的重复利用,大大降低了训练时的计算量^[31]。文献[18]在输入数据和最后重建层之间采用跳跃连接进行信息传递。研究表明,在各层之间建立多个跳跃连接可以有效地训练深度网络^[21]。

由于网络深度的不断增加,该方法将残差网络引入图像超分辨率以解决深度网络训练难度大的问题;将一种对称长短跳跃连接引入卷积神经网络,通过在网络中设置带泄漏线性整流(Leaky Rectified Linear Unit, LReLU)函数作为激活函数,使网络训练更稳定,并以原始低分辨率图像作为输入,减少图像经预处理后导致高频信息丢失的现象,进一步提高了网络的特征提取能力。

2 对称残差卷积神经网络模型

2.1 对称残差卷积网络结构

基于对称残差的卷积网络(Symmetric Residual Convolution Neural, SymRCN)模型主要由特征提取、特征融合和重建 3 部分构成,共包含 31 层卷积层。该网络模型包括 4 个残差块,采用对称长短跳跃连接实现全局与局部特征融合,实现网络训练的稳定性 and 特征提取的高效性。在残差块内采用对称残差的方式提取更丰富的特征,残差块外通过长跳连接实现全局特征融合,有效缓解了由简单堆叠多个残差块而导致特征提取不充分、梯度消失和网络退化问题。网络结构如图 2 所示,其中, x 和 y 分别表示网络的输入和输出。

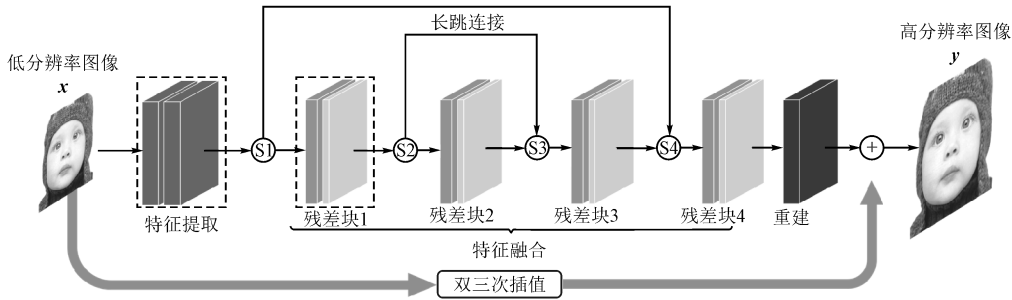


图 2 对称残差卷积网络结构图

对称残差卷积神经网络模型建立时的具体实现步骤有 3 个:①特征提取。主要完成提取不同条件下的细节特征,将获得的低分辨率图像的的稳定特征作为特征融合模块的输入数据;②特征融合。利用残差块内多个对称残差的卷积层和非线性映射函数的复合实现网络中不同特征图的提取,通过在残差块外建立长跳连接来完成各个残差块间特征的融合,并作为重建模块的输入数据;③重建。利用预测的残差图像重建出最终的高分辨率图像。

特征提取部分由两层卷积层构成,为了降低网络参数数量和计算复杂度,每层卷积层均使用 64 个大小为 3×3 的卷积核对原始低分辨率图像进行卷积,提取特征图。特征 B_0 提取过程可以表示为

$$B_0 = f(x) \quad , \quad (1)$$

其中, f 表示特征提取函数, x 并作为下面残差块的输入。

特征融合部分由 4 个残差块组成,每个残差块由一个增强单元和一个压缩单元构成,这个过程可以表示为

$$B_m = F_m(B_{m-1}) \quad , \quad m = 1, 2, \cdots, n \quad , \quad (2)$$

其中, F_m 表示第 m 个残差块对应的函数, B_{m-1} 和 B_m 分别表示第 m 个残差块的输入和输出。

重建部分使用一层无激活函数的反卷积层实现最终图像重建,该层的功能相当于上采样操作。在反卷积过程中,当步长 s 大于 1 时,反卷积操作被视为上采样,且网络的整体复杂度会降低^{s²},但步长不宜过大,因为过大的步长会导致重建质量的下降。根据采样因子的不同,相应调整步长大小,但步长始终大于 1。重建过程中反卷积层对特征图进行上采样操作,将最终残差块的输出特征组合起来生成残差图像,其中,反卷积层的偏置项能够自动调整残差图像数据分布的中心值,使之接近原始图像。由于输入的原始低分辨率图像与高分辨率图像间存在极大的相似性,因而两者间残差图像的像素信息多数情况趋近于零。使用输入的低分辨率图像、原始高分辨率图像和生成的残差图像共同完成高分辨率图像的重建,进一步提高了图像的重建质量。网络的输出 y 可表示为

$$y = R(F_n(B_{n-1})) + U(x) \quad , \quad (3)$$

其中, R 和 U 分别表示重建和双三次插值函数。

多数网络结构采用均方误差 (Mean Square Error, MSE) 作为损失函数进行网络训练。该网络考虑并采用了平均绝对值误差损失函数估测重建后的高分辨率图像 \hat{I} 与原始图像 I 之间的误差, l_{MAE} 可表示为

$$l_{MAE} = \frac{1}{N} \sum_{i=1}^N \| I_i - \hat{I}_i \|_1 \quad (4)$$

2.2 特征融合

特征融合是本网的核心部分,由增强单元和压缩单元组成,Conv+LReLU(k, n)中 k 代表卷积核大小, n 代表卷积核个数,并使用带泄漏线性整流函数作为激活函数。其中增强单元包含 6 层结构相同的卷积层,通过对称残差实现浅层与深层信息的恒等映射,融合网络上下文信息,提取更丰富的特征。压缩单元由 1 层 1×1 的卷积层构成,为后续网络提取关键信息。残差块内增强与压缩单元框架如图 3 所示。当前残差块的输出 B_{m-1} 可表示为

$$B_{m-1} = D \left((C_1^{m-1} + C_6^{m-1}), (C_2^{m-1} + C_5^{m-1}), (C_3^{m-1} + C_4^{m-1}) \right) \quad (5)$$

其中, B_{m-1} 既表示当前残差块的输出,又同时作为下一个残差块的输入; D 表示降维操作; C_z^{m-1} ($z = 1, 2, \dots, 6$) 表示第 $m-1$ 个残差块中第 z 层卷积层的卷积操作。

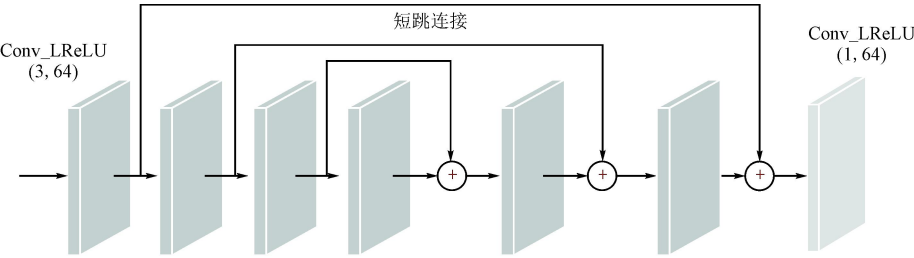


图 3 残差块内增强与压缩单元框架图

3 实验结果分析

3.1 数据集预处理

使用文献[12]的 91 张图像和文献[32]中的 200 张图像作为训练样本。为了充分利用训练数据,通过对 291 张图像进行 90° 、 180° 、 270° 旋转,水平翻转,并以因子 0.9、0.8、0.7、0.6 的顺序缩小,对训练图像进行数据增强处理后获得训练图像 11 640 张。为了进一步证明提出方法的有效性,选择应用广泛的标准数据集 Set5、Set14、BSD100 进行测试,数据集中包含了丰富的自然场景,可以有效地测试网络的性能。

利用双三次插值法以因子 k ($k = 2, 3, 4$) 对原始图像进行下采样,生成相应的低分辨率图像,将低分辨率训练图像裁剪为一组 $l_{sub} \times l_{sub}$ 的子图,相应的高分辨率训练图像被裁剪为 $kl_{sub} \times kl_{sub}$ 的子图。由于网络使用 Caffe 深度学习框架进行训练^[33],所以将反卷积核产生的输出大小设置为 $(kl_{sub} - k + 1)^2$,而非 $(kl_{sub})^2$,因此,高分辨率子图的像素边界应裁剪 $(k - 1)$ 。同时,使用 Caffe 框架训练时,若拥有较大学习率的训练样本尺寸越大,则训练过程越不稳定。由于裁剪图像块时无重叠部分,为了充分利用 291 张图像,当采样因子增大时,子图像采样步长相应缩小,裁剪后的训练子图尺寸相应变小,以便得到更多边缘的图像块。以采样因子 $k = 3$ 为例,根据数据集中最小图像的尺寸,将低分辨率子图图像采样步长设置为 15,低分辨率图像裁剪为 15×15 (15^2) 的训练子图,对应的高分辨率图像裁剪为 43×43 (43^2 , 其中高分辨率子图尺寸通过 $15 \times 3 - 3 + 1$ 获得)的训练子图,故训练阶段使用大小为 $15^2/43^2$ 的训练对进行训练。初始学习率设为 10^{-4} ,训练过程中,每 250 000 次学习率下降 10^{-1} ,总的训练次数为 600 000 次。训练样本尺寸如表 1 所示。

表 1 不同采样因子的训练子图尺寸

采样因子	训练
2	$29^2/57^2$
3	$15^2/43^2$
4	$11^2/41^2$

对于原始彩色图像,将每张彩色图像从 RGB 颜色空间转换为

YCbCr 彩色空间。由于人眼视觉相比于颜色对图像亮度更加敏感^[34],在 SRCNN 中已经证明仅在 Y 通道进行映射关系不会影响图像的重建质量^[9],所以仅对 Y 通道即亮度通道做训练从而得到对应的映射关系,对 Cb、Cr 颜色分量进行简单的插值放大,这样可以减轻计算的开销,同时保证了图像的重建质量^[35]。

网络中,所有采样因子的上采样核均为 17×17 ,带泄漏线性整流函数的负斜率设置为 0.05,使用文献[36]提出的方法初始化权重,偏置设为零,网络使用 Adam 进行优化。

3.2 实验分析

实验硬件配置为 Intel(R)Xeon(R)CPU E5-1650 v4 @ 3.60GHz \times 12 处理器, Tesla K20c 显卡, 64GB 内存,平台为 Matlab R2016a 软件和 caffe 深度学习框架以及用于调用 GPU 的开发包 CUDA8.0。首先针对在残差块内使用和不使用对称短跳连接两种情况,采用两种不同的网络模型进行峰值信噪比 (PSNR) 的测试实验,然后使用标准测试集 Set5、Set14、BSD100 进行测试,将 SymRCN 方法与 Bicubic、A+^[13]、SRCNN^[9]、VDSR^[14]、DRCN^[15] 和 LapSRN^[16] 6 种典型方法的重建结果进行比较,使用峰值信噪比和结构相似度 (SSIM) 作为衡量图像重建质量的指标。

图 4 统计了残差块内是否使用对称,并经过 600 000 次迭代后,在 Set5 测试集上重建结果的平均峰值信噪比曲线图。从图 4 中可以看出,使用对称的网络模型,峰值信噪比值有明显提高,充分证明了使用对称可以有效改善网络加深带来的梯度消失现象。

图 5~图 7 展示了当采样因子为 2 倍、3 倍和 4 倍时,在 Set5 和 Set14 测试集上使用对称残差卷积网络方法和其他 6 种方法进行重建后的图像对比,从主观角度对图像的重建效果进行了展示。可以看出, Bicubic 和 A+ 两种方法所重建的图像比较模糊,锯齿状较为明显,重建效果较差。SRCNN、VDSR、DRCN 和 LapSRN 相较于前两种方法的重建效果较好,但重建图像仍然存在细节不完整,清晰度不够高的问题。在不同采样因子下,使用对称残差卷积网络方法重建 Set5 中 butterfly_GT 图像后的蝴蝶翅膀纹理更加清晰,细节更丰富,结构相似度更高;重建 Set5 数据集中的 bird_GT 图像后的小鸟身体各部位细节信息提取更充分,边缘更清晰,辨识度更高;重建 Set14 中 zebra 图像的峰值信噪比和结构相似度虽略低于 LapSRN,但重建的图像与 LapSRN 算法重建的图像视觉感官上十分接近。同时,相较于其他 5 种方法,该方法重建图像更清晰,整体视觉效果更好。




图 4 在 Set5 测试集上两种方法的峰值信噪比收敛曲线




图 5 Set5 中的 butterfly_GT 采样 2 倍的重建对比图




图 6 Set5 中的 bird_GT 采样 3 倍的重建对比图

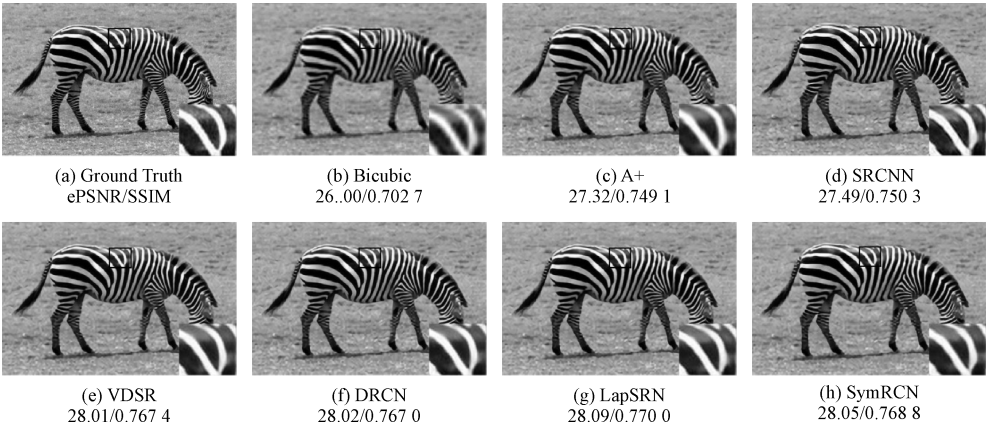


图 7 Set14 中的 zebra 采样 4 倍的重建对比图

表 2 在 Set5、Set14 和 BSD100 数据集上不同超分辨率重建方法的平均 PSNR/SSIM

数据集	采样因子	Bicubic (PSNR /SSIM)	A+ (PSNR /SSIM)	SRCNN (PSNR /SSIM)	VDSR (PSNR /SSIM)	DRCN (PSNR /SSIM)	LapSRN (PSNR /SSIM)	SymRCN (PSNR /SSIM)
Set5	× 2	33.66/0.929 9	36.54/0.954 4	36.66/0.954 2	37.53/0.958 7	37.63/0.958 8	37.52/0.959 1	37.83/0.9598
	× 3	30.39/0.868 2	32.58/0.908 8	32.75/0.909 0	33.66/0.921 3	33.82/0.922 6	33.81/0.922 0	34.00/0.924 6
	× 4	28.42/0.810 4	30.28/0.860 3	30.48/0.862 8	31.35/0.883 8	31.53/0.885 4	31.54/0.885 2	31.53/0.885 5
Set14	× 2	30.24/0.868 8	32.28/0.905 6	32.42/0.906 3	33.03/0.912 4	33.04/0.911 8	32.99/0.912 4	33.22/0.913 7
	× 3	27.55/0.774 2	29.13/0.818 8	29.28/0.820 9	29.77/0.831 4	29.76/0.831 1	29.79/0.832 5	29.88/0.833 8
	× 4	26.00/0.702 7	27.32/0.749 1	27.49/0.750 3	28.01/0.767 4	28.02/0.767 0	28.09/0.770 0	28.05/0.768 8
BSD100	× 2	29.56/0.843 1	31.21/0.886 3	31.36/0.887 9	31.90/0.896 0	31.85/0.894 2	31.80/0.895 2	32.01/0.897 4
	× 3	27.21/0.738 5	28.29/0.783 5	28.41/0.786 3	28.82/0.797 6	28.80/0.796 3	28.82/0.798 0	28.87/0.799 6
	× 4	25.96/0.667 5	26.82/0.708 7	26.90/0.710 1	27.29/0.725 1	27.23/0.723 3	27.32/0.727 5	27.24/0.724 7
平均值		28.78/0.800 4	30.50/0.841 7	30.64/0.843 1	31.26/0.854 9	31.30/0.854 5	31.30/0.855 8	31.40/0.867 5

注:粗体标记数字表示最佳效果。

表 3 在 Set5、Set14 和 BSD100 数据集上不同超分辨率重建方法的平均测试时间 s

数据集	采样因子	Bicubic	A+	SRCNN	VDSR	DRCN	LapSRN	SymRCN
Set5	× 2	0.000	0.623	3.389	0.054	0.735	0.032	0.078
	× 3	0.000	0.400	3.405	0.062	0.748	0.049	0.040
	× 4	0.000	0.281	3.496	0.054	0.735	0.040	0.027
Set14	× 2	0.000	1.370	5.134	0.113	1.579	0.035	0.142
	× 3	0.000	0.790	5.095	0.122	1.569	0.061	0.068
	× 4	0.000	0.630	5.162	0.112	1.526	0.040	0.044
BSD100	× 2	0.000	0.921	3.992	0.071	0.983	0.018	0.092
	× 3	0.000	0.563	4.140	0.071	0.996	0.037	0.044
	× 4	0.000	0.411	3.998	0.071	0.984	0.023	0.028
平均值		0.000	0.665	4.201	0.081	1.095	0.037	0.062

注:粗体标记数字表示最佳效果。

不同图像超分辨率重建方法在 Set5、Set14 和 BSD100 数据集上进行测试的 PSNR 和 SSIM 结果如表 2 所示,从客观角度评价了图像的重建效果。可以看出,VDSR、DRCN 和 LapSRN 这 3 种方法比 Bicubic、A+ 和 SRCNN 这 3 种方法的峰值信噪比和结构相似度值均有提高;由于 SymRCN 方法将对称残差引入到了卷积神经网络中,实现了局部和全局特征融合,SymRCN 方法较 VDSR、DRCN 和 LapSRN 这 3 种方法的平均峰值信噪比值分别提高了 0.14 dB、0.1 dB 和 0.1 dB,平均结构相似度值分别提高了 0.012 6、0.013 0 和 0.011 7,充分证明了该方法的有效性和重建图像质量的可靠性。除了图像质量评价外,测试时间也是评价超分辨率重建质量的一项重要指标,不同方法在 Set5、Set14 和 BSD100 数据集上测试的时间结果如表 3 所示。从表 3 中可以看出,SymRCN 方法的测试时间虽略高于 LapRCN 方法的,但综合峰值信噪比和结构相似度两种评价指标,SymRCN 方法的整体重建效果更好,效率更高,同时相较于其他 5 种比较方法所用平均测试时间较短,实际应用中实时性较好。

4 结束语

文中方法将跳跃连接引入图像超分辨率重建,设计了一种长短跳跃连接网络,提出了基于对称残差卷积神经网络的图像超分辨率重建方法。采用对称残差学习以提升收敛速度,采用长短跳跃连接融合全局与局部分级特征,从而保证网络训练的稳定性。实现了残差块内局部信息的充分利用,有效改善了由网络深度带来的梯度消失;同时实现了残差块外全局特征的融合以弥补网络加深丢失的高频细节。实验结果表明,对称残差卷积神经网络方法的重建效果较传统方法有明显的优势,重建图像的视觉效果更贴近人眼感官要求,充分证明了该方法的有效性和实用性。在后续的研究中,将尝试继续拓宽网络宽度和深度以进一步改进网络,寻求其他优化方法以进一步提高重建质量。

参考文献:

[1] 胡长胜,詹曙,吴从中.基于深度特征学习的图像超分辨率重建[J].自动化学报,2017,43(5):814-821.
HU Changsheng,ZHAN Shu,WU Congzhong.Image Super-resolution Based on Deep Learning Features[J].Acta Automatica Sinica,2017,43(5):814-821.

[2] 李欣,韦宏卫,张洪群.结合深度学习的单幅遥感图像超分辨率重建[J].中国图象图形学报,2018,23(2):209-218.
LI Xin,WEI Hongwei,ZHANG Hongqun.Super-resolution Reconstruction of Single Remote Sensing Image Combined with Deep Learning[J].Journal of Image and Graphics,2018,23(2):209-218.

[3] REN H Y,EL-KHAMY M,LEE J.CT-SRCNN:Cascade Trained and Trimmed Deep Convolutional Neural Networks for Image Super Resolution[C]//Proceedings of the 2018 IEEE Winter Conference on Applications of Computer Vision.

- Piscataway : IEEE , 2018 : 1423-1431 .
- [4] ZOU W W W , YUEN P C . Very Low Resolution Face Recognition Problem [J] . IEEE Transactions on Image Processing , 2012 , 21(1) : 327-340 .
- [5] KARRAS T , AILA T , LAINE S , et al . Progressive Growing of GANs for Improved Quality , Stability , and Variation [CA/OL] . [2018-12-20] . <https://www.researchgate.net/publication/320707565> .
- [6] HARRIS J L . Diffraction and Resolving Power[J] . Journal of the Optical Society of America , 1964 , 54(7) : 931-936 .
- [7] ZHU S , ZENG B , LIU G , et al . Image Interpolation Based on Non-local Geometric Similarities[C]//Proceedings of the 2015 IEEE International Conference on Multimedia and Expo . Washington : IEEE Computer Society , 2015 : 7177417 .
- [8] ZHANG K , GAO X , TAO D , et al . Single Image Super-resolution with Non-local Means and Steering Kernel Regression [J] . IEEE Transactions on Image Processing , 2012 , 21(11) : 4544-4556 .
- [9] DONG C , LOY C C , HE K , et al . Image Super-resolution Using Deep Convolutional Networks[J] . IEEE Transactions on Pattern Analysis and Machine Intelligence , 2016 , 38(2) : 295-307 .
- [10] 王世平 , 毕笃彦 , 刘坤 , 等 . 一种多映射卷积神经网络的超分辨率重建算法[J] . 西安电子科技大学学报 , 2018 , 45(4) : 155-160 .
- WANG Shiping , BI Duyan , LIU Kun , et al . Multi-mapping Convolution Neural Network for the Image Super-resolution Algorithm[J] . Journal of Xidian University , 2018 , 45(4) : 155-160 .
- [11] YANG J C , WRIGHT J , HUANG T S , et al . Image Super-resolution as Sparse Representation of Raw Image Patches [C]// Proceedings of the 2008 26th IEEE Conference on Computer Vision and Pattern Recognition . Washington : IEEE Computer Society , 2008 : 4587647 .
- [12] YANG J C , WRIGHT J , HUANG T S , et al . Image Super-resolution via Sparse Representation[J] . IEEE Transactions on Image Processing , 2010 , 19(11) : 2861-2873 .
- [13] TIMOFTE R , DE V , GOOL L V . Anchored Neighborhood Regression for Fast Example-based Super-resolution[C]// Proceedings of the 2013 IEEE International Conference on Computer Vision . Piscataway : IEEE , 2013 : 1920-1927 .
- [14] TIMOFTE R , DE S V , VAN G L . A+ : Adjusted Anchored Neighborhood Regression for Fast Super-resolution[C]// Lecture Notes in Computer Science : 9006 . Heidelberg : Springer Verlag , 2015 : 111-126 .
- [15] ZHANG H , PATEL V M . Densely Connected Pyramid Dehazing Network[C]//Proceedings of the 2018 IEEE Computer Society Conference on Computer Vision and Pattern Recognition . Washington : IEEE Computer Society , 2018 : 3194-3203 .
- [16] ZHANG H , PATEL V M . Density-aware Single Image De-raining Using a Multi-stream Dense Network [C]// Proceedings of the 2018 IEEE Computer Society Conference on Computer Vision and Pattern Recognition . Washington : IEEE Computer Society , 2018 : 695-704 .
- [17] 张金刚 , 方圆 , 袁豪 , 等 . 一种识别表情序列的卷积神经网络[J] . 西安电子科技大学学报 , 2018 , 45(1) : 150-155 .
- ZHANG Jingang , FANG Yuan , YUAN Hao , et al . Multiple Convolutional Neural Networks for Facial Expression Sequence Recognition[J] . Journal of Xidian University , 2018 , 45(1) : 150-155 .
- [18] 许强 , 李伟 , 占荣辉 , 等 . 一种改进的卷积神经网络 SAR 目标识别算法[J] . 西安电子科技大学学报 , 2018 , 45(5) : 177-183 .
- XU Qiang , LI Wei , ZHAN Ronghui , et al . Improved Algorithm for SAR Target Recognition Based on the Convolutional Neural Network[J] . Journal of Xidian University , 2018 , 45(5) : 177-183 .
- [19] KIM J , LEE J K , LEE K M . Accurate Image Super-resolution Using Very Deep Convolutional Networks [C]// Proceedings of the 2016 IEEE Computer Society Conference on Computer Vision and Pattern Recognition . Washington : IEEE Computer Society , 2016 : 1646-1654 .
- [20] KIM J , LEE J K , LEE K M . Deeply-recursive Convolutional Network for Image Super-resolution[C]//Proceedings of the 2016 IEEE Computer Society Conference on Computer Vision and Pattern Recognition . Washington : IEEE Computer Society , 2016 : 1637-1645 .
- [21] LAI W S , HUANG J B , AHUJA N , et al . Deep Laplacian Pyramid Networks for Fast and Accurate Super-resolution [C]// Proceedings of the 2017 30th IEEE Conference on Computer Vision and Pattern Recognition . Piscataway : IEEE , 2017 : 5835-5843 .
- [22] TAI Y , YANG J , LIU X . Image Super-resolution via Deep Recursive Residual Network[C]//Proceedings of the 2017

- 30th IEEE Conference on Computer Vision and Pattern Recognition . Piscataway : IEEE , 2017 : 2790-2798 .
- [23] MAO X J , SHEN C H , YANG Y B . Image Restoration Using Very Deep Convolutional Encoder-decoder Networks with Symmetric Skip Connections[C]//Advances in Neural Information Processing Systems 29 - Proceedings of the 2016 Conference . Vancouver : Neural Information Processing Systems Foundation , 2016 : 2810-2818 .
- [24] HE K , ZHANG X , REN S , et al . Deep Residual Learning for Image Recognition[C]//Proceedings of the 2016 IEEE Computer Society Conference on Computer Vision and Pattern Recognition . Washington : IEEE Computer Society , 2016 : 770-778 .
- [25] 陈建廷 , 向阳 . 深度神经网络训练中梯度不稳定现象研究综述[J] . 软件学报 , 2018 , 29(7) : 2071-2091 .
CHEN Jianting , XIANG Yang . Survey of Unstable Gradients in Deep Neural Network Training [J] . Journal of Software , 2018 , 29(7) : 2071-2091 .
- [26] TAI Y , YANG J , LIU X . Image Super-resolution via Deep Recursive Residual Network[C]//Proceedings of the 2017 30th IEEE Conference on Computer Vision and Pattern Recognition . Piscataway : IEEE , 2017 : 2790-2798 .
- [27] LIM B , SON S , KIM H , et al . Enhanced Deep Residual Networks for Single Image Super-resolution[C]//Proceedings of the 2017 IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops . Washington : IEEE Computer Society , 2017 : 1132-1140 .
- [28] AHN N , KANG B , SOHN K A . Fast , Accurate , and Lightweight Super-resolution with Cascading Residual Network [C]// Lecture Notes in Computer Science : 11214 . Heidelberg : Springer Verlag , 2018 : 256-272 .
- [29] ZHANG Y , LI K P , LI K , et al . Image Super-resolution Using Very Deep Residual Channel Attention Networks[C]//Lecture Notes in Computer Science : 11211 . Heidelberg : Springer Verlag , 2018 : 294-310 .
- [30] LI J C , FANG F M , MEI K F , et al . Multi-scale Residual Network for Image Super-resolution[C]//Lecture Notes in Computer Science : 11212 . Heidelberg : Springer Verlag , 2018 : 527-542 .
- [31] 孙跃文 , 李立涛 , 丛鹏 , 等 . 基于深度学习的辐射图像超分辨率重建方法[J] . 原子能科学技术 , 2017 , 51(5) : 890-895 .
SUN Yuewen , LI Litao , CONG Peng , et al . Super-resolution Method for Radiation Image Based on Deep Learning[J] . Atomic Energy Science and Technology , 2017 , 51(5) : 890-895 .
- [32] MARTIN D , FOWLKES C , TAL D , et al . A Database of Human Segmented Natural Images and Its Application to Evaluating Segmentation Algorithms and Measuring Ecological Statistics[C]//Proceedings of the 2001 IEEE International Conference on Computer Vision . Piscataway : IEEE , 2001 : 416-423 .
- [33] JIA Y , SHELHAMER E , DONAHUE J , et al . Caffe : Convolutional Architecture for Fast Feature Embedding[C]//Proceedings of the 2014 ACM Conference on Multimedia . New York : ACM , 2014 : 675-678 .
- [34] HUANG J B , SINGH A , AHUJA N . Single Image Super-resolution from Transformed Self-exemplars[C]//Proceedings of the 2015 IEEE Computer Society Conference on Computer Vision and Pattern Recognition . Washington : IEEE Computer Society , 2015 : 5197-5206 .
- [35] 李浪宇 , 苏卓 , 石晓红 , 等 . 图像超分辨率重建中的细节互补卷积模型[J] . 中国图象图形学报 , 2018 , 23(4) : 572-582 .
LI Langyu , SU Zhuo , SHI Xiaohong , et al . Mutual-detail Convolution Model for Image Super-resolution Reconstruction [J] . Journal of Image and Graphics , 2018 , 23(4) : 572-582 .
- [36] HE K , ZHANG X , REN S , et al . Delving Deep into Rectifiers : Surpassing Human-level Performance on Imagenet Classification[C]//Proceedings of the 2015 IEEE International Conference on Computer Vision . Piscataway : IEEE , 2015 : 1026-1034 .

(编辑 : 齐淑娟)