

## 基于加速残差网络的图像超分辨率重建方法

梁 敏\*, 王昊榕, 张 瑶, 李 杰

(山西财经大学 信息学院, 太原 030006)

(\* 通信作者电子邮箱 liangmin716@163.com)

**摘 要:**针对深层网络架构的图像超分辨率重建任务中存在网络参数多、计算复杂度高等问题,提出了一种基于加速残差网络的图像超分辨率重建方法。首先,构建一个残差网络对低分辨率图像与高分辨率图像之间的高频残差信息进行重建,以减少冗余信息的深层网络传输过程,提高重建效率;然后,通过特征收缩层对提取的低分辨率特征图进行降维,从而以较少的网络参数实现快速映射;之后,对高分辨率特征图通过特征扩展层进行升维,从而以较丰富的信息重建高频残差信息;最后,将残差与低分辨率图像求和得到重建的高分辨率图像。实验结果表明,该方法取得的峰值信噪比(PSNR)及结构相似性(SSIM)均值结果较基于卷积神经网络的图像超分辨率(SRCNN)取得的结果分别提升了0.57 dB和0.013 3,较基于中间层监督卷积神经网络的图像超分辨率重建(ISCNN)取得的结果分别提升了0.45 dB和0.006 7;在重建速度方面,以数据集Urban100为例,较现有方法提高了1.5~42倍。此外,将该方法应用于运动模糊图像的超分辨率重建时,获得了优于超深卷积神经网络的图像超分辨率(VDSR)的性能。所提方法以较少的网络参数快速获得较好的重建质量,并且为图像超分辨率重建提供了新的思路。

**关键词:**卷积神经网络;超分辨率重建;残差学习;收缩层;扩展层

**中图分类号:**TP391.41 **文献标志码:**A

### Image super-resolution reconstruction method based on accelerated residual network

LIANG Min\*, WANG Haorong, ZHANG Yao, LI Jie

(School of Information, Shanxi University of Finance and Economics, Taiyuan Shanxi 030006, China)

**Abstract:** To solve the problems of multiple network parameters and high computational complexity in image super-resolution reconstruction of deep network architecture, an image super-resolution reconstruction method based on accelerated residual network was proposed. Firstly, a residual network was constructed to reconstruct the high-frequency residual information between low-resolution image and high-resolution image, so as to reduce the deep network transmission process of redundant information and improve the reconstruction efficiency. Secondly, the dimensionality of the extracted low-resolution feature map was reduced by the feature shrinking layer to realize fast mapping with fewer network parameters. Thirdly, the dimensionality of the high-resolution feature map was increased by the feature expanding layer to reconstruct the high-frequency residual information with the rich information. Finally, the residual and low-resolution images were summed to obtain the reconstructed high-resolution image. Experimental results show that the Peak Signal-to-Noise Ratio (PSNR) and the Structural SIMilarity (SSIM) mean results obtained by the proposed method are 0.57 dB and 0.013 3 higher than those obtained by Super-Resolution using Convolutional Neural Network (SRCNN) respectively, and 0.45 dB and 0.006 7 higher than those obtained by Intermediate Supervision Convolutional Neural Network (ISCNN). In terms of reconstruction speed, using dataset Urban100 as example, the proposed method is 1.5 to 42 times faster than the existing methods. In addition, when this method is applied to the super-resolution reconstruction of motion blur images, it has the performance better than image Super-Resolution using Very Deep convolutional network (VDSR). The proposed method achieves better reconstruction quality with fewer network parameters and provides a new idea for image super-resolution reconstruction.

**Key words:** Convolutional Neural Network (CNN); super-resolution reconstruction; residual learning; shrinking layer; expanding layer

## 0 引言

图像在采集、传输过程中受设备、光照等环境影响,直接降低了图像的质量。数字图像超分辨率(Super-Resolution, SR)旨在通过某种模型约束条件由低分辨率(Low Resolution, LR)图

像重建清晰的高分辨率(High Resolution, HR)图像,在公共安全、视频监控、医学图像处理<sup>[1-3]</sup>等方面具有强烈的需求。但根据有限的图像信息重建出更多信息是一个病态过程,所以图像超分辨率重建研究始终是一个具有挑战性的任务。

目前,图像超分辨率重建是前沿热门领域,吸引了越来越

**收稿日期:**2020-09-30; **修回日期:**2020-11-15; **录用日期:**2020-12-03。 **基金项目:**国家自然科学基金资助项目(61801279);山西省应用基础研究项目(201801D221160);山西省研究生教育创新项目(2020SY176, 2020SY175)。

**作者简介:**梁敏(1979—),女,山西忻州人,副教授,博士,CCF会员,主要研究方向:图像处理、模式识别;王昊榕(1996—),女,山西大同人,硕士研究生,主要研究方向:计算机视觉、三维超分辨重建;张瑶(1994—),女,山西临汾人,硕士研究生,主要研究方向:图像处理、模式识别;李杰(1986—),男,四川邛崃人,副教授,博士,CCF会员,主要研究方向:计算机视觉、三维超分辨计算。

多的学者参与研究,并发表了众多有意义的工作,其中,具有代表性的有:Yang等<sup>[4]</sup>提出的基于稀疏编码表示的超分辨率方法(Sparse-coding-based Super-Resolution, ScSR),Timofte等<sup>[5]</sup>提出的可调整锚定邻域回归方法(Adjusted Anchored neighborhood regression for fast super-resolution, A+)。近年来,基于深度学习的超分辨率方法表现出良好的性能。Dong等<sup>[6]</sup>提出了基于卷积神经网络的图像超分辨率重建(Super-Resolution using Convolutional Neural Network, SRCNN)方法,将卷积神经网络应用于超分辨率,实现了以低分辨率图像作为输入、高分辨率图像作为输出的端到端映射的重建模型。Wang等<sup>[7]</sup>将传统的稀疏编码模型与深度学习相结合,提出了基于稀疏编码的网络(Sparse-Coding-based Network, SCN)。Dong等<sup>[8]</sup>修改了SRCNN模型,提出了加速的超分辨率卷积神经网络(Fast Super-Resolution Convolutional Neural Network, FSRCNN),通过在网络末端添加反卷积层替代SRCNN初始上采样操作,使得不同比例缩放因子可以共享卷积层权重,提升了重建速度。Kim等<sup>[9]</sup>应用残差学习并结合可调梯度裁剪策略提出了超深卷积神经网络的图像超分辨率方法(Super-Resolution using Very Deep convolutional network, VDSR)。李现国等<sup>[10]</sup>设计了具有中间层监督的网络模型(Intermediate Supervision Convolutional Neural Network, ISCNN),借助监督层误差函数来改善网络梯度消失现象。刘月峰等<sup>[11]</sup>先对低分辨率图像进行三种插值操作,然后进行五种不同强度的锐化操作,最后将图像合并排列成三维矩阵,以此作为网络的多通道输入。Wang等<sup>[12]</sup>设计了一个通过深层和浅层卷积网络实现端到端映射的超分辨率模型(End-to-End Deep and Shallow convolutional network, EEDS),由浅层通道重建图像的主要结构,深层通道重建图像的高频细节。上述方法仍存在的问题是:浅层网络不能充分提取图像的特征,有重建质量不高的天然缺陷;而深层网络参数量大、计算复杂度高、重建效率低。

针对上述问题,本文提出一种基于加速残差网络的图像超分辨率重建方法(image Super-Resolution reconstruction method based on Accelerated residual network, ADSR)。该方法对低分辨率图像与高分辨率图像之间的高频残差信息运用加速残差网络进行训练,将低分辨率图像与网络学到的残差相加得到重建图像。主要贡献包括:

1)构建一个残差网络对低分辨率图像与高分辨率图像之间的高频残差信息进行重建,避免低分辨率图像携带的低频信息在深层网络中的冗余学习,将网络主要用于高频残差信息的训练,从而提高效率。

2)在非线性映射前加入收缩层,对提取的低分辨率图像的特征图维数进行降维,能够减少深层网络参数,提高时间效率,以较少的网络参数快速获得较好的重建质量。

3)探索ADSR网络模型在运动模糊图像超分辨率重建上的有效性,在多种模糊核下均取得了较现有方法更好的视觉效果和客观量化指标。

## 1 ADSR 网络

为了解决利用深层网络进行超分辨率重建中存在的网络参数多、计算复杂度高等问题,本文构建了一个ADSR网络模型。在本章中,将其视为由低分辨率图像到高分辨率图像的端到端映射过程,并划分为六部分介绍:低分辨率特征提取、特征收缩、非线性映射、高分辨率特征扩展、高频残差信息重建以及残差求和。图1给出了ADSR的网络框架。ADSR整体是一个残差网络,其主要目的是对低分辨率图像缺失的高频细节部分进行重建,提高边缘及纹理信息的重建精度。在局部上将端到端的非线性映射部分更细致地划分成特征收缩、非线性映射、高分辨率特征扩展这三个部分,降低了深层网络传输过程中低分辨率特征图的维度,从而降低模型复杂度。

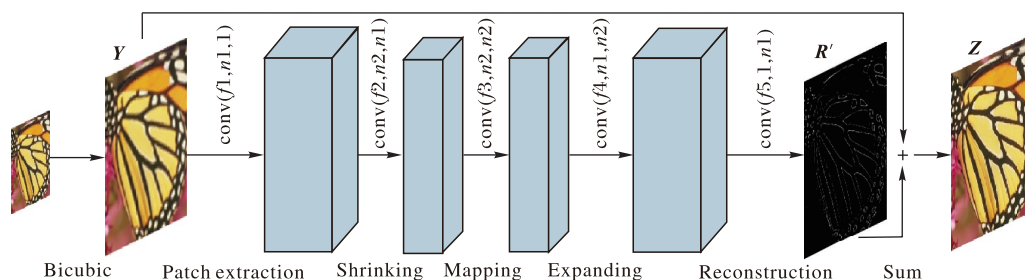


图1 ADSR网络架构

Fig. 1 ADSR network architecture

### 1.1 低分辨率特征提取

单幅低分辨率图像重建时,首先将该低分辨率图像采用双三次插值方法(Bicubic)上采样到要重建的高分辨率图像尺寸,得到初始的上采样低分辨率图像Y作为网络的输入,网络的目标是将Y尽可能地恢复出与真值高分辨率图像X相似的重建图像Z。利用一组滤波器对低分辨率图像Y进行卷积操作提取出丰富的图像特征,其中每一个滤波器对应得到一张特征图。将该层结构表示为 $F_1(Y) = W_1 * Y + B_1$ , $W_1$ 和 $B_1$ 分别表示滤波器的权重以及偏差,“\*”表示卷积操作, $W_1$ 对应 $n_1$ 个尺寸为 $f_1 \times f_1$ 的滤波器,即经过特征提取层能够提取出 $n_1$ 张特征图。该部分如图1中的Patch extraction所示。

### 1.2 特征收缩

在超分辨率重建任务中,把从低分辨率特征提取层 $F_1$ 提

取到的特征图进行非线性映射得到用于重建高分辨率图像对应的高分辨率特征图。然而在特征提取层中为了获得图像的丰富特征,特征维数 $n_1$ 通常较大,再将这些特征传入多层非线性映射结构时会产生较多的参数,时间复杂度较高。

ADSR在非线性映射前加入了特征收缩层将特征图维数从 $n_1$ 维降至 $n_2$ 维。该层结构表示为 $F_2(Y) = W_2 * F_1(Y) + B_2$ , $W_2$ 和 $B_2$ 分别表示滤波器的权重以及偏差, $W_2$ 对应 $n_2$ 个尺寸为 $f_2 \times f_2$ 的滤波器,且 $n_2 < n_1$ ,即经过特征收缩层将特征图维数降至 $n_2$ 。该部分如图1中的Shrinking所示。

### 1.3 非线性映射

通过低分辨率特征提取及特征收缩后得到了低分辨率图像的特征图,将这些特征图进行非线性映射能够得到用于重建高分辨率图像对应的高分辨率特征图,所以非线性映

射结构对重建质量发挥着关键的作用。ADSR使用多层小尺寸滤波器串联的架构来获得较大的图像感受野,有利于提高重建质量。将非线性映射部分的当前层数表示为 $i$ ,其结构表示如式(1)所示:

$$F3_i(Y) = \begin{cases} W3_i * F2(Y) + B3_i & i = 1 \\ W3_i * F3_{i-1}(Y) + B3_i & 1 < i \leq M \end{cases} \quad (1)$$

其中: $W3_i$ 和 $B3_i$ 表示第 $i$ 层滤波器的权重以及偏差, $M$ 表示非线性映射部分的总层数,其值将在实验部分讨论确定。该部分如图1中的Mapping所示。

#### 1.4 高分辨率特征扩展

为了减少网络参数,在非线性映射前应用了特征收缩层进行降维,但直接使用 $n2$ 维特征进行重建得到的图像质量不高,所以要在非线性映射之后、重建之前加入扩展层将特征图维数从 $n2$ 维升回至 $n1$ 维。表示为 $F4(Y) = W4 * F3_i(Y) + B4$ ,其中 $i=M$ , $W4$ 和 $B4$ 分别表示滤波器的权重以及偏差, $W4$ 对应 $n1$ 个尺寸为 $f4 \times f4$ 的滤波器,即经过特征扩展层将高分辨率特征图维数升至 $n1$ 。该部分如图1中的Expanding所示。

#### 1.5 高频残差信息重建

深层超分辨率重建网络主要完成两个任务:一是将低分辨率图像 $Y$ 已有的信息从网络层的输入端输送至输出端;二是重建低分辨率图像与真值高分辨率图像之间的差值部分 $R$ ,即 $R = X - Y$ 。在超分辨率重建任务中,要重建的信息远少于低分辨率和高分辨率图像已有的公共信息,所以任务一将耗费网络极大的资源,而真正用于任务二的资源较少。另外输入端信息 $Y$ 在网络中进行传输学习时随着网络结构加深,容易出现细节丢失的问题。

ADSR构建了一个残差网络对低分辨率图像与高分辨率图像之间的高频残差信息进行重建。残差结构能够避免信息 $Y$ 的深层网络传送过程,将网络主要用在高频残差信息 $R$ 的重建上。ADSR将 $n1$ 维高分辨率特征图进行融合生成的一维图像,即为重建出的高频残差图像。表示为 $R' = W5 * F4(Y) + B5$ , $W5$ 和 $B5$ 分别表示滤波器的权重以及偏差, $W5$ 对应1个尺寸为 $f5 \times f5$ 的滤波器。该部分如图1中Reconstruction所示。

#### 1.6 残差求和

本文构建的残差网络框架在训练时以上采样低分辨率图像 $Y$ 作为输入,将由残差网络获得的高频残差图像 $R'$ 与低分辨率图像 $Y$ 相加得到的重建高分辨率图像 $Z$ 作为输出,以均方误差(Mean Squared Error, MSE)作为网络模型的损失函数,如式(2)所示,式中 $n$ 表示训练集的样本数目。

$$L = \frac{1}{n} \sum_{i=1}^n \|X - Z\|^2 \quad (2)$$

图2显示了set5数据集中butterfly图像的上采样低分辨率图像 $Y$ ,重建的残差图像 $R'$ 以及最终生成的高分辨率图像 $Z$ 。



图2 butterfly图像超分辨率重建过程

Fig.2 Super-resolution reconstruction process of butterfly image

综上所述,基于加速残差网络的图像超分辨率重建方法的过程如图3所示,分为以下步骤:

- 1)对输入的低分辨率图像进行双三次插值处理,获得上采样的低分辨率图像 $Y$ ;
- 2)提取代表图像 $Y$ 高频信息的 $n1$ 张低分辨率特征图;
- 3)通过特征收缩层将其降维至 $n2$ ;
- 4)经过非线性映射层得到对应的 $n2$ 张高分辨率特征图;
- 5)通过特征扩展层将其升维至 $n1$ ;
- 6)由 $n1$ 张高分辨率特征图重建出高分辨率残差图像 $R'$ ;
- 7)将 $R'$ 与 $Y$ 相加获得最终重建的高分辨率图像 $Z$ 。

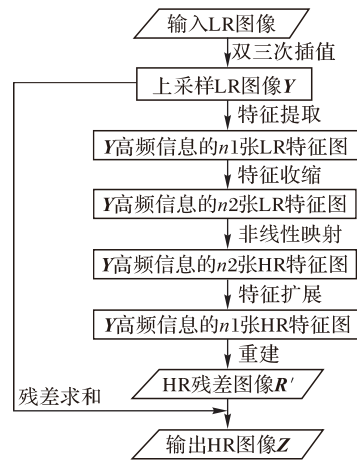


图3 ADSR技术路线

Fig.3 ADSR technology roadmap

## 2 实验

### 2.1 实现细节

#### 2.1.1 训练集与测试集

**训练集** 本文实验基于随机森林学习(Random Forest Learning, RFL)<sup>[13]</sup>的超分辨率方法使用的291张图片,采用数据增强的方法,对图像旋转90°、180°、270°,并缩小0.6倍以及0.8倍,得到3492张图片作为训练集。采用43的步长将数据集切割成43×43的图像块,混合多比例因子2、3、4数据集将获得大约38万张的图像块用于网络训练。

**测试集** 采用set5<sup>[14]</sup>、set14<sup>[15]</sup>、BSD100<sup>[16]</sup>以及Urban100<sup>[17]</sup>四个数据集作为测试集。

#### 2.1.2 训练细节

ADSR网络结构以MSE作为损失函数,表示重建的高分辨率图像与真值图像之间的差异,选用Adam(Adam optimization)算法来优化损失函数。训练的初始学习率设置为0.0001,权重衰减系数设置为0.0001,滤波器的权重采用He等<sup>[18]</sup>提出的方法进行初始化。训练的批大小设置为128,模型训练了超过200个epoch。网络在硬件参数NVIDIA GeForce GTX 1060下使用caffe工具以及Matlab R2017b接口进行训练及测试。

#### 2.1.3 评价指标

为了定量表示重建结果并与其他方法进行对比,本文采用峰值信噪比(Peak Signal-to-Noise Ratio, PSNR)及结构相似性(Structural SIMilarity, SSIM)作为重建效果评价标准。PSNR值越大代表与真值图像相比重建图像失真越少,SSIM值越大代表重建图像与真值图像的结构相似性越高。



2.2 网络参数设置研究

2.2.1 不同层数设置

ADSR 加入特征收缩层减少网络参数势必会以降低重建质量为代价,所以考虑增加网络层数来降低质量的损失,因此设置了实验对合适的网络层数进行探讨,先以 22 层网络结构

作为基础,之后通过增加  $M$  讨论选定 ADSR 最终的层数。

表 1 显示了 ADSR 在  $n_1=64$ 、 $n_2=32$ ,网络层数分别为 22、23、24、25 以及 26 的各测试集的 PSNR 及 SSIM 均值结果(其中加粗表示最高值)。通过分析不同层数的重建结果,选定层数较小且重建质量较好的 24 层为默认的层数。

表 1 测试集在不同层数设置下的 PSNR 及 SSIM 均值

Tab. 1 Mean values of PSNR/SSIM of test sets under different layer configurations

数据集	比例因子	层数=22		层数=23		层数=24		层数=25		层数=26	
		PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM
set5	×2	37. 31	0. 958 1	37. 22	0. 958 2	37. 17	<b>0. 958 2</b>	37. 21	0. 957 9	37. 20	0. 957 5
	×3	33. 45	0. 919 3	33. 45	0. 920 0	<b>33. 50</b>	<b>0. 920 3</b>	33. 44	0. 919 6	33. 34	0. 917 7
	×4	31. 14	0. 878 5	31. 08	0. 879 3	<b>31. 19</b>	<b>0. 880 7</b>	31. 15	0. 879 7	30. 97	0. 876 5
set14	×2	32. 80	0. 910 9	32. 78	0. 910 9	32. 76	<b>0. 911 7</b>	<b>32. 81</b>	0. 911 0	32. 75	0. 910 1
	×3	29. 66	0. 827 9	29. 65	0. 829 9	<b>29. 68</b>	<b>0. 830 2</b>	29. 62	0. 828 8	29. 58	0. 826 1
	×4	27. 85	0. 761 3	27. 83	0. 763 8	<b>27. 91</b>	<b>0. 764 0</b>	27. 84	0. 762 8	27. 82	0. 759 7
B100	×2	31. 73	0. 893 6	31. 71	0. 893 9	31. 69	<b>0. 894 9</b>	<b>31. 73</b>	0. 893 8	31. 69	0. 893 0
	×3	28. 70	0. 793 6	28. 71	0. 796 2	<b>28. 74</b>	<b>0. 796 2</b>	28. 72	0. 794 9	28. 65	0. 791 8
	×4	27. 17	0. 720 4	27. 17	<b>0. 723 5</b>	<b>27. 20</b>	0. 722 7	27. 19	0. 721 9	27. 13	0. 718 4
Urban100	×2	<b>30. 36</b>	0. 909 5	30. 35	0. 909 5	30. 31	<b>0. 910 1</b>	30. 34	0. 909 5	30. 20	0. 907 1
	×3	26. 84	0. 818 9	26. 89	<b>0. 822 0</b>	<b>26. 91</b>	0. 821 8	26. 88	0. 821 0	26. 72	0. 815 4
	×4	24. 94	0. 741 4	24. 97	<b>0. 745 0</b>	<b>25. 00</b>	0. 743 9	24. 98	0. 743 4	24. 84	0. 737 1

2.2.2 不同滤波器个数设置

本文将低分辨率特征提取部分的滤波器个数  $n_1$  设置为 64,即通过特征提取层提取出代表低分辨率图像特征的 64 张特征图。在进行收缩时考虑将其降为 16 维、32 维以及 48 维。表 2 显示了在 24 层网络架构上( $n_1, n_2$ )设置为(64, 16)、(64, 32)及(64, 48)的各测试集的 PSNR 及 SSIM 均值结果(其中加粗的值表示最高值)。通过分析不同设置下的重建结果,选定重建质量较好的(64, 48)为默认的滤波器个数。

表 2 测试集在不同滤波器个数  $n_1, n_2$  设置下的 PSNR 及 SSIM 均值

Tab. 2 Mean values of PSNR/SSIM of test sets under different filter number  $n_1, n_2$  configurations

数据集	比例因子	$(n_1, n_2)=(64, 16)$		$(n_1, n_2)=(64, 32)$		$(n_1, n_2)=(64, 48)$	
		PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM
set5	×2	36. 28	0. 953 5	37. 17	0. 958 2	<b>37. 36</b>	<b>0. 958 4</b>
	×3	32. 31	0. 905 9	33. 50	0. 920 3	<b>33. 59</b>	<b>0. 920 8</b>
	×4	29. 94	0. 853 3	31. 19	0. 880 7	<b>31. 19</b>	<b>0. 881 2</b>
set14	×2	32. 14	0. 903 9	32. 76	<b>0. 911 7</b>	<b>32. 86</b>	0. 911 5
	×3	29. 01	0. 816 5	<b>29. 68</b>	<b>0. 830 2</b>	29. 67	0. 829 6
	×4	27. 11	0. 742 9	<b>27. 91</b>	<b>0. 764 0</b>	27. 88	0. 763 2
B100	×2	31. 17	0. 884 7	31. 69	<b>0. 894 9</b>	<b>31. 78</b>	0. 894 5
	×3	28. 24	0. 782 1	<b>28. 74</b>	<b>0. 796 2</b>	28. 73	0. 795 5
	×4	26. 70	0. 704 8	27. 20	<b>0. 722 7</b>	<b>27. 20</b>	0. 721 9
Urban 100	×2	29. 02	0. 890 6	30. 31	0. 910 1	<b>30. 44</b>	<b>0. 910 7</b>
	×3	25. 81	0. 789 3	26. 91	0. 821 8	<b>26. 92</b>	<b>0. 822 5</b>
	×4	24. 06	0. 704 3	25. 00	0. 743 9	<b>25. 00</b>	<b>0. 744 7</b>

2.2.3 不同比例因子设置

为解决一个神经网络模型只适用于单一比例因子的问

题,本文将原始训练集按多种倍数比例因子进行缩放并融合成大的训练集,使得训练得到的模型适用于所有训练集中包含的比例因子,提高网络模型的泛化能力。表 3 和表 4 显示了层数为 24,滤波器个数为(64, 48)的网络结构在不同训练集下得到的模型的 set5 数据集的 PSNR 及 SSIM 结果,其中加粗的值表示测试比例因子包含在训练集的比例因子中。

实验结果显示单比例因子训练集的模型无法处理其他比例因子重建问题,有时重建效果甚至比双三次插值方法效果还差。以缩放比例因子 2 下的测试集重建结果为例,其在比例因子 2 训练集的模型下的 PSNR 值为 37. 55,在比例因子 3 训练集的模型下的 PSNR 值为 30. 92,在比例因子 4 训练集的模型下的 PSNR 值为 25. 67,而用双三次插值方法得到的 PSNR 值为 33. 66。

相比单比例因子训练集来说,混合比例因子训练集下的模型可以有效处理所有预定义比例因子的重建问题,且能使大比例因子测试集的重建效果得到增强。以表 3 中(×2, 3, 4)训练集模型下的各尺度 PSNR 值与对应的各单比例因子训练集的模型的 PSNR 值对比为例:37. 36(×2, 3, 4)-37. 55(×2)、33. 59(×2, 3, 4)-33. 47(×3)、31. 19(×2, 3, 4)-31. 00(×4)。

另外对于大比例因子 3 和 4 来说训练集涉及的预定义比例因子越多,模型重建的增强效果就越明显。以缩放比例因子 4 下的测试集重建结果为例,其在单比例因子 4 训练集的模型下的 PSNR 值为 31. 00,在混合比例因子(×2, 4)训练集的模型下的 PSNR 值为 31. 14,(×3, 4)训练集的模型下的 PSNR 值为 31. 06,(×2, 3, 4)训练集的模型下的 PSNR 值为 31. 19。

表 3 不同比例因子模型对 PSNR 均值的影响

Tab. 3 Influence of different scale factor models on mean value of PSNR

测试集	训练集比例因子							Bicubic
	比例因子	×2	×3	×4	(×2, 3)	(×2, 4)	(×3, 4)	
set5	×2	37. 55	30. 92	25. 67	<b>37. 43</b>	<b>37. 32</b>	32. 19	33. 66
	×3	30. 49	<b>33. 47</b>	29. 54	<b>33. 52</b>	30. 35	<b>33. 47</b>	30. 39
	×4	28. 45	28. 80	<b>31. 00</b>	28. 80	<b>31. 14</b>	<b>31. 06</b>	28. 42

表 4 不同比例因子模型对 SSIM 均值的影响

Tab. 4 The influence of different scale factor models on mean value of SSIM

测试集 比例因子	训练集比例因子							Bicubic
	×2	×3	×4	(×2,3)	(×2,4)	(×3,4)	(×2,3,4)	
×2	<b>0.959 0</b>	0.914 2	0.822 2	<b>0.958 8</b>	<b>0.958 3</b>	0.927 1	<b>0.958 4</b>	0.929 9
×3	0.873 1	<b>0.920 0</b>	0.880 2	<b>0.920 1</b>	0.889 8	<b>0.918 8</b>	<b>0.920 8</b>	0.868 2
×4	0.811 2	0.825 4	<b>0.876 7</b>	0.824 0	<b>0.879 2</b>	<b>0.877 7</b>	<b>0.881 2</b>	0.810 4

2.3 与现有方法比较

2.3.1 重建质量的比较

为了反映 ADSR 的重建效果, 本文将它与 Bicubic、ScSR<sup>[4]</sup>、A+<sup>[5]</sup>以及近来国内外提出的基于深度学习的方法 SRCNN<sup>[6]</sup>、SCN<sup>[7]</sup>、FSRCNN<sup>[8]</sup>、VDSR<sup>[9]</sup>、ISCNN<sup>[10]</sup>、刘月峰等<sup>[11]</sup>方法以及 EEDS<sup>[12]</sup>进行比较。其中, 所有对比方法的重建结果都使用原作者提供的数据或原作者发布的源代码生成的数据。本文方法选择在层数为 24、滤波器个数为 (64, 48)、数据集为

(×2,3,4)混合比例因子融合下的重建结果。图 4 列出了 set14 数据集中 comic 图像在比例因子为 3 时多种方法下的重建图像以及 PSNR 值。从中可以看出, ADSR 方法在边缘处及高频细节处的重建效果更为突出, 且整体结构与原图更为接近。

表 5、6 分别显示了 ADSR 与这些方法在 set5、set14、B100 及 Urban100 四个测试集下的 PSNR 和 SSIM 均值, 其中加粗标注的值表示最高值, 下划线标注的值表示次高值。结果显示在重建质量上 ADSR 除稍低于 VDSR 外, 均优于对比方法。




图 4 comic 在比例因子为 3 时的重建图像

Fig. 4 Reconstructed image of comic at the scale of 3

表 5 ADSR 与现有方法 PSNR 的比较

单位: dB

Tab. 5 Comparison of PSNR of ADSR with existing methods

unit: dB

数据集	比例因子	Bicubic	ScSR <sup>[4]</sup>	A+ <sup>[5]</sup>	SRCNN <sup>[6]</sup>	SCN <sup>[7]</sup>	FSRCNN <sup>[8]</sup>	VDSR <sup>[9]</sup>	ISCNN <sup>[10]</sup>	文献[11]方法	EEDS <sup>[12]</sup>	ADSR
set5	×2	33.66	35.78	36.54	36.66	37.14	37.00	<b>37.53</b>	36.81	36.75	37.29	<u>37.36</u>
	×3	30.39	31.34	32.58	32.75	33.26	33.16	<b>33.66</b>	32.97	32.90	33.47	<u>33.59</u>
	×4	28.42	29.07	30.28	30.48	31.04	30.71	<b>31.35</b>	30.72	30.46	31.14	<u>31.19</u>
set14	×2	30.24	31.64	32.28	32.42	32.71	32.63	<b>33.03</b>	32.46	—	32.81	<u>32.86</u>
	×3	27.55	28.19	29.13	29.28	29.55	29.43	<b>29.77</b>	29.31	29.34	29.60	<u>29.67</u>
	×4	26.00	26.40	27.32	27.49	27.76	27.59	<b>28.01</b>	27.56	—	27.82	<u>27.88</u>
B100	×2	29.56	30.77	31.21	31.36	31.54	31.50	<b>31.90</b>	—	—	31.64	<u>31.78</u>
	×3	27.21	27.72	28.29	28.41	28.58	28.52	<b>28.82</b>	—	—	28.64	<u>28.73</u>
	×4	25.96	26.61	26.82	26.90	27.11	26.96	<b>27.29</b>	—	—	27.11	<u>27.20</u>
Urban100	×2	26.88	28.26	29.20	29.50	—	29.88	<b>30.76</b>	—	—	30.59	<u>30.44</u>
	×3	24.46	25.69	26.03	26.24	—	26.43	<b>27.14</b>	—	—	26.82	<u>26.92</u>
	×4	23.14	24.02	24.32	24.52	—	24.62	<b>25.18</b>	—	—	24.70	<u>25.00</u>

表 6 ADSR 与现有方法 SSIM 的比较

Tab. 6 Comparison of SSIM of ADSR with existing methods

数据集	比例因子	Bicubic	ScSR <sup>[4]</sup>	A+ <sup>[5]</sup>	SRCNN <sup>[6]</sup>	SCN <sup>[7]</sup>	FSRCNN <sup>[8]</sup>	VDSR <sup>[9]</sup>	ISCNN <sup>[10]</sup>	文献[11]方法	EEDS <sup>[12]</sup>	ADSR
set5	×2	0.9299	0.9485	0.9544	0.9542	0.9567	0.9558	<b>0.9587</b>	0.9560	0.9581	0.9579	<u>0.9584</u>
	×3	0.8682	0.8869	0.9088	0.9090	0.9167	0.9140	<b>0.9213</b>	0.9140	0.9131	0.9191	<u>0.9208</u>
	×4	0.8104	0.8263	0.8603	0.8628	0.8775	0.8657	<b>0.8838</b>	<u>0.8820</u>	0.8632	0.8783	<u>0.8812</u>
set14	×2	0.8688	0.8940	0.9056	0.9063	0.9095	0.9088	<b>0.9124</b>	0.9070	—	0.9105	<u>0.9115</u>
	×3	0.7742	0.7977	0.8188	0.8209	0.8271	0.8242	<b>0.8314</b>	0.8230	—	0.8284	<u>0.8296</u>
	×4	0.7027	0.7218	0.7491	0.7503	0.7620	0.7535	<b>0.7674</b>	0.7560	—	0.7626	<u>0.7632</u>
B100	×2	0.8431	0.8744	0.8863	0.8879	0.8908	0.8906	<b>0.8960</b>	—	—	0.8928	<u>0.8945</u>
	×3	0.7385	0.7647	0.7835	0.7863	0.7910	0.7893	<b>0.7976</b>	—	—	0.7925	<u>0.7955</u>
	×4	0.6675	0.6983	0.7087	0.7101	0.7191	0.7128	<b>0.7251</b>	—	—	0.7200	<u>0.7219</u>
Urban100	×2	0.8403	0.8828	0.8938	0.8946	—	0.9020	<b>0.9140</b>	—	—	0.8710	<u>0.9107</u>
	×3	0.7349	0.7831	0.7973	0.7989	—	0.8080	<b>0.8279</b>	—	—	0.8030	<u>0.8225</u>
	×4	0.6577	0.7024	0.7183	0.7221	—	0.7280	<b>0.7524</b>	—	—	0.7145	<u>0.7447</u>

VDSR 的 PSNR 及 SSIM 均值略高于本文方法,其原因是它直接使用提取出的高维度特征图进行非线性映射,网络模型参数量比 ADSR 大(2.36 MB>1.50 MB)。ADSR 采用的特征降维操作会产生较小的重建质量的损失,但能在时间效率上取得较大的优势。图 5 列出了 ADSR 与 VDSR 这两种方法在 4 个测试集上的重建质量与重建时间的对比,结果显示 ADSR 方法的 PSNR 均值只比 VDSR 低 0.1 dB 左右,但重建速度提高了将近一倍。




图 5 VDSR 与 ADSR 重建质量与时间的对比  
Fig.5 Comparison of reconstruction quality and time between VDSR and ADSR

另外,虽然 ADSR 在测试集上的重建均值略低,但能在很多图像上取得比 VDSR 好的重建结果,如图 6 所示,列出了 set5 数据集中 bird 图像及 set14 数据集中 flowers 图像在比例因子为 3 时两种方法下的重建图像以及 PSNR 值对比,其中 ADSR 取得了更佳的重建结果。

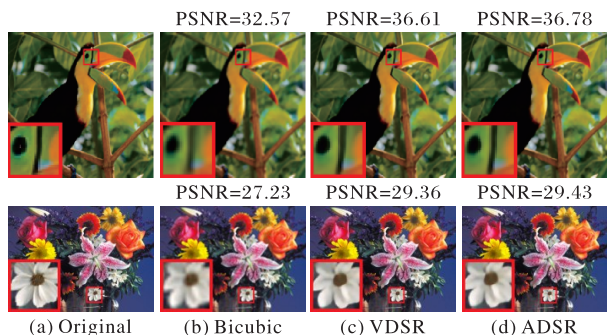


图 6 Bird 及 flowers 在比例因子为 3 时的重建图像  
Fig.6 Reconstructed images of bird and flowers at the scale of 3

### 2.3.2 重建时间的比较

为了反映 ADSR 的深层网络加速效果,本文与 A+[5]、SRCNN[6]、VDSR[9]、ISCNN[10]以及基于对称残差卷积神经网络的图像超分辨率重建方法(Super-Resolution based on Symmetric residual convolution neural network, SymSR)[19]进行了重建时间的比较。表 7 显示了 ADSR 与这些方法在 set5、set14、B100 以及 Urban100 测试集下的重建时间均值,其中加粗标注的值表示最低值。结果显示 ADSR 的重建速度最快。在 set5、set14、B100 三个数据集上 ADSR 的重建速度至少是 SRCNN 的 20 倍,是 VDSR 深层网络的 1.5 倍。在具有重建挑战性的城市数据集 Urban100 上 ADSR 的重建速度至少是 SRCNN 的 43 倍,是 VDSR 深层网络的 2.5 倍。另外 ADSR 网络模型参数量较 VDSR 有所减小(1.50 MB<2.36 MB),说明了本文方法达到了减少网络参数,降低网络复杂度,且明显提高重建速度的目的。

表 7 ADSR 与现有方法重建时间的比较

单位:s

Tab. 7 Comparison of reconstruction time of

ADSR with other methods							unit:s
数据集	比例因子	A+[5]	SRCNN[6]	VDSR[9]	ISCNN[10]	SymSR[19]	ADSR
set5	×2	0.58	2.19	0.13	2.50	0.22	<b>0.09</b>
	×3	0.32	2.23	0.13	1.92	0.21	<b>0.09</b>
	×4	0.24	2.19	0.12	2.51	0.20	<b>0.09</b>
set14	×2	0.86	4.32	0.25	5.12	0.42	<b>0.15</b>
	×3	0.56	4.40	0.26	4.07	0.42	<b>0.15</b>
	×4	0.38	4.39	0.25	5.01	0.41	<b>0.15</b>
B100	×2	0.59	2.51	0.16	—	0.29	<b>0.11</b>
	×3	0.33	2.58	0.21	—	0.29	<b>0.11</b>
	×4	0.26	2.51	0.21	—	0.29	<b>0.11</b>
Urban100	×2	2.96	22.12	0.98	—	—	<b>0.43</b>
	×3	1.67	19.35	1.08	—	—	<b>0.44</b>
	×4	1.21	18.46	1.06	—	—	<b>0.43</b>

### 2.4 ADSR 模型处理运动模糊的有效性

目前对图像超分辨率重建的研究绝大多数是集中在处理下采样模糊的理想化退化模型,鲜有研究考虑运动模糊等更为一般的退化因素[20]。本文将 ADSR 应用在处理运动模糊这一具有挑战性的问题上,探索 ADSR 模型在处理运动模糊时的有效性。

训练集将多种运动模糊核考虑在内,提升网络模型的泛化能力,其中模糊长度设置为[5,8,11,14],模糊角度设置为[0°,45°]。图 7 列出了测试集中的 3 张图像在模糊长度为 14,模糊角度为 45°下的重建图像以及 PSNR 值,结果显示,与 VDSR 相比,ADSR 能以较小的网络模型获得更优的重建效果,说明在处理运动模糊图像超分辨率重建问题上 ADSR 更有效。

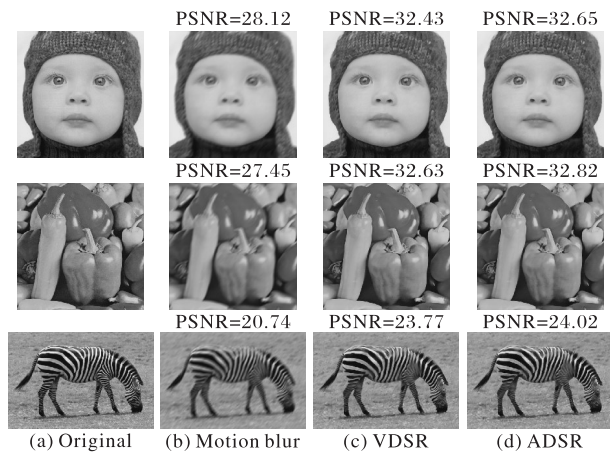


图 7 VDSR 与 ADSR 重建质量的比较

Fig. 7 Comparison of reconstruction quality between VDSR and ADSR

图 8 列出了这两种方法在 4 个测试集上的重建时间对比,结果显示 ADSR 方法的重建速度比 VDSR 快将近一倍。




图 8 VDSR 与 ADSR 重建时间的比较

Fig. 8 Comparison of reconstruction time between VDSR and ADSR



### 3 结语

本文提出了一种基于加速残差网络的图像超分辨率重建方法ADSR。该方法对低分辨率图像与真值图像之间的残差信息进行重建,它在多层小尺寸滤波器串联的非线性映射结构前加入特征收缩层对提取的特征图维数进行降维,然后在映射后加入高分辨率特征扩展层进行升维,重建出高分辨率的残差信息。经实验证明,ADSR能够取得较A+等传统方法以及SRCNN、ISCNN等国内外深度学习方法更好的超分辨率重建结果,并且能够减少深层网络参数,降低网络复杂度,达到加快重建速度、提高重建效率的目的。此外将该方法应用于运动模糊图像的超分辨率重建也获得了较好的性能,但实际获取的低分辨率图像降质因素众多,后续将构建更高效的网络来处理通用降质模型下的低分辨率图像的超分辨率重建问题。

#### 参考文献 (References)

- [1] SHI W, CABALLERO J, LEDIG C, et al. Cardiac image super-resolution with global correspondence using multi-atlas PatchMatch [C]// Proceedings of the 2013 International Conference on Medical Image Computing and Computer-Assisted Intervention, LNCS 8151. Berlin: Springer, 2013: 9-16.
- [2] ZHANG L, ZHANG H, SHEN H, et al. A super-resolution reconstruction algorithm for surveillance images [J]. Signal Processing, 2010, 90(3): 848-859.
- [3] 王宁, 秦品乐, 李传朋, 等. 基于残差神经网络的图像超分辨率改进算法[J]. 计算机应用, 2018, 38(1): 246-254. (WANG Y N, QIN P L, LI C P, et al. Improved algorithm of image super resolution based on residual neural network [J]. Journal of Computer Applications, 2018, 38(1): 246-254.)
- [4] YANG J, WRIGHT J, HUANG T, et al. Image super-resolution via sparse representation [J]. IEEE Transactions on Image Processing, 2010, 19(11): 2861-2873.
- [5] TIMOFTE R, DE SMET V, VAN GOOL L. A+: adjusted anchored neighborhood regression for fast super-resolution [C]// Proceedings of the 2014 Asian Conference on Computer Vision, LNCS 9006. Cham: Springer, 2014: 111-126.
- [6] DONG C, LOY C C, HE K, et al. Image super-resolution using deep convolutional networks [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(2): 295-307.
- [7] WANG Z, LIU D, YANG J, et al. Deep networks for image super-resolution with sparse prior [C]// Proceedings of the 2015 IEEE International Conference on Computer Vision. Piscataway: IEEE, 2015: 370-378.
- [8] DONG C, LOY C C, TANG X. Accelerating the super-resolution convolutional neural network [C]// Proceedings of the 2016 European Conference on Computer Vision, LNCS 9906. Cham: Springer, 2016: 391-407.
- [9] KIM J, LEE J K, LEE K M. Accurate image super-resolution using very deep convolutional networks [C]// Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2016: 1646-1654.
- [10] 李现国, 孙叶美, 杨彦利, 等. 基于中间层监督卷积神经网络的图像超分辨率重建[J]. 中国图象图形学报, 2018, 23(7): 984-993. (LI X G, SUN Y M, YANG Y L, et al. Image super-resolution reconstruction based on intermediate supervision convolutional neural networks [J]. Journal of Image and Graphics, 2018, 23(7): 984-993.)
- [11] 刘月峰, 杨涵晰, 蔡爽, 等. 基于改进卷积神经网络的单幅图像超分辨率重建方法[J]. 计算机应用, 2019, 39(5): 1440-1447. (LIU Y F, YANG H X, CAI S, et al. Single image super-resolution reconstruction method based on improved convolutional neural network [J]. Journal of Computer Applications, 2019, 39(5): 1440-1447.)
- [12] WANG Y, WANG L, WANG H, et al. End-to-end image super-resolution via deep and shallow convolutional networks [J]. IEEE Access, 2019, 7: 31959-31970.
- [13] SCHULTER S, LEISTNER C, BISCHOF H. Fast and accurate image upscaling with super-resolution forests [C]// Proceedings of the 2015 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2015: 3791-3799.
- [14] BEVILACQUA M, ROUMY A, GUILLEMOT C, et al. Low-complexity single-image super-resolution based on nonnegative neighbor embedding [C]// Proceedings of the 2012 British Machine Vision Conference. Durham: BMVA Press, 2012: No. 135.
- [15] ZEYDE R, ELAD M, PROTTER M. On single image scale-up using sparse-representations [C]// Proceedings of the 2010 International Conference on Curves and Surfaces, LNCS 6920. Berlin: Springer, 2010: 711-730.
- [16] MARTIN D, FOWLKES C, TAL D, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics [C]// Proceedings of the 8th IEEE Conference on Computer Vision. Piscataway: IEEE, 2001: 416-423.
- [17] HUANG J B, SINGH A, AHUJA N. Single image super-resolution from transformed self-exemplars [C]// Proceedings of the 2015 IEEE Conference on Computer Vision and Pattern Recognition. Piscataway: IEEE, 2015: 5197-5206.
- [18] HE K M, ZHANG X Y, REN S Q, et al. Delving deep into rectifiers: surpassing human-level performance on ImageNet classification [C]// Proceedings of the 2015 International Conference on Computer Vision. Piscataway: IEEE, 2015: 1026-1034.
- [19] 孙叶美. 基于卷积神经网络的图像超分辨率重建算法研究 [D]. 天津: 天津工业大学, 2019: 35-38. (SUN Y M. Research on image super-resolution reconstruction algorithms based on convolutional neural network [D]. Tianjin: Tianjin Polytechnic University, 2019: 35-38.)
- [20] 郭业才, 朱文军. 基于深度卷积神经网络的运动模糊去除算法 [J]. 南京理工大学学报(自然科学版), 2020, 44(3): 303-312. (GUO Y C, ZHU W J. Motion deblurring algorithm based on deep convolutional neural network [J]. Journal of Nanjing University of Science and Technology, 2020, 44(3): 303-312.)

This work is partially supported by the National Natural Science Foundation of China (61801279), the Applied Basic Research Project of Shanxi Province (201801D221160), the Shanxi Postgraduate Education Innovation Project (2020SY176, 2020SY175).

**LIANG Min**, born in 1979, Ph. D., associate professor. Her research interests include image processing, pattern recognition.

**WANG Haorong**, born in 1996, M. S. candidate. Her research interests include computer vision, three-dimensional super-resolution reconstruction.

**ZHANG Yao**, born in 1994, M. S. candidate. Her research interests include image processing, pattern recognition.

**LI Jie**, born in 1986, Ph. D., associate professor. His research interests include computer vision, three-dimensional super-resolution calculation.