

基于残差注意力网络的地震数据超分辨率方法

周文辉^{1,2} 石 敏³ 朱登明¹ 周 军⁴

1 中国科学院计算技术研究所 北京 100190

2 中国科学院大学 北京 101408

3 华北电力大学控制与计算机工程学院 北京 102206

4 中国石油集团测井有限公司技术中心 西安 710065

(765647930@qq.com)

摘 要 地震数据在油气勘探、地质勘探领域发挥着至关重要的作用。精确详细的地震数据有助于对油气勘探做出精确指导,减小勘探的风险,从而产生巨大的社会效益和经济效益。在提升地震数据分辨率方面,现有的方法在面对海量数据时,在高分辨恢复、去噪性能和效率上效果欠佳,难以恢复出细节丰富的地质信息,无法满足实际需求。地震数据能够反映地质构造以及地层的组成,具有局部相关性高、全局相关性低的特点。同时,地震数据高频部分通常蕴含着地质勘探等重要信息,如分层、断层信息等。针对地震数据的特点,文中将地震数据重建问题转化为图像超分辨率问题,提出了采用基于生成对抗网络的地震数据超分辨率方法。针对地震数据分布具有局部相关性高、全局相关性低的特点,设计残差注意力模块,挖掘地震数据的内在相关性,通过训练含有相对生成对抗损失函数的生成对抗网络模型,来对地震数据进行超分辨率恢复,以得到更加精确的地震数据。在真实的地震数据集上进行了实验验证,结果表明,所提方法在地震数据超分辨率上效果良好,在性能指标 PSNR 和 SSIM 上有 3%~4% 的提升,具有较强的实用性。

关键词: 地震数据;残差注意力模块;生成对抗网络;相对生成对抗损失;超分辨率

中图法分类号 TP391.41

Seismic Data Super-resolution Method Based on Residual Attention Network

ZHOU Wen-hui^{1,2}, SHI Min³, ZHU Deng-ming¹ and ZHOU Jun⁴

1 Institute of Computing Technology, Chinese Academy of Sciences, Beijing 100190, China

2 University of Chinese Academy of Sciences, Beijing 101408, China

3 College of Control and Computer Engineering, North China Electric Power University, Beijing 102206, China

4 China National Petroleum Logging Co., Ltd. Technology Center, Xi'an 710065, China

Abstract Seismic data plays a vital role in oil and gas exploration and geological exploration. Accurate and detailed seismic data can help to provide accurate guidance for oil and gas exploration, reduce the risk of exploration, and generate huge social and economic benefits. In terms of improving the resolution of seismic data, the existing methods are difficult to recover detailed geological information when facing large amounts of data, and have poor results in high-resolution recovery, denoising performance and efficiency, and it is difficult to meet the actual needs. Seismic data can reflect the composition of geological structures and strata, and have the characteristics of high local correlation and low global correlation. At the same time, the high frequency part of seismic data usually contain important geological exploration information such as layering, chasm, etc. In view of the characteristics of seismic data, this paper innovatively transforms the problem of seismic data reconstruction into the problem of image super-resolution, and proposes a method for super-resolution of seismic data based on the generative adversarial networks. In view of the characteristics of high local correlation and low global correlation of seismic data distribution, a residual attention module is designed to mine the inherent correlation of seismic data, so as to recover more refined seismic data. By training a generative adversarial network model with a relative generative adversarial loss function, the generative network is used to perform super-resolution recovery of the seismic data to recover more refined seismic data. In this paper, experimental verification is carried out on real seismic data, and the experimental results show that the proposed method has a good effect on super-resolution of seismic data and has strong practicability.

Keywords Seismic data, Residual attention module, Generative adversarial network, Relative generative adversarial loss, Super resolution

到稿日期:2020-09-04 返修日期:2020-11-17

基金项目:国家重大科技专项(2017ZX05019005)

This work was supported by the National Major Science and Technology Project(2017ZX05019005).

通信作者:朱登明, zhu@ict.ac.cn

1 引言

地震数据在油气勘探、地质勘探领域发挥着至关重要的作用。精确详细的地震数据有助于勘探人员了解该地区的油藏类型、构造样式、输导体系和成藏过程,从而实现对油气勘探的精确指导,减小勘探风险,产生巨大的社会效益和经济效益^[1-2]。石油地震勘探技术的原理是利用弹性特征来对地下的地质结构进行分析判断,从而推断出岩体的物理特性^[3]。随着油气勘探精度及效益的不断提升,在获取具有更高空间分辨率的地震数据的同时,降低地震采集的成本成为近年来油气勘探的一个重要发展方向。

在地震数据的采集过程中,由于声波在地层传播过程中存在不同程度的损耗,同时检波器接受声波的精度受到采集环境不同程度的影响(如环境温度、湿度等因素),导致最终采集得到的数据难以避免地存在部分失真、含有噪声等问题,因此对地震数据进行重建一直是业界研究的热点。早期的地震数据重建方法主要包括在采集方法上使用更加精密的仪器、缩小地面道距、使用更多的检波器等,这些方法能够获取更加精细的地震数据,但也显著增加了地震数据的采集成本。另外,基于已有的地震数据,利用信号重建的方法恢复地震数据也得到了广泛的研究,例如基于预测滤波、波动方程、降秩理论、压缩感知等重建方法。这些方法一定程度上能够恢复出地震数据丢失的信息,但是当遇到数据特征复杂、数据量庞大的地震数据时,这些方法难以得到真实且细节丰富的地震数据,因此难以满足人们对油气勘探精度以及效益的需求。

近年来,随着硬件技术以及深度学习的发展,深度学习算法在数据重建领域逐渐兴起,为地震数据的恢复提供了新的思路。本文在充分分析地震数据分布的特点以及现有的地震数据重建方法的基础上,对地震数据蕴含的信息进行了充分挖掘利用,本文方法从图像领域得到启发,主要贡献在于:将地震数据重建问题转化为图像超分辨率问题,提出了基于生成对抗网络的地震数据超分辨率方法。该方法首先将地震数据转化成地质图像,结合地震数据的局部相关性高、全局相关性低的特点,设计残差注意力模块以及生成对抗模型来充分挖掘数据的内在相关性,从而对地质图像进行超分辨率恢复。与传统方法相比,该算法得到的超分辨率数据具有高效率、高信噪比、高保真、高可信度等特点,在提升地震数据的分辨率方面具有较好的效果。

2 相关工作

2.1 地震数据

反射波地震勘探技术是地震勘探中的一项主流技术,目前采集地震数据使用最多的是3D地震勘探技术^[4],该技术通过人工方式激发地震波,地震波在由激发点向地底传播的过程中,在遇到地层分层处时将产生不同强度、不同类型的反射波信号。通过地面测线上的检波器接收反射波并将其记录在磁带上,从而得到原始的地震数据,如图1所示。随后对数据进行数据净化,包括对数据中的干扰波、空、废道进行替换删除等预处理,对有效数据进行振幅补偿校正处理,对目的层进行属性提取、时频域分析等^[5],最终将数据保存在SEG-Y

格式文件中。本文实验采用的数据即为经过上述方式处理后得到的地震数据。




图1 单道地震数据

Fig. 1 Single channel seismic data

2.2 地震数据重建

由于采集得到的数据难以避免地存在部分失真、含有噪声等问题,为了提升地震数据空间上的信噪比以及分辨率,在采集方法上可结合地面道距、采样间隔、炮道密度等方式来提升数据的空间分辨率,但是这种方法也显著地增加了采样的成本^[6-7]。另一方面,直接利用数据分布规律对地震数据进行重建,地震道插值与随机噪声压制是地震数据处理中比较常用的方法,地震道插值利用地震数据中完整的地震道数据来重建出缺失的地震道数据,主要包括由Spitz^[8]和Gulunay^[9]等提出的基于预测滤波的重建、基于波动方程的重建^[10]以及基于压缩感知理论的重建^[11-12]等。传统的地震随机噪声压制方法则主要基于变换域滤波或信号重建,如频率波数域滤波、傅里叶变换^[13]、Radon变换^[14]、Curvelet变换^[15]、Seislet变换^[16]、Shearlet变换^[17]、Dreamlet变换^[18]等方法。这些方法基于有效信号与随机噪声在变换域中的特征差异来设计合适的阈值,从而滤除大部分噪声。但当数据特征复杂或者面向海量数据时,地震道插值方法的处理效率较低,同时难以恢复出真实且细节丰富的地质信息;人工控制阈值的处理方法在去噪性能和去噪效率上效果欠佳,二者均难以满足人们对油气勘探精度以及效益的需求。

在图像超分辨率领域,Dong等^[19]于2014年首次利用深度学习处理方法处理图像超分辨率问题。随后,其团队于2016年在原来模型的基础上提出了卷积神经网络加速算法^[20],直接将原始的低分辨率图像输入网络中,实现图像超分辨率重建。Kim等^[21]于2016年在网络中引入残差结构,使得网络训练效果得到进一步提升。Ledig等^[22]于2017年提出了SR-GAN,将生成对抗网络引入图像超分辨率重建过程中,实现了基于生成对抗网络的图像超分辨率方法,该方法在图像超分辨率重构上取得了较好的效果。

2.3 注意力机制

深度网络中注意力机制(attention mechanism)最早源于对人类视觉的研究。在认知科学中,人类会选择性地关注所有信息的一部分,同时忽略其他可见的信息,上述机制通常被称为注意力机制。注意力机制早在20世纪90年代就被应用在视觉领域^[23-24]。Mnih等^[25]于2014年的研究使得注意力机制在深度学习领域重新获得广泛应用,近年来其在计算机视觉领域越来越受到人们的重视。人类的视觉注意力使得我们能够在图片的低解析度背景下更加关注具有高解析度或辨识度(high resolution)的特定区域,随后逐渐将注意力分散到整张图片上,从而推断出图中的信息。在视觉领域,注意力机

制的一个重要应用为促使深度网络学习数据的关键信息分布规律,使得网络能够忽略数据中的无关信息,从而更加注重数据本身的特性。

注意力机制在实现方法上分为**强注意力机制**^[26]和**软注意力机制**^[27],其中软注意力机制更为常用。软注意力机制共有两类,第一类是空间域(spatial domain)注意力,表现在图像上就是对 feature map 上不同位置的关注程度不同,表现在数学上指,针对某个大小为 $H \times W \times C$ 的特征图,一个有效的空间注意力对应一个大小为 $h \times w$ 的矩阵,每个位置的值作为原 feature map 对应位置上的一个权重,随后逐位置相乘得到注意力增强后的 feature map。第二类为通道域(channel domain),这种注意力主要分布在 channel 上,表现在图像上就是对不同的图像通道的关注程度不同,反映在数学上指,针对某个大小为 $H \times W \times C$ 的 feature map,通道注意力对应一个大小为 $1 \times 1 \times C$ 的矩阵,每个位置为对应原特征图 channel 上的一个权重,采用逐像素相乘得到注意力增强后的 feature map。

在地震数据中,高频信息中往往蕴含着丰富的地质信息^[28],例如不同岩性的地层信息、地层层间的分层信息以及地层断层信息,这些关键信息的分布规律是地震勘探的重要线索,超分辨率恢复的效果直接决定了地震勘探的精度。在地质图像上采用注意力机制,能够促使网络在学习过程中对高频信息赋予更高的学习权重。同时,通过分析地质的形成过程,处于空间邻近位置上的地质条件类似,具有较高的相关性,空间位置较远的地质数据则相关性低,因此本文采用空间域与通道域相结合的网络结构来共同提取地震数据特征。

2.4 残差网络

在深度神经网络的训练过程中,随着网络深度的增加,模型通常能够得到更好的拟合数据,学习到数据间复杂的非线性映射关系。然后,随着网络的加深,网络梯度常常发生梯度弥散、爆炸的现象,导致网络难以收敛。为解决该问题,He 等^[29]于 2016 年提出了深度残差网络,随后该结构便受到了极大的关注,在许多深度学习研究中得到广泛的使用。

深度残差网络在网络中引入了跳跃结构,组成残差模块,该模块将浅层的特征直接与深层特征相结合。残差模块的基本架构由网络层、跳跃结构以及激活函数组成,如图 2 所示。




图 2 残差结构
Fig. 2 Residual structure

图 2 中, X 表示输入数据, weight layer 表示网络层参数, Relu 表示线性整流激活函数, $F(X)$ 表示网络残差。对于一个神经网络而言,当输入为 X 时,其学习到的特征记为 $H(X)$,图 2 中的残差结构表明,输入数据通过跳跃结构直接与输出相加,因此在跳跃结构之间的网络层负责学习残差 $F(X)$,残差可以表示为:

$$F(X) = H(X) - X$$

因此,通过设计残差模块,将地震数据特征直接映射问题转化为间接映射,有效地降低了网络训练过程中特征映射的难度,使得网络训练过程更加简单。同时,在进行梯度反向传播的计算过程中,跳跃结构的存在很好地缓解了网络的梯度弥散、爆炸等问题,使得深层网络在训练时能够快速收敛,模型能够更好地拟合地震数据。

2.5 生成对抗模型

生成对抗模型(Generative Adversarial Networks, GAN)^[30]作为一种形式简单、效果优异的生成式模型,一经提出便受到极大的关注,迅速成为深度学习领域的另一个研究热点,许多基于生成对抗网络的工作相继被提出^[31-32]。生成对抗模型的核心思想是**对抗与博弈**,其基于一个博弈式的训练过程训练而成,即通过对抗的方式去学习数据分布。生成对抗模型主要由生成网络和判别网络组成,生成网络尽可能生成逼真样本,判别网络则尽可能判别该样本是否是真实样本。其网络框架如图 3 所示。




图 3 生成对抗模型结构
Fig. 3 Generate adversarial model structure

隐变量 Z (通常为服从高斯分布的随机噪声)通过生成器生成假样本 X ,判别器负责判别输入的样本是真实样本还是生成样本,网络优化目标函数如下:

$$\min_G \max_D V(G, D) = \min_G \max_D E_{x \sim p_{\text{data}}} [\log D(x)] + E_{z \sim p_z} [\log(1 - D(G(z)))]$$

其中, D 为判别器, G 为生成器。对于判别器 D 来说,网络需要学习一个二分类判别器,对于生成器 G 来说,优化目标为尽可能降低判别器 D 的准确率,因此需要最大化生成样本的判别概率 $D(G(z))$,即最小化 $\log(1 - D(G(z)))$ 。在实际训练时,生成器和判别器采取交替训练的方式,即先训练 D ,然后训练 G ,不断往复。由于生成对抗模型的结构简单,在超分辨率、图像风格转换、目标检测、视频生成等方面有着广泛的应用。

生成对抗网络在进行超分辨率恢复时,如 ESRGAN^[33], RCAN^[34]等,通常采用的残差结构仅仅将浅层特征和深层特征在 channel wise 上进行融合,没有充分考虑到地震数据结构上具有的局部相关性高、全局相关性低的特点,本文方法将混合注意力机制与残差结构相结合,构造了一个全新的 RA_BLOCK 结构,在超分辨率过程中能够显著提升地震数据的精度。

3 地震数据的超分辨率方法

在油气勘探、地质勘探领域,常用的地震解释技术通常使用颜色空间作为地震强度的表达媒介,通过颜色传递函数将

地震数据中的反射波强度数据映射到颜色空间。将地震数据绘制成图像,利用地震成像数据来研究地层的构造以及油藏的分布。地震解释使用蓝、白、红颜色空间,3个颜色通道分别代表地震波正向振幅、零振幅、负向振幅,上述过程可以表示为:

$$C_{rbw} = F_{\text{project}}(I_{\text{identify}})$$

其中, C_{rbw} 表示映射后的图像数, F_{project} 表示映射函数, I_{identify} 表示原始的地震数据。因此,本文利用颜色映射函数得到地震成像数据,并在此基础上对图像进行超分辨率恢复,以便勘探人员在对地震成像数据进行观测判断时精准分析该地层的构造以及油藏类型。

通过人工激发地震波、地表检波器检波的方式得到的地层地震数据场,即为空间上连续变化的点云数据,点云数值体现了不同地层对地震波的放射强度。点云数据的强度变化趋势体现了地底地质结构的变换。地震数据场在纵向上以一个较小的时间间隔对声波数据进行采样,分辨率较高,而横向上的数据点由检波器的布置密度决定,分辨率较低,地震数据采集以及地层分布如图4所示。




图4 地震数据采集图

Fig. 4 Seismic data acquisition map

本文的研究目的是利用现有的地震数据,基于生成对抗网络增强地震数据的分辨率,从而使地震数据更加贴合地层结构,并结合残差网络、注意力机制结构,使得生成的数据能够精确地反映地层的变换,恢复出真实且具有丰富细节的地震数据。

在地震数据的采集过程中,由于采集的过程复杂,最终采集得到的数据中不可避免地存在部分失真、含有噪声等问题。使用传统方法处理后的地震数据,在信噪比和分辨率提升上效果欠佳,难以满足人们的需求。

考虑到海量地震数据规模大、数据分布复杂,难以用数学模型直接表达,因此本文从地震数据出发,针对地震数据分布具有局部相关性高、全局相关性低的特点,提出了注意力机制模型,让深度学习模型更加注重学习局部特征的关联性。同时,由于生成对抗网络不依赖于任何假设的先验分布的特点,因此将地震数据作为训练数据,利用网络的对抗性在生成网络与判别网络的相互对抗、相互适应的过程中,训练生成网络以生成尽可能逼真的地震数据,训练判别网络以尽可能提升对真样本和假样本的判别能力。

3.1 地震数据超分辨率模型的网络结构

本文方法在生成对抗模型 ESRGAN 的基础上加入了 RA_BLOCK 残差注意力机制模块,整体结构如图5所示,地震数据超分辨率模型的网络结构主要由4部分组成:两层的全卷积层模块,用于提取地震数据的浅层信息;通道注意力机制模块,用于增强地震数据中的高频;局部信息权重,残差模块,用于学习地震数据中的深层信息;上采样以及超分辨率重建层,用于提升图像的分辨率,学习高分辨率图像与输入图像之间的残差。

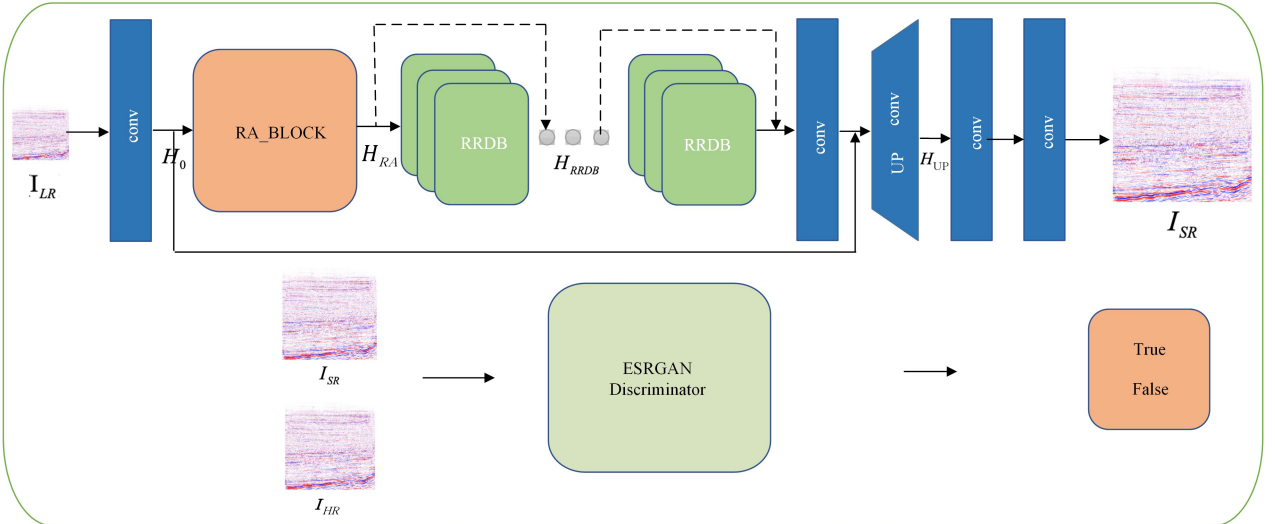


图5 超分辨率算法结构图

Fig. 5 Super-resolution algorithm structure diagram

图5中,将单道的地震数据输入网络中,首先通过卷积层提取地震数据浅层的 feature map:

$$H_0 = F_{\text{conv}}(I_{LR})$$

其中, H_0 表示卷积层之后的输出, $F_{\text{conv}}(\cdot)$ 表示卷积操作。 H_0 作为下一阶段残差注意力机制模块的输入,即:

$$H_{RC} = F_{RA}(I_{LR})$$

其中, H_{RC} 表示残差注意力模块的输出, $F_{RA}(\cdot)$ 表示残差注

意力模块的网络运算。残差注意力模块对每个通道赋予不同的注意力权重,目的是使得网络在训练过程中更加关注地震数据中高频部分以及局部特征关联性的学习。 H_{RA} 作为密集残差卷积结构的输入,得到:

$$H_{RRDB} = F_{RRDB}(H_{RA})$$

其中, $F_{RRDB}(\cdot)$ 表示密集残差卷积操作, H_{RRDB} 作为上采样以及分辨率重建层的输入,其中上采样层的操作如下:

$$H_{UP} = F_{UP}(H_{RRDB})$$

其中, H_{UP} 表示上采样层的输出, $F_{UP}(\cdot)$ 表示上采样操作。最后将 H_{UP} 输入超分辨率重建层, 即得到模型输出重建后的高分辨率图像:

$$I_{SR} = F_{REC}(H_{UP}) = F_{SR}(I_{LR})$$

其中, $F_{REC}(\cdot)$ 表示超分辨率重建操作, $F_{SR}(\cdot)$ 表示整个深度网络。将低分辨率图像输入网络中, 最终得到其高分辨率的版本。最后通过优化生成对抗网络的损失函数来优化网络参数, 以提升超分辨率的效果。传统的生成对抗网络中的损失函数采用概率距离作为量度, 计算式如下:

$$D(x_r) = \sigma(C(x_r)) \rightarrow 1$$

$$D(x_f) = \sigma(C(x_f)) \rightarrow 0$$

其中, x_r 为真实样本, x_f 为生成样本, $\sigma(\cdot)$ 为 sigmoid 函数, $C(\cdot)$ 表示判别器的输出。从上式可以看出, 标准的判别损失将原始的输入图像严格映射到 1, 0 上, 以判别图像的真实性。本文采用的是相对判别损失, 即优化函数的目标是保证生成的样本相对真实样本更加真实或者相对虚假, 计算式如下:

$$D_{Ra}(x_r, x_f) = \sigma(C(I_r) - E[C(I_f)]) \rightarrow 1$$

$$D_{Ra}(x_f, x_r) = \sigma(C(I_f) - E[C(I_r)]) \rightarrow 1$$

其中, D_{Ra} 表示相对判别损失, $E_{x_f}[\cdot]$ 表示生成样本各个位置上的值取平均。训练生成对抗网络, 依次优化生成器和判别器, 判别器的损失函数如下:

$$L_{D_{Ra}}^R = -E_{x_r}[\log(D_{Ra}(x_r, x_f))] - E_{x_f}[\log(1 - D_{Ra}(x_f, x_r))]$$

生成器的损失函数如下:

$$L_{G_{Ra}}^R = -E_{x_r}[\log(1 - D_{Ra}(x_r, x_f))] - E_{x_f}[\log(D_{Ra}(x_f, x_r))]$$

通过修改生成对抗网络的损失函数, 使得网络能够更好地利用生成样本以及真实样本进行对抗训练, 从而提升网络的超分辨率效果。

3.2 残差注意力模块

在图像超分辨率领域, 大量实验表明图像的高频特征往往在超分辨率重建上起着更大的作用, 因此让深度网络将更多的注意力集中在高频通道的特征学习上, 将明显提升图像的超分辨率效果。地质构造是地壳或岩石圈各个组成部分的形态及其结合方式的总称, 在空间上相邻位置上的地质条件比较相似, 局部相关性较高, 而全局的相关性较低。因此, 本文采用混合域注意力机制的方法, 即同时应用空间域和通道域, 分别对地震数据通道上的高频数据以及空间上的局部关联性添加学习权重, 结合残差网络, 组成残差注意力模块, 残差注意力模块的结构如图 6 所示。




图 6 残差注意力模块(RA_BLOCK)

Fig. 6 Residual attention module(RA_BLOCK)

图 6 中, 输入的特征经过通道注意力单元得到每一个像素位置上的权重, 通过逐像素相乘后传入一个卷积模块。随

后与残差网络 Identity Mapping 相加得到第一阶段的输出。第二阶段与第一阶段相似, 将特征图传入空间注意力结构中, 得到空间注意力权重之后再输出。其中, 通道注意力机制的内部结构如图 7 所示。

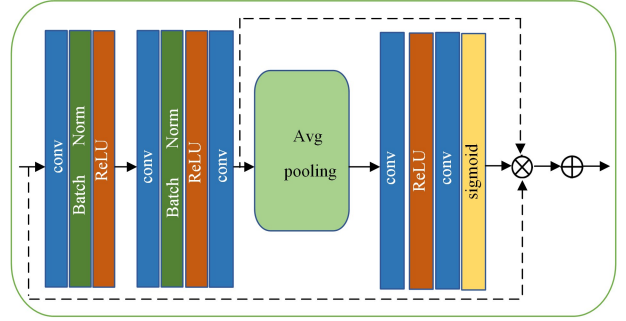


图 7 RA_BLOCK(通道注意力部分)

Fig. 7 RA_BLOCK(channel attention part)

将特征图输入网络中, 通过卷积变换得到一个大小为 $1 \times 1 \times C$ 的权重向量, C 表示 C 个通道, 向量上每一个位置的值得即为不同通道的权重值, 将该权重重复赋值到原始的特征图上, 即可得到通道注意力加权的特征图。空间注意力机制如图 8 所示, 首先在输入的特征的 channel 维度上做 max-pooling 和 avg pooling, 将池化的结果相加后通过一个 7×7 的卷积后输入 sigmoid 函数中, 将特征值转化为空间注意力权重, 将结果与原始特征图相乘后, 得到空间注意力权重加权后的特征图。




图 8 RA_BLOCK(空间注意力部分)

Fig. 8 RA_BLOCK(spatial attention part)

4 实验结果与分析

本文首先将地震数据通过颜色映射函数, 将反射波强度数据映射到白、红、蓝颜色空间, 从而将地震数据恢复问题转化为地震数据图像的超分辨率问题。并在生成对抗网络的基础上提出了残差注意力模块, 使得网络在地震数据超分辨率过程中着重学习网络的局部特征以及数据中的高频特征。实验使用实际地质勘探中采集的地震反射波数据, 以验证本文方法的有效性。

4.1 实验数据

本文使用一组采集完整、清晰度较高的地震体数据作为实验数据。地震体数据的点云尺度为 $600 \times 623 \times 300$, 每一个位置上的数值表示地震反射波的强度。对地震体数据进行切片, 随后使用颜色映射函数, 将数值映射到 RGB 空间, 地震解释中使用的蓝、白、红颜色空间这 3 个颜色通道分别代表地震波正向振幅、零振幅、负向振幅。映射得到的地震数据图像如图 9 所示。




图9 地震切片数据

Fig. 9 Seismic slice data

在地震数据超分辨率网络的训练过程中,训练数据为低分辨率数据,以及对应的高分辨率数据(对照组数据)。在训练网络过程中,网络学习低分辨率数据到高分辨率数据之间的映射。为了构造成对的地震数据,本文利用采集质量较好的地震数据作为对照组数据,使用线性插值方法将高分辨率数据减小为原来的 $1/4$ 以生成低分辨率数据,将结果输入网络中对网络进行训练。

本文采用两组分辨率的地震数据图像作为训练数据,充分挖掘网络对不同分辨率图像的学习能力。第一组对照组数据的尺度为 $120 \times 120 \times 3$,低分辨率训练数据的大小为 $30 \times 30 \times 3$,第二组对照组数据的尺度为 $240 \times 240 \times 3$,低分辨率训练数据的大小为 $60 \times 60 \times 3$ 。训练数据及对照数据如图 10 所示。

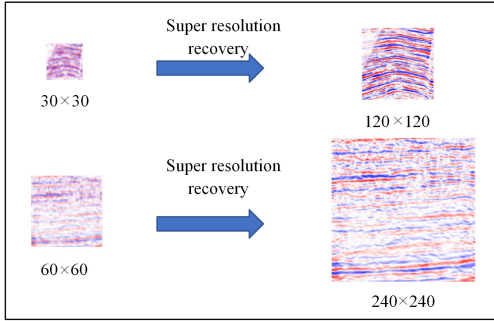


图10 训练数据及对照组数据

Fig. 10 Training data and control data

4.2 模型训练与结果对比

网络在两种分辨率数据下进行 40 万次迭代训练,其中 BatchSize 设置为 16,每个 GPU 上设置 6 个线程,同时通过加载预训练模型来加速网络的训练。网络优化器选择 Adam。为了保证梯度持续下降,学习率使用 MultiStepLR 策略,即按设定的时间间隔调整学习率。网络的训练环境为:使用 4 张型号为 1080Ti 的 GPU,CPU 型号为 Intel(R) Core(TM) i7-6800K CPU @ 3.40 GHz。

本文方法经过 40 万次迭代训练之后,与常见的超分辨率网络 ESRGAN 和 RCAN 在地震数据的超分辨率恢复上的还原效果对比如图 11、图 12 所示。从图中可以看出,在对地震数据的恢复上,RCAN 与 ESRGAN 难以恢复地震数据的细节信息,RCAN 恢复出的高分辨率地震数据缺失高频信息,图像整体较平滑、模糊,ESRGAN 恢复出的超分辨率地震数

据严重缺失低频信息,图像纹理比较突兀,细节过渡不平滑。本文方法恢复出的地震数据有着更加精细的细节信息,在高频以及低频的信息处理上更加出色,有着更加真实的视觉效果。




图11 地震体数据正面恢复的对比

Fig. 11 Comparison of the positive recovery of seismic volume data




图12 地震体数据侧面恢复的对比

Fig. 12 Comparison of lateral recovery of seismic volume data

为了更加客观地评价方法的性能,本文在不同的性能指标上对不同的方法进行比较。本文采用 PSNR 和 SSIM 两种指标,其中 PSNR 为峰值信噪比,PSNR 值越大,生成图像与真实图像之间的均方差越小,重建出的图像质量就越高,PSNR 的表达式如下:

$$MSE(y, \hat{y}) = \frac{1}{2} \|y - \hat{y}\|^2$$

$$PSNR(y, \hat{y}) = 20 \log(s) - 10 \log(MSE(y, \hat{y}))$$

其中, y 是真实图像, \hat{y} 是网络重建得到的 HR 图像, s 表示最大可能像素取值为 255。SSIM 为人眼视觉感知结构相似指数 (Structural Similarity Index, SSIM), 该评价指标通常用来衡量两幅图像之间的相似度,以弥补在相同的 PSNR 情况下存在不同的质量感知问题。SSIM 的取值为 $0 \sim 1$, 数值越接近 1, 算法失真越小, 算法的性能就越好, 指标公式如下:

$$SSIM(y, \hat{y}) = \frac{(2u_y u_{\hat{y}} + c_1)(2\sigma_{y\hat{y}} + c_2)}{(u_y^2 + u_{\hat{y}}^2 + c_1)(2\sigma_y^2 + \sigma_{\hat{y}}^2 + c_2)}$$

其中, u_y , $u_{\hat{y}}$ 以及 $\sigma_{y\hat{y}}$ 表示原图像 y 和超分图像 \hat{y} 的均值和标准差, σ_y 则表示交叉协方差, c_1 和 c_2 为常数, 通常, $c_1 = (0.01s)^2$, $c_2 = (0.03s)^2$, s 为最大可能像素取值 255。

表 1 列出了本文方法与 RCAN, ESRGAN 在相同数据集上质量指标的比较。可以看出, 本文方法在性能指标上相比其他方法有较大的优势, 其中 PSNR 相比 RCAN 提升了

3.97%(1.59/40),相比ESRGAN提升了3.35%(1.34/40)。SSIM相比RCAN提升了4.6%(0.046/1),相比ESRGAN提升了3.4%(0.034/1)。

表 1 不同算法的性能指标比较

Table 1 Comparison of performance indicators of different algorithms

Algorithm	PSNR	SSIM
RCAN	27.87	0.732
ESRGAN	28.12	0.744
Our Method	29.46	0.778

结束语 地震数据在油气勘探、地质勘探领域发挥着至关重要的作用,精确详细的地震数据有助于勘探人员实现对油气的精确判断,减小勘探风险,从而产生巨大的社会和经济效益。受限于采集设备和采集环境的影响,地震数据的精度有待进一步提升。传统的地震数据恢复方法通常是基于地震道插值,这类方法恢复效率低,同时难以恢复出真实且细节丰富的地质信息。本文借鉴图像超分辨率的处理方法,将地震数据重建问题转化为图像超分辨率问题,提出了基于生成对抗网络的地震数据超分辨方法。结合地震数据局部相关性高、全局相关性低的特点,设计残差注意力模块以及生成对抗模型来充分挖掘数据的内在相关性。该方法恢复得到的高分辨数据有着更加丰富的细节,具有高保真、高效率、高新信噪比等特点,视觉效果更为真实。

但本文方法也存在一些不足,如在训练网络时,需要大量的地震数据作为训练数据。数据的精细度质量以及数据的数量都将影响网络的超分辨率恢复性能。此外,本文方法恢复得到的地震数据与原始高分辨率数据仍然存在一定的差距,本文恢复得到的地震数据图像在清晰度、图像精细度方面仍有欠缺。后续工作中需要进一步研究地震数据的内在规律,结合数据特点在数据增强以及网络结构上进行创新,从而得到更加准确且细节丰富的超分辨率地震数据。

参 考 文 献

[1] JIAO H C. Research on seismic phase division method in 3D seismic data[D]. Chengdu: University of Electronic Science and Technology of China, 2019.

[2] ZHAO N, YAN X P, HAO C L. Application of comprehensive geological exploration methods in geological exploration[J]. World Nonferrous Metals, 2020(3): 233-235.

[3] CHEN S X. Analysis on the development of petroleum geological seismic exploration technology[J]. Petrochemical Technology, 2019, 26(3): 193.

[4] SHANG J K. Application of three-dimensional seismic exploration technology under complex geological conditions[J]. Jiangxi Coal Science and Technology, 2020(3): 143-146.

[5] ZHAN Z D, XU D P, WU H Y, et al. In-depth analysis of the accuracy of SEG Y format seismic data conversion[J]. Physical and Geochemical Exploration, 2011, 35(6): 851-854.

[6] XIONG Z. Seismic exploration methods and techniques for stratigraphic and lithologic reservoirs[J]. Petroleum Geophysical Prospecting, 2012, 47(1): 1-18.

[7] REILEY D L, COOPER L N. An Overview of Neural Net-

works: Early Models to Real World Systems[M]. San Diego: Academic Press, 2015: 7-15.

[8] SPITZ S. Seismic trace interpolation in the F-X domain[J]. Geophysics, 1991, 56(6): 785.

[9] GULUNAY N, CHAMBERS R E. Unaliased fk domain trace interpolation[C]// SEG Technical Program Expanded Abstracts. Tulsa: Society of Exploration Geophysicists, 1996: 1461-1464.

[10] RONEN J. Wave-equation trace interpolation[J]. Geophysics, 2012, 52(7): 973-984.

[11] ZHAO Z Y, LI Z C, ZHANG M. Discrete orthogonal S-transform seismic data reconstruction using compressed sensing technology[J]. Petroleum Geophysical Prospecting, 2020, 55(1): 29-35.

[12] JIAO X M, DU Q Z, ZHAO Q. The compressive sensing seismic trace reconstruction method based on the maximum correlation entropy criterion[J]. Journal of China University of Petroleum (Edition of Natural Science), 2020, 44(3): 38-46.

[13] XU S, ZHANG Y, PHAM D, et al. Antileakage Fourier transform for seismic data regularization[J]. Geophysics, 2005, 70(4): V87-V95.

[14] HUANG X W, WU L, NIU B H. Seismic trace reconstruction based on parabolic Radon transformation[J]. Journal of China University of Mining & Technology, 2003(5): 534-539.

[15] HERRMANN F J, HENNENFENT G. Non-parametric seismic data recovery with curvelet frames[J]. Geophysical Journal of the Royal Astronomical Society, 2010, 173(1): 233-248.

[16] LIU C, LI P, LIU Y, et al. Anti-aliasing iterative data interpolation method based on Seislet transform[J]. Chinese Journal of Geophysics, 2013, 56(5): 1619-1627.

[17] ZHANG L, HAN L G, XU D X, et al. Shearlet transform reconstruction of seismic data based on compressed sensing technology[J]. Petroleum Geophysical Prospecting, 2017, 52(2): 220-225.

[18] HUANG W, WU R S, WANG R. Damped dreamlet representation for exploration seismic data interpolation and denoising[J]. IEEE Transactions on Geoscience & Remote Sensing, 2018, 56(6): 3159-3172.

[19] DONG C, LOY C C, HE K, et al. Learning a deep convolutional network for image super-resolution[C]// IEEE International Conference on Computer Vision, 2014.

[20] DONG C, LOY C C, HE K, et al. Image super-resolution using deep convolutional networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(2): 295-307.

[21] KIM J, LEE J K, LEE K M. Accurate image super-resolution using very deep convolutional networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1646-1654.

[22] LEDIG C, THEIS L, HUSZAR F, et al. Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network[C]// IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017.

[23] ROLAND P. Cortical regulation of selective attention in man. A regional cerebral blood flow study[J]. Journal of Neurophysiology, 1982, 48(5): 1059.

[24] MORAN J,DE SIMONE R. Selective attention gates visual processing in the extrastriate cortex[J]. Science,1985,229(4715): 782-784.

[25] MNIH V,HEESS N,GRAVES A, et al. Recurrent Models of Visual Attention[C]//Conference and Workshop on Neural Information Processing Systems. 2014.

[26] MALINOWSKI M,DOERSCH C,SANTORO A, et al. Learning visual question answering by bootstrapping hard attention[C]// Proceedings of the European Conference on Computer Vision (ECCV). 2018;3-20.

[27] MCCLENNY L,BRAGA-NETO U. Self-Adaptive Physics-Informed Neural Networks using a Soft Attention Mechanism [J]. arXiv:2009. 04544,2020.

[28] ZHANG B B,ZHANG Z J,FU J R, et al. Recovering low-frequency information using high-frequency components of seismic data[C] // 2014 China Earth Sciences Joint Academic Annual Conference—Topic 18:Collected Papers on Reservoir Geophysics. 2014.

[29] HE K,ZHANG X,REN S,et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017.

[30] GOODFELLOW L,POUGET-ABADIE J,MIRZA M, et al. Generative adversary yal nets[C] // Conference and Workshop on Neural Information Processing Systems. 2016.

[31] ZHAO Z,SUN Q,YANG H, et al. Compression artifacts reduction by improved generative adversarial networks[J]. EURASIP

Journal on Image and Video Processing,2019,2019(1).

[32] ZHAO Z S,GAO H X,SUN Q, et al. The theoretical framework of generative confrontation network, the latest development of derivative models and applications [J]. Small Microcomputer System,2018,39(12);44-48.

[33] WANG X,YU K,WU S, et al. Esrgan:Enhanced super-resolution generative adversarial networks[C] // Proceedings of the European Conference on Computer Vision (ECCV). 2018.

[34] ZHANG Y,LI K P,LI K, et al. Image super-resolution using very deep residual channel attention networks[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018;286-301.



ZHOU Wen-hui, born in 1995, master. His main research interests include computer vision and computer graphics.



ZHU Deng-ming, born in 1973, Ph.D, as-sociate researcher, master supervisor, is a member of China Computer Federation. His main research interests include virtual reality and human-computer interaction.