

基于残差网络的图像超分辨率重建算法

陈晨¹, 刘明明², 刘兵^{1,3}, 周勇¹

1. 中国矿业大学 计算机科学与技术学院, 江苏 徐州 221116

2. 江苏建筑职业技术学院 智能制造学院, 江苏 徐州 221008

3. 中国科学院 航空航天信息研究所, 江苏 徐州 221116

摘要:传统的卷积神经网络用到的方法是在稀疏表示的超分辨率图像的基础上学习高/低分辨率图像之间端到端的映射, 输入的是高分辨率的图像, 输出的是低分辨率的图像, 拥有三层卷积层的SRCNN虽然有一定的重建效果, 但是感受野较低, 因此, 提出加深网络结构的方法, 此次改进使得后面的网络层拥有更大的感受野, 这样结果的像素点可以根据更多的像素点来推断。但是考虑到网络结构加深对传输速率的影响, 通过引入局部残差学习和全局残差学习相结合的方法来提高学习率, 通过该办法有效地加快了收敛速度, 并且通过实验结果验证, 与已有的Bicubic、SRCNN和VDSR相比, 重建效果在峰值信噪比、结构相似性和视觉效果上均有所提升。

关键词:卷积神经网络; 图像超分辨率重建; 残差网络

文献标志码:A **中图分类号:**TP391 **doi:**10.3778/j.issn.1002-8331.1901-0331

陈晨, 刘明明, 刘兵, 等. 基于残差网络的图像超分辨率重建算法. 计算机工程与应用, 2020, 56(8): 185-191.

CHEN Chen, LIU Mingming, LIU Bing, et al. Image super-resolution reconstruction algorithm based on residual network. Computer Engineering and Applications, 2020, 56(8): 185-191.

Image Super-Resolution Reconstruction Algorithm Based on Residual Network

CHEN Chen¹, LIU Mingming², LIU Bing^{1,3}, ZHOU Yong¹

1. College of Computer Science and Technology, China University of Mining and Technology, Xuzhou, Jiangsu 221116, China

2. Institute of Intelligent Manufacturing, Jiangsu Vocational Institute of Architectural Technology, Xuzhou, Jiangsu 221008, China

3. Aerospace Information Research Institute, Chinese Academy of Sciences, Xuzhou, Jiangsu 221116, China

Abstract: The traditional convolutional neural network uses end-to-end mapping between high/low resolution images based on sparsely expressed super-resolution images. The input image is high resolution and the output image is low resolution. SRCNN with three convolution layers has a certain reconstruction effect, but the field of receptivity is low. Therefore, a deeper network structure is proposed. This improvement makes the latter network layer have a larger field of perception, so that the result pixels can be inferred from more pixels. However, considering the influence of network structure deepening on transmission rate, the learning rate is improved by introducing a combination of local residual learning and global residual learning. The convergence rate is effectively accelerated by this method. The experimental results are verified. Compared with existing Bicubic, SRCNN and VDSR, the reconstruction effect has been improved in peak signal-to-noise ratio, structural similarity and visual effect.

Key words: convolutional neural network; image super-resolution reconstruction; residual network

基金项目:国家自然科学基金(No.61801198);江苏省自然科学基金(No.BK20180174)。

作者简介:陈晨(1995—),女,硕士研究生,研究领域为深度学习、图像超分辨率重建,E-mail:15850985118@163.com;刘明明(1985—),女,博士,讲师,主要研究方向为机器学习、模式识别;刘兵(1981—),男,博士后,副教授,研究领域为机器学习、数据挖掘;周勇(1974—),男,博士后,教授,研究领域为机器学习、数据挖掘。

收稿日期:2019-01-22 **修回日期:**2019-04-23 **文章编号:**1002-8331(2020)08-0185-07

CNKI网络出版:2019-05-28, <http://kns.cnki.net/kcms/detail/11.2127.TP.20190527.1720.009.html>

1 引言

本文所要研究的超分辨率图像重建(Super Resolution Image Reconstruction, SRIR 或 SR)是一种图像复原的方法,是指通过软件算法的方法,将低分辨率(Low-Resolution, LR)的图像或者序列转化为高分辨率(High-Resolution, HR)的图像^[1]。实际生活中,自从有了照相机、摄像头,通过不断的改进向世界呈现真实画面就成为了人们不断研究的目标,此项图像超分辨率重建技术更多的是用来实现对目标物体专注度的分析,来获得人们感兴趣的更高的空间分辨率的图像,而不需要直接采取数据量极大的高空间分辨率图像的配置。用时间带宽换取空间分辨率,实现时间分辨率和空间分辨率之间的转换是超分辨率重建的核心思想。

Harris 和 Goodman 等在 1969 年时,通过将带限信号外推的方法来解决当时的光学图像超分辨率重建的问题,在此确定了图像超分辨率重建的数学基础^[2-3]。1984 年, Huang 和 Tsai 等提出了频率域法,核心思想是利用图像之间傅里叶变换的位移性质,将单幅图像超分辨率重建扩展到多幅图像超分辨率重建,将高低分辨率之间的位移关系通过傅里叶变换来建立,开启了多幅图像超分辨率重建的新篇章^[4]。后来, Freeman 等在 2002 年时利用马尔可夫网络提出了一种新的基于样例学习的图像超分辨率重建算法,通过训练图像建立一个数据库,学习高低分辨率图像和领域高分辨率图像的关系来重建出新的高分辨率图像^[5]。截至目前,通过多位学者的研究可将图像重建算法分为以下三大类:基于插值、基于重构、基于学习。

为了提高图像超分辨率重建的效果, Yang^[5]等人提出了基于稀疏表示的图像超分辨率重建,此算法的核心内容是通过联合训练两个用于高低分辨率图像块的字典,这种办法可以有效增强高低分辨率图像块对相对于自身字典的稀疏表示的相似性。在这个前提下,低分辨率的图像块的稀疏表示和高分辨率图像块的字典产生高分辨率图像块,这样可以有效地降低算法的计算成本。传统的凸集投影(POCS)算法能够重建低分辨率(LR)图像,但在保留图像细节和去噪方面存在矛盾,从而限制了重建图像的质量。为了避免 POCS 的缺陷,获得更高的分辨率, Shang 等人^[6]将基于稀疏表示的思想用于图像的去噪。稀疏表示对图像的数据具有自适应性,能够学习优化图像过完备稀疏字典,用来描述图像的本质特征,来达到有效的去噪目的。2016 年, Dong 等^[7]率先提出基于卷积神经网络(SRCNN)的方法,核心思想是使用三个卷积层,将图像特征在低分辨率空间和高分辨率空间建立非线性映射,实验结果表明此方法的重建效果优于其他传统方法。

之后, Kim^[8]等人受 ResNet 的启发,在 SRCNN 的基础上提出了超深卷积神经网络图像超分辨率重建,引入

了 20 层卷积层和全局残差学习,得到了非常好的重建效果,但内存占用较大且计算复杂度较高。

同年, RED 网络结构被提出,主要特点在于此网络引入了反卷积层,卷积层与反卷积层一一对应,反卷积层恢复因经过卷积层而减小的图像尺寸,能够有效地恢复图像细节。采取 30 层网络结构,相对应的卷积层与反卷积层跳跃相连,将反向传播信号直接传递到底层,避免梯度消失的同时有效地重建出高质量的图像。

近几年随着医疗事业的发展,研究者逐渐开始研究磁共振图像的重建。刘振圻等^[9]于 2013 年将重建技术与现有的去噪技术相结合,在重建图像的同时,达到去噪的效果,有效地提高了磁共振图像的分辨率。

近几年,许多方法^[10-15]在图像超分辨率重建方向都取得了不错的效果。稀疏分解先于压缩感知提出,信号稀疏表示是为了在给定的超完备字典中尽可能用少量的原子来表示信号,因此来获得简洁的信号表示方式,可以更加容易地从信号中获取所要蕴含的信息,方便对信号进行进一步加工处理。

2 相关工作

2.1 卷积神经网络

卷积神经网络(Convolutional Neural Networks, CNN)是一类包含卷积或相关计算且具有深度结构的前馈神经网络(Feedforward Neural Networks),是深度学习(deep learning)的代表算法之一^[16-17]。在卷积神经网络中每一个节点代表的都是一个神经元,这点和全连接神经网络一样。

卷积层计算公式如下:

$$y_j^l = \sum_{i \in M_l} y_i^{l-1} \otimes k_{ij}^l + b_j^l \quad (1)$$

其中, y_j^l 表示的是第 l 层卷积层中第 j 个卷积核的输出,通常情况下称作特征图,它代表的是一个二维向量; k_{ij}^l 代表卷积核,表示的是第 l 层卷积层输入的第 i 个特征图与第 $l-1$ 层输出的第 j 个特征图之间的卷积核; b_j^l 表示的是第 l 层卷积层的第 j 个卷积核的偏置项; M_l 表示的是所有特征图集合,代表的是输入特征图要连接到输出的第 j 个特征图,将卷积操作的符号表示为 \otimes 。

特征提取是卷积神经网络与传统神经网络之间最大的区别,卷积层和子采样层构成了特征提取部分,卷积层中,神经元之间并不是完全连接,其中,一个神经元只与部分邻层神经元连接。

从低分辨率图像中有重叠的提取图像块并用高维向量表示,相当于采用一组滤波器对图像进行卷积操作,图像重建阶段是将重叠的高分辨率图像块进行平均化操作产生最终的高分辨率图像,而非线性映射阶段是将上一层的特征向量从低分辨率空间变换至高分辨率空间。

2.2 基于卷积神经网络的图像超分辨率重建(SRCNN)

首次将深度学习应用到图像超分辨率重建中, SRCNN 直接学习的是高低分辨率图像之间的端对端映射。映射表现为一个深度卷积神经网络(CNN)^[14], 输入的是低分辨率图像, 输出的是高分辨率图像, 如图1。SRCNN 不像传统的稀疏表示的图像超分辨率重建分开处理每个部件, 此共同优化了所有的层, 有很好的重建质量, 在实际应用中也取得了很好的效果。

SRCNN 首先做的预处理是使用双立方插值的方法来提升到它所需要的尺寸记作 Y , 这是 SRCNN 中唯一执行的预处理, 图像超分辨率重建的目标是将 Y 恢复为重建后的图像 $F(Y)$, $F(Y)$ 与原始的真实的高分辨率图像 X 需要尽可能地相似, 网络结构中学习到的映射记作 F , F 从概念上由小块的提取和表示、非线性映射、重建这三个操作组成。分成以下三个操作:

$$F_1(Y) = \max(0, W_1 \times Y + B_1) \tag{2}$$
$$F_2(Y) = \max(0, W_2 \times F_1(Y) + B_2) \tag{3}$$
$$F_3(Y) = \max(0, W_3 \times F_2(Y) + B_3) \tag{4}$$

其中, W_1 代表滤波器, 而 B_1 代表偏置, 将 W_1 的大小定义为 $c \times f_1 \times f_1 \times n_1$ 。输入图像中通道的数量记作 c , 滤波器的空间大小记作 f_1 , 滤波器的数量记作 n_1 。通俗来讲就是, 滤波器 W_1 在图像上进行 n_1 次的卷积操作, 输出图像由 n_1 个特征图组成。 B_1 表示的是 n_1 维的向量, B_1 的每个元素都与一个滤波器相对应。本文采用 ReLU 函数 ($\max(0, x)$)^[18] 在滤波器响应上。 W_2 、 B_2 、 W_3 、 B_3 同理。

SRCNN 有它独特的优点。首先, SRCNN 的网络结构非常简单, 和基于样本的图像超分辨率重建方法相比, 有着相同的优秀的精准性。其次, 这个方法因为中等数量的过滤器和层数, 所以在实际在线使用中甚至是 CPU 上, 也实现了很快的速度。由于 SRCNN 是完全前馈的, 因此在训练速度方面比基于样本的方法要快一点, 且不需要解决优化问题。最后, 当数据变多, 或者使用模型变大的时候, 通过实验证明是可以达到进一步的改善网络的修复质量的目的。

2.3 残差网络(ResNet)

现实情况是直接让一些层去拟合一个隐藏的恒等

映射函数 $H(X) = x$ 相对来说是比较困难的, 这是深度网络训练困难的原因。但是, 如果把网络结构设计为 $H(X) = F(x) + x$, 如图2所示。这样可以将上式转换成学习一个残差函数 $H(X) = F(x) - x$ 。此时, 只需 $F(x) = 0$, 就可以轻易构成一个恒等的映射 $H(X) = x$ 。此时, 拟合残差也会变得更加容易。




图2 ResNet 结构简图

网络结构的基本要求: (1)输出特征映射大小相同的网络层需要有相同数量的过滤器, 即通道数相同; (2)当特征映射大小减半时(经过池化层), 通道数量翻倍。

残差单元的结构表示为:

$$x_{l+1} = x_l + F(x_l, w_l) \tag{5}$$

$$F(x_l, w_l) = w_l \sigma(w_{l-1} x_{l-1}) \tag{6}$$

σ 为激活函数, C 为损失函数:

$$\frac{\partial C}{\partial x_l} = \frac{\partial C}{\partial x_L} \frac{\partial x_L}{\partial x_l} = \frac{\partial C}{\partial x_L} (1 + \frac{\partial}{\partial x_l} \sum_{i=1}^{L-1} F(x_i, w_i)) \tag{7}$$

2.4 Very Deep Convolutional Networks(VDSR)

残差结构被运用到大量的实际运用中, 在图像超分辨率重建领域, 表现最直观模型是 VDSR, 在 2016 年时提出, 通过残差网络来解决加深网络而导致的梯度问题^[8]。

VDSR 将网络结构加深到 20 层, 实验验证在图像超分辨率重建上达到了很好的效果, 采取了残差学习来提高学习率, 防止因为网络结构太深对梯度传输产生障碍。并且为了防止卷积使得图像越来越小, 在下次卷积前, 对图像进行补 0 操作。VDSR 的第三点特别之处在于将不同大小倍数的图像混合在一起训练, 这样训练出来的一个模型就可以解决不同倍数的超分辨率问题。




图1 SRCNN 网络结构图

3 模型设计及算法流程

为了有效提高图像超分辨率重建的效果,本文在原始SRCNN的基础上加深了网络结构,但是伴随着网络结构的增加,网络负重也增加,因此为了解决这个问题提出了本文的网络模型。

3.1 模型设计

在本节中,将详细介绍本文所设计的 ResNet 和 SRCNN 相结合的图像超分辨率重建模型。在 VDSR 及其他典型深度学习的图像超分辨率重建算法中,皆有提及图像重建的效果随着网络层次的加深而提高,加深网络结构虽然会得到不错的效果,但随着深度到达一定的程度时,继续增加深度会导致网络模型误差变大的现象发生。本文主要采用残差学习来减少网络的负重,简单来说,网络不需要去记忆太多的信息,相较于非残差模式,非残差模式随着网络层数的增多,需要记录的特征也随之增多,对于位于深层次的卷积层而言,一些图像信息特征已经丢失(这是由于网络负载过大造成),因此可以采用残差学习一定程度上缓解这个问题。

残差学习的目的类似于 ResNet 结构模型中的残差学习单元。输入低分辨率图像 x , 网络模型表示为 y , 当传统卷积神经网络到达一定的深度时,可以使得 $F(x)$ 逼近 y , 此时继续增加网络模型的深度可能会造成饱和目标函数的偏移,因此在 RDSR-a 模型中,采用残差学的方法将学习目标转换成 $y-x$, 使得模型达到继续优化的效果。在网络模型中加入递归学习的方法,为了达到不增加参数的效果,递归层的卷积层之间权值共享,从而提高学习率。

如图3所示,是简化的网络模型,采取局部残差学习和全局残差学习相结合的方法,所提出的网络模型可以解释成五个步骤:特征提取、收缩、非线性映射、扩张、最后的重建。

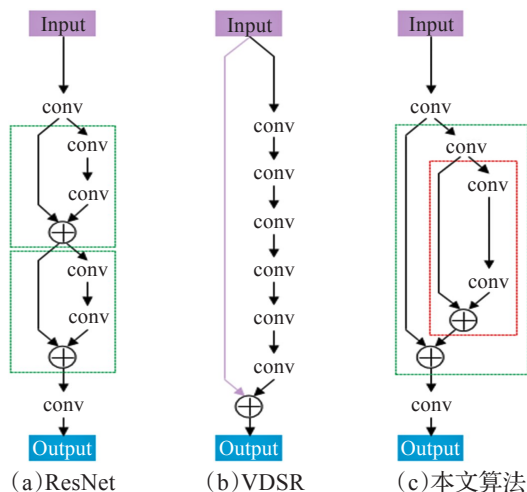


图3 简化的网络模型

第一部分是特征提取阶段,传统 SRCNN 仅有三层卷积层,感受野较低,为了增加感受野,采用加深网络结

构的方法。随着网络结构的加深,感受野逐步变大,感受野越大表示其能接触到的原始图像范围就越大,可以根据更多的像素点去推断结果像素点。但是随之而来的是运算复杂度的提升,因此,第二部分是应用 1×1 的卷积核进行降维,减少网络参数,降低算法的复杂度。第三部分非线性映射部分考虑到加深的网络结构可能会造成学习速率降低,或者梯度爆炸、梯度消失的问题,采取残差学习的方法提高学习率,并且对梯度进行裁剪,提高学习率。

可以通过残差学习提高学习率的方法来解决网络层次加深带来的梯度消失的问题,梯度爆炸和梯度消失的原因可以理解为信息流的过大或者过小,产生这个问题的原因在于网络的负载过大。在深度网络中,图3(c)红色部分即为此网络结构的深度部分。实验部分最先采用6层卷积层,重建效果并不明显,因此本文采用16层卷积。此外,残差学习在一定程度上加快了算法的收敛速度。

第四部分应用 1×1 的卷积核扩维到原始维度,最后反卷积重建,实现上采样操作,回复原始图像大小,达到重建后的图像和原始尺寸相同。

算法描述:

输入:低分辨率图像

输出:高分辨率图像

步骤1 选取 3×3 的卷积核对低分辨率图像进行特征提取;

步骤2 选取 1×1 的卷积核进行降维,减少网络参数;

步骤3 进入图3(c)网络结构 ResNet 结构中进行训练;

步骤4 应用 1×1 的卷积核扩维;

步骤5 进入反卷积层,上采样到原始目标图像尺寸;

步骤6 重建出最终的高分辨率图像。

3.2 损失函数

考虑到传统基于卷积神经网络的图像超分辨率重建的图片通过逐步卷积会导致图片越来越小,不适合一个很深的网络。减少 SRCNN 中双三次插值的预处理,将原始图像的尺寸作为输入,直接进行卷积操作。考虑到当采用传统卷积操作时,感受野小,边缘区域考虑得较少,于是采取对卷积结果做裁剪的方法,剪去边界区域,但是会使得图像变得更小,因此下一次卷积前,对图像进行补0,将重建图像恢复到原始图像的大小,这样不仅解决了深度浅的问题,也加深了对图像边缘的操作,通过实验证明了对图像细节处理确实是有明显的改进。

损失函数沿用 SRCNN 中的均方误差(MSE):

$$L(\theta) = \frac{1}{n} \sum_{i=1}^n \|F(Y_i; \theta) - X_i\|^2 \quad (8)$$

其中, n 表示的是训练样本的数量。使用具有标准反向

传播的随机梯度下降法使损失最小化^[19]。如果只有损失函数可推导,CNN并不排除使用其他类型的损失函数。如果在训练过程中给出更好的感知度量,它能够灵活地针对网络去适应度量。相反,这样的灵活性通常来说对于传统的“手工”方法是很难实现的。

3.3 反卷积重建

在实际实验中,卷积操作会使图像越来越小,考虑到这个影响,采取反卷积操作对图像进行重建,能够多尺度放大特征映射图。并没有像SRCNN采用双三次插值预处理是由于双三次插值的预处理限制了学习速度^[20-21]。反卷积(Deconvolution)的概念第一次出现是Zeiler在2010年发表的论文《Deconvolutional networks》中,但是并没有指定反卷积这个名字,反卷积这个术语正式的使用是在其之后的工作中^[22]。通过反卷积可以使图像变大,实现图像的上采样效果得到想要的图像大小,反卷积的反向传播即卷积层的前向传播,卷积层的前向传播为乘以 C ,反卷积层的反向传播为乘以 $(C^T)^T$ 。

4 实验结果分析

本文所有程序在 tensorflow 环境 spyder 编译器下运行,硬件平台为 PC:Inter® Core™ i7-8750H CPU@2.20 GHz,内存为 8 GB。交叉验证法采用传统的留出法,将数据集分为训练集、验证集和测试集三部分。

在实验中,训练此次改进的残差卷积神经网络的图像集为常用的 91 幅自然图像,采取与 VDSR 算法中相同的缩放、旋转的方式进行样本增强。

并且同样运用 Set5 和 Set14、Urban100 测试集对残差网络进行测试。这三个数据集为图像超分辨率重建常用数据集,Set5 数据集包含动植物图像,Set14 包含动植物、景物图像,细节信息比 Set5 更多,Urbn100 数据集包含的是城市建筑图像,边缘信息多,重构难度大。

4.1 评价指标

本文采取的衡量标准是图像超分辨率中常用的评价指标:峰值信噪比(Peak Signal to Noise Ratio,PSNR)和图像的结构相似性(Structural Similarity,SSIM)。

通常来讲,更高的 PSNR 表示了更高分辨率的图像,一般情况下通过均方误差(Mean Square Error,MSE)进行定义:

$$MSE = \frac{1}{mn} \sum_{i=0}^{m-1} \sum_{j=0}^{n-1} [I(i,j) - K(i,j)]^2 \tag{9}$$

峰值信噪比(PSNR)表示为:

$$PSNR = 20 \cdot \lg(\frac{MAX_I}{\sqrt{MSE}}) \tag{10}$$

其中, I 和 K 表示两个 $m \times n$ 大小的图像。规定 PSNR 的单位是 dB,且数值越小表示失真越大,即数值越大失真越小。

结构相似性(SSIM)表示为:

$$SSIM(x,y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_1^2 + \mu_2^2 + c_1)(\sigma_1^2 + \sigma_2^2 + c_2)} \tag{11}$$

其中, μ_x 表示 x 的平均值, μ_y 表示 y 的平均值, σ_x 表示 x 的方差, σ_y 表示 y 的方差, σ_{xy} 表示 x 和 y 的协方差。且规定结构相似性的范围是-1到+1(即 $SSIM \in (-1, 0]$)。

4.2 在数据集上的对比

本文算法主要从加深网络结构、降低网络复杂度方向进行研究。图4表示在Set5测试集上本文提出的超分辨率重建算法和其他算法的对比,Set5中的蝴蝶图像在放大细节后可以观察到,本文算法的重建效果更好,细节纹理更加清晰。图5是在Set14测试集上本文提出的超分辨率重建算法和其他算法的对比,Set14中人像图像在放大帽子边缘的细节后可以看出,本文重建算法的纹理与Bicubic重建的图像和SRCNN、VDSR重建的图像对比均更加清晰。图6是在Urban100测试集上本文提出的超分辨率重建算法和其他算法的对比,Urbn100中图像在放大左上角的细节后可以看出,本文重建算法的纹理与Bicubic、SRCNN、VDSR重建的图像对比均更加清晰。因此,本文提出的增加网络层数引进残差网络的图像超分辨率重建效果从视觉效果来说是有所改进的。




图4 Set5测试集上的对比




图5 Set14测试集上的对比

表1表示了本文方法和Bicubic、SRCNN、VDSR在两个数据集上且上采样因子分别为2、3、4时的对比,可

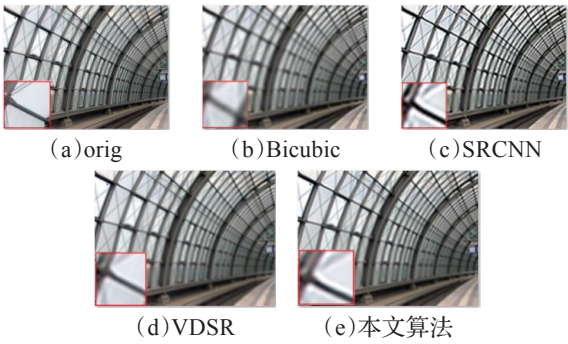


图6 Urban100测试集上的对比

以看出Bicubic、SRCNN、VDSR三种方法在scale值为2时PSNR和SSIM的值最大。由于本文采取反卷积扩大尺寸,预处理中并未做上采样操作,所以本文结果与其他三种方法最好的情况进行对比。本文算法的PSNR与SSIM值为采取八组实验后的平均值。Set5中,本文算法的PSNR值比VDSR提高0.07 dB,比SRCNN提高0.29 dB,比Bicubic提高3.92 dB,本文算法的SSIM值比VDSR提高0.01。Set14中,PSNR值最高的是VDSR,可以看出本文的33.79 dB比VDSR的33.03 dB提高了

表1 各方法在不同数据集下的PSNR、SSIM值对比

数据集	方法	scale	PSNR/dB	SSIM
Set5	Bicubic	2	32.16	0.92
		3	30.32	0.88
		4	28.26	0.85
	SRCNN	2	35.79	0.95
		3	31.46	0.90
		4	30.07	0.86
	VDSR	2	36.01	0.95
		3	33.72	0.92
		4	31.43	0.88
	本文算法		36.08	0.96
Set14	Bicubic	2	30.75	0.85
		3	27.66	0.71
		4	25.43	0.59
	SRCNN	2	32.41	0.89
		3	29.95	0.21
		4	27.96	0.67
	VDSR	2	33.03	0.90
		3	29.77	0.83
		4	28.01	0.76
	本文算法		33.79	0.91
Urban100	Bicubic	2	26.88	0.84
		3	24.46	0.73
		4	23.15	0.66
	SRCNN	2	29.52	0.90
		3	26.24	0.80
		4	24.54	0.72
	VDSR	2	30.77	0.91
		3	27.14	0.83
		4	25.18	0.75
	本文算法		31.01	0.92

0.76 dB,本文算法的SSIM值为0.91也比SSIM值为0.90的VDSR和SRCNN算法要高。Urban100中,PSNR值最高的是VDSR,可以看出本文的31.01 dB比VDSR的30.77 dB提高了0.24 dB,本文算法的SSIM值为0.92也比SSIM值为0.91的VDSR算法高。因此可以得出本文算法在数据上优于其他算法的结论。

4.3 消融法

本文主要从网络深度和网络结构两个方面对原有的SRCNN算法进行改进,提出了两点改进^[23]:

- (1)采取局部残差和全局残差相结合。
 - (2)取消双三次插值,在最后增加反卷积层,且在残差网络结构首尾分别加入1×1的卷积核进行降维和扩维。
- 随着网络结构的加深,必然会带来算法复杂度的提高,采取1×1卷积核降维可以在不增加参数的情况下降低算法复杂度,有效地提高算法效率,尾部1×1扩维到原始维度。

为了验证对残差网络进行降维和扩维的有效性,本文采取消融法,对进行降维和扩维的算法验证,采取同样的Set5、Set14、Urban100数据集,训练集也采取相同的训练集,进行同样的缩放操作。采取八组实验取平均值,在Set5上的PSNR和SSIM值分别为36.03 dB和0.95,在Set14上的PSNR和SSIM值分别为33.41 dB和0.91。在Urban100上的PSNR和SSIM值分别为30.89 dB和0.91。与本文提出的方法对比,本文算法的PSNR值分别高了0.05 dB、0.38 dB、0.12 dB,而SSIM值在数据集Set5、Urban100上也提升了0.01。

因此,从客观评价指标中,可以得出本文算法的有效性。和SRCNN、VDSR算法相比,本文算法在主观和客观评价指标上有所提升。

5 结语

SRCNN的训练速度较慢且存在网络深度的问题,针对这一缺点,本文提出加深卷积层深度,且为了避免深度太深无法训练加入了残差网络ResNet,减少了SRCNN中Bicubic步骤,在训练时只fine-tuning最后的反卷积层,提高了训练速度。引入了全局模式的残差学习和局部模式的残差学习相结合的方式降低在深层网络中由于网络加深造成的训练难度,并且使用由残差单元组成的递归块来学习高分辨率和低分辨率图像之间的残差图像,可以通过增加网络深度来提高精度,而不需要添加任何权重参数。该算法能够更好地重建图像的高频纹理信息,不论是客观评价还是视觉效果上都取得了较好的效果^[24]。

对于未来的研究方向,观察到此次的算法主要对网络结构进行改进,有一定的改进效果,但是距离更好的优化还有一定的改进空间,因此在接下来的研究工作中,将考虑到改进现有的其他算法,例如GAN网络,并

考虑图像超分辨率重建在实际运用中的实验,例如医学图像、光学遥感图像中的运用等^[25]。

参考文献:

- [1] 苏衡,周杰,张志浩.超分辨率图像重建方法综述[J].自动化学报,2013,39(8):1202-1213.
- [2] Zhang D, Wu X. An edge-guided image interpolation algorithm via directional filtering and data fusion[J]. IEEE Transactions on Image Processing, 2006, 15(8): 2226-2238.
- [3] Rasti P, Demirel H, Anbarjafari G. Image resolution enhancement by using interpolation followed by iterative back projection[C]//21st Signal Processing and Communications Applications Conference, 2013: 1-4.
- [4] Zhou F, Yuan T, Yang W, et al. Single-image super-resolution based on compact KPCA coding and kernel regression[J]. IEEE Signal Processing Letters, 2015, 22(3): 336-340.
- [5] Yang J, Wright J, Huang T S, et al. Image super-resolution via sparse representation[J]. IEEE Transactions on Image Processing, 2010, 19(11): 2861-2873.
- [6] Shang L, Liu S, Sun Z. Image super-resolution reconstruction based on sparse representation and POCS method[C]//International Conference on Intelligent Computing, 2015: 348-356.
- [7] Dong C, Loy C C, He K M, et al. Image super-resolution using deep convolutional networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2016, 38(2): 295-307.
- [8] Kim J, Lee J K, Lee K M. Accurate image super-resolution using very deep convolutional networks[C]//IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1646-1654.
- [9] 刘振圻,包立君,陈忠.基于自适应对偶字典的磁共振图像的超分辨率重建[J].光电技术应用,2013,28(4):55-60.
- [10] Zhu Xuan, Jin Peng, Wang Xianxian, et al. Multi-frame image super-resolution reconstruction via low-rank fusion combined with sparse coding[J]. Multimedia Tools and Applications, 2019, 78(6): 7143-7154.
- [11] 陶志强,李海林,张红兵.基于新边缘指导插值的迭代反投影超分辨率重建算法[J].计算机工程,2016,42(6): 255-260.
- [12] 黄吉庆,王丽会,秦进,等.基于多种正则化的改进超分辨率重建算法[J].计算机工程与应用,2018,54(15):22-28.
- [13] 王建新,吴宏林,张建明,等.残差字典学习的快速图像超分辨率算法[J].计算机科学与探索,2018,12(8): 1305-1314.
- [14] 邢晓羊,魏敏,符颖.基于特征损失的医学图像超分辨率重建[J].计算机工程与应用,2018,54(20):202-207.
- [15] Mourabit I E, Rhabi M E, Laghrib A, et al. A new denoising model for multi-frame super-resolution image reconstruction[J]. Signal Processing, 2017, 132: 51-65.
- [16] 胡长胜,詹曙,吴从中.基于深度特征学习的图像超分辨率重建[J].自动化学报,2017(5):814-821.
- [17] Goodfellow I, Bengio Y, Courville A, et al. Deep learning[M]. Cambridge: MIT Press, 2016: 326-366.
- [18] Gu J, Wang Z, Kuen J, et al. Recent advances in convolutional neural networks[J]. Pattern Recognition, 2018, 77: 354-377.
- [19] Nair V, Hinton G E. Rectified linear units improve restricted Boltzmann machines[C]//Proceedings of ICML, 2010: 807-814.
- [20] LeCun Y, Boser B, Denker J S, et al. Backpropagation applied to handwritten zip code recognition[J]. Neural Computation, 1989: 541-551.
- [21] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [22] Zeiler M D, Taylor G W, Fergus R. Adaptive deconvolutional networks for mid and high level feature learning[C]//International Conference on Computer Vision, 2011.
- [23] 端木春江,戚河平.一种新的基于稀疏表示的超分辨率重建算法[J].智能处理与应用,2018(8):108-111.
- [24] Cui L, Wang J, Lee S. Mathing pursuit of an adaptive impulse dictionary for bearing fault diagnosis[J]. Journal of Sound and Vibration, 2014, 333(5): 2840-2862.
- [25] Karahanoglu N B, Erdogan H. Aorthogonal matching pursuit: best-first research for compressed sensing signal recovery[J]. Digital Signal Processing, 2012, 22(7): 555-568.