

基于特征融合的单幅图像超分辨率重构方法

陈 平

(徽商职业学院, 安徽 合肥 230000)

摘要: 目的 针对低分辨率图像不清晰、质量低等问题, 提出一种新的特征融合超分辨率重构网络。方法 所提网络包括特征提取、特征融合、图像重构 3 个部分。首先, 网络通过卷积和局部残差学习, 提取到不同层次的特征。之后, 网络自适应地保存浅层的信息, 并将其传递到更深的层次, 最后通过拼接层进行特征融合。结果 通过非线性映射实现高分辨率图像的重建。结论 实验结果表明, 该方法能明显提高低分辨率图像的质量。

关键词: 卷积神经网络; 低分辨率; 特征提取; 特征融合

中图分类号: TP 389.1

文献标识码: A

DOI: 10.3969/j.issn.1673-1492.2022.03.007

Method of Single Image Super-resolution Reconstruction Based on Feature Fusion

CHEN Ping

(Huishang Vocational College, Hefei, Anhui 230000, China)

Abstract: **Objective** For the problems of unclear low-resolution images and low quality, a new feature fusion super-resolution reconstruction network (FFSRN) was proposed. **Methods** The proposed network included three parts: feature extraction, feature fusion and image reconstruction. First, the network extracted features at different levels through convolution and local residual learning. Second, the network adaptively saved the shallow information and transferred it to a deeper level, and then performed feature fusion through the splicing layer. **Results** The reconstruction of high-resolution images was achieved through nonlinear mapping. **Conclusion** The experimental results showed that this method can improve the quality of low-resolution images significantly.

Keywords: convolutional neural network; low resolution; feature extraction; feature fusion

0 引 言

图像是一种直接获得的可视化信息, 人们可以通过图像获取和利用对自己有价值的信息。随着社会的发展, 各行各业对图像质量的要求也越来越高, 例如交通部门的电子监控系统、医学和天文学领域等。数字图像是由数字设备如摄像机、数码相机、录像机等电子设备生成的图像^[1]。然而在实际生活中, 经常会因为环境或设备本身原因造成图像质量的降低^[2]。因此提高图像的分辨率在实际应用中具有很大意义。

为了获得高分辨率的图像, 最直接的方法是改进或更换硬件设备, 但成本较高。因此图像超分辨率重构 (super resolution, SR) 技术已成为解决这一问题的主要途径^[3]。

在计算机视觉中, SR 是具有很大的吸引力和挑战性的任务, 目的是从一幅或多幅低分辨率图像中生成详细的和空间分辨率强的图像。通常 SR 可以分为 3 类: 基于插值的方法、基于重构的方法和基于学习的方法^[4-5]。基于插值的方法简单、快速, 但结果过于平滑, 振铃现象严重。基于重建的方法利用数学模型重建高分辨率图像, 但计算复杂。基于学习的方法充分利用了图像固有的先验知识。该方法能很好地保留图像的细节, 适用于处理特殊图像, 如光谱图像^[6]、红外图像^[7]和医学图像^[8]。但是基于学习的方法需

来稿日期: 2021-04-06

基金项目: 2019 安徽省教育厅自然科学研究重点项目: “基于卷积神经网络的深度学习算法与图像识别应用研究”(KJ2019A1242)

作者简介: 陈平(1987-), 女, 安徽合肥人, 讲师, 硕士。主要研究方向: 人工智能与机器学习、深度学习、图像处理。

要大量的训练样本，训练的时间代价也很高。

本文提出了一种新的图像超分辨率算法，即特征融合卷积超分辨率重构神经网络（FFSRN）。该方法由 3 个部分组成，第一部分是提取 LR 图像的特征，第二部分是提取到的各个层次 LR 图像的特征传递到深层并融合，第三部分是重构 HR 图像。本文的内容组织如下：在第一节中，对所提出的 SR 方法进行了详细的说明，第二节给出了实验结果，第三节对本文进行了总结。

1 本文方法

1.1 GoogLeNet 卷积神经网络

现在卷积神经网络越来越大，性能也越来越好。在一般情况下，神经网络的性能可以通过增加层数和每层滤波器的数目来提高^[9]。GoogLeNet 是 2014 年 ImageNet 的冠军，它的体系结构被认为是网络中的网络^[10-11]。主模块称为 Inception 架构，是一个很小的网络，在该网络中，对图像同时进行不同大小的滤波器卷积，得到不同的特征图，然后将这些特征图连接在一起，形成新的融合特征图。该结构减少了滤波器大小对神经网络性能的影响，可以提取更多的特征。因此 GoogLeNet 有非常好的表现。该方法受 Inception 架构的启发，在第一层使用不同的滤波器大小来提取更多的特征，提高图像的重建性能^[12-13]。

1.2 特征融合超分辨率重构网络

特征融合超分辨率重构网络（FFSRN）是 LR 图像与对应的 HR 图像之间的端到端的映射。FFSRN 实验验证了通过调整网络的层数、滤波器的大小和每层滤波器的数目可以影响重构结果。因此本文将使用 3 种不同的滤波器尺寸，同时对 LR 图像进行处理，然后将不同的特征图连接起来共同形成新的融合特征图，可以提高图像重建的质量，如图 1 所示。

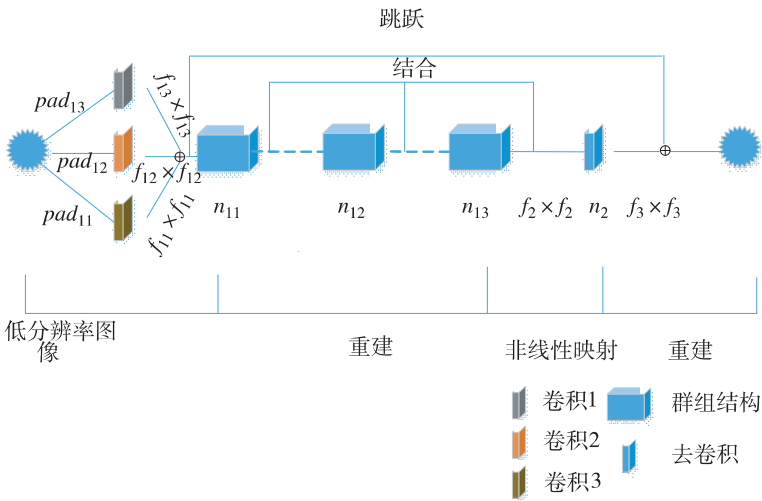


图 1 特征融合超分辨率重构网络结构

在接下来的叙述中， X 代表高分辨率图像， Y 为双三次低分辨率图像插值， X 和 Y 大小，尺寸相同。 $F(Y)$ 表示为图像的重构， $F(Y)$ 与 X 最相似。

1) 特征提取

在第一层中，图像同时被 3 层包含卷积不同尺寸卷积层的滤波器 f_{11} ， f_{12} 和 f_{13} 进行特征提取（对应的分别是 pad_{11} ， pad_{12} ， pad_{13} ）。这 3 个特征图相互关联共同形成新的一层融合特征图，作为下一层的输入。特征提取与表示为

$$\begin{aligned} F_1(Y) &= \max(0, W_{11} * Y + B_{11}) \\ &\oplus \max(0, W_{12} * Y + B_{12}) \\ &\oplus \max(0, W_{13} * Y + B_{13}) \end{aligned} \tag{1}$$

其中， $f_{11} \times f_{11}$ ， $f_{12} \times f_{12}$ ， $f_{13} \times f_{13}$ 为滤波器尺寸， W_{11} ， W_{12} ， W_{13} 为滤波器权值， B_{11} ， B_{12} ， B_{13} 为滤波器偏值， n_{11} ， n_{12} ， n_{13} 滤波器的个数 和 B_{11} ， B_{12} ， B_{13} 为 n 维空间向量，假设 $n_{11} = n_{12} = n_{13} = n_1$ ，其中 ‘ $*$ ’ 表示卷

积操作，‘ \oplus ’表示连接符。

2) 非线性映射

非线性映射是指将 1 个三维图像特征映射到 2 个 n 维特征。非线性映射表示为

$$F_2(Y) = \max(0, W_2 * F_1(Y) + B_2) \tag{2}$$

其中， $f_2 \times f_2$ 是滤波器的大小， n_2 是滤波器的数目。其中 W_2 和 B_2 分别是滤波器的权重和滤波器的偏置。二维矢量表示 n_2 维高分辨率特征并被用于最终的重建。

3) 图像重建

从重构滤波器卷积 n_2 维高分辨率特征中得到最终的 HR 图像。图像重建表示为

$$F(Y) = W_3 * F_2(Y) + B_3 \tag{3}$$

其中， W_3 是对应于 $f_3 \times f_3$ 滤波器的滤波器权重， B_3 是标量。

1.3 损失函数

超分辨率重构算法一般习惯使用均方误差（mean squared error, MSE）作为损失函数来测试训练模型的精度和更新模型的参数。所以在本文中，我们仍然使用 MSE 作为损失函数来训练神经网络，表达式为

$$L(\Theta) = \frac{1}{n} \sum_{i=1}^n \| F(Y_i; \Theta) - X_i \|^2 \tag{4}$$

其中 n 是训练图像的数量， Y_i 是采用双三次插值的第 i 个低分辨率图像， X_i 是低分辨率图像对应的高分辨率图像， $F(Y_i; \Theta)$ 由网络模型 Θ 重建高分辨率图像。

2 实 验

2.1 实验数据和特征融合卷积超分辨率重构网络模型结果

本文采用 DIV2K 数据集。数据集 1 包括 96 幅图像，训练集为 91 幅，测试集为 5 幅（Set5）（图 2）。数据集 2 包括 986 幅图像，训练集为 976 幅，测试集为 10 幅（Set10），其中 5 幅与 Set5 相同。

本实验分别使用 Dataset1 和 Dataset2 训练 FFSRN 模型。用 FFSRN 模型、FFSRN Dataset1 模型、FFSRN Dataset2 模型对 Set5 进行测试（图 2）。注意 FFSRN 模型是由 ImageNet 进行训练的，因此只能得到最终的重建结果。




图 2 FFSRN 网络实验结果

图 3 和图 4 为实验在训练和测试时所得的 PSNR 和 SSIM 指标，网络训练迭代次数为 1 000 次，PSNR 值可达 38.5，SSIM 值可达 0.955。此外实验表明训练数据越多，网络的性能越好。并且，对于图像重建，自然图像集优于合成数据集。




图 3 训练集的 PSNR 指标




图 4 训练集的 SSIM 指标

2.2 损失函数的收敛性分析

下图 5 和图 6 分别为 Dataset1 和 Dataset2 数据集训练时的损失函数收敛图。由图可知，1 000 次迭代已接近收敛，损失函数的收敛情况相似。




图 5 Dataset1 MSE 收敛曲线




图 6 Dataset2 MSE 收敛曲线图

2.3 FFSRN 网络参数

为了提高图像的重建质量，在第一层设计了 3 种不同的滤波器尺寸，特征融合卷积超分辨率重构网络。FFSRN1：

$(f_{11} = 5, f_{12} = 7, f_{13} = 9, f_2 = 3, f_3 = 5;$
 $n_{11} = n_{12} = n_{13} = 32, n_2 = 32, n_3 = 1);$

FFSRN2：

$(f_{11} = 7, f_{12} = 9, f_{13} = 11, f_2 = 3, f_3 = 5;$
 $n_{11} = n_{12} = n_{13} = 32, n_2 = 32, n_3 = 1);$

FFSRN3：

$(f_{11} = 9, f_{12} = 11, f_{13} = 13, f_2 = 3, f_3 = 5;$
 $n_{11} = n_{12} = n_{13} = 32, n_2 = 32, n_3 = 1)。$

2.4 模型参数

1) 滤波器的数量

在 FFSRN2 中，每层的过滤数为 $n_{11} = n_{12} = n_{13} = 32, n_2 = 32, n_3 = 1$ 。本实验改变了第一层和第二层的过滤数，即 FFSRN4 和 FFSRN5。

2) 滤波器的尺寸

在 FFSRN2 中，非线性映射层的滤波器大小为 $f_2 = 3$ 。将非线性映射层的滤波器大小调整为 FFSRN6 ($f_2 = 1$) 和 FFSRN7 ($f_2 = 5$)。在训练集上的测试结果如实验表明，FFSRN2 的平均 PSNR 值高于其他两种模型，因此 FFSRN2 模型仍然是最佳选择。

3 结 论

本文提出了一种自然图像超分辨率重建方法。基于 FFSRN 网络算法，该方法在第一层卷积过程中使用多尺度并行滤波器，以获得更多的图像特征。在第二层实现非线性映射，然后在第三层进行超分辨率重建。实验表明，该模型能有效提高低分辨率图像的质量，但由于实际的如法医图像、车牌大小等图像通常很小，甚至只有十几个像素，因此，实验结果不是很理想。所以在后续工作中将研究高倍化重建方法。

参考文献：

[1] 王容,张永辉,张健,等. 基于 CNN 的图像超分辨率重建方法[J]. 计算机工程与设计,2019,40(6):1654-1659.
[2] CHEN S L, HUANG H Y, LUO C. A Low-cost high-quality adaptive scalar for real-time multimedia applications[J]. IEEE Transactions on Circuits & Systems for Video Technology,2011,21(11):1600-1611.

[3] CHAVEZ-ROMAN H,PONOMARYOV V. Super-resolution image generation using wavelet domain interpolation with edge extraction via a sparse representation[J]. IEEE Geoscience & Remote Sensing Letters,2014,11(10):1777-1781.

[4] LI X,HU Y,GAO X,et al. A multi-frame image super-resolution method[J]. Signal Processing,2010,90(2):405-414.

[5] Gao X,Wang Q,Li X,et al. Zernike-Moment-based image super resolution[J]. IEEE Transactions on Image Processing, 2011,20(10):2738-2747.

[6] YU J,GAO X,TAO D,et al. A unified learning framework for single image super-resolution[J]. IEEE Transactions on Neural Networks & Learning Systems,2014,25(4):780-792.

[7] 南方哲,钱育蓉,行艳妮,等. 基于深度学习的单图像超分辨率重建研究综述[J]. 计算机应用研究,2020,37(2):321-326.

[8] 刘晨羽,蒋云飞,李学明. 基于卷积神经网络的单幅图像超分辨率重建算法[J]. 计算机辅助设计与图形学学报,2017,29 (9):1643-1649.

[9] 蔡迎春. 基于深度卷积神经网络的图像超分辨率重建算法[D]. 徐州:中国矿业大学,2019.

[10] KER J,WANG L,RAO J,et al. Deep learning applications in medical image analysis[J]. IEEE Access,2017,PP(99):1-1.

[11] 刘一胶. 基于深度学习的单张低分辨率图像的超分辨率技术的研究[D]. 北京:北京邮电大学,2019.

[12] DONG C,CHEN C L,HE K,et al. Image super-resolution using deep convolutional networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence,2016,38(2):295-307.

[13] 孙旭,李晓光,李嘉锋,等. 基于深度学习的图像超分辨率复原研究进展[J]. 自动化学报,2017,43(5):697-709.

[责任编辑：王荣荣 英文编辑：刘彦哲]

(上接第 36 页)

去噪处理,最大限度减少信号损失,保证信号传输真实性;最后利用基于峰值点修正的资源管理大数据挖掘方法,对回波波形进行拟合纠正,能够更加准确地发现峰值点位置,挖掘误差在-50~50 mm 波动,运用幅度临界值把信号中幅度较小的伪峰值点进行过滤剔除,以此提升挖掘精准度,保证挖掘结果的可靠性。

参考文献：

[1] 黎静华,黄玉金,黄乾. 基于改进混沌时间序列的风电功率区间预测方法[J]. 电力自动化设备,2019,301(5):60-67+75.

[2] 杨洪军,徐娟娟,刘杰. 基于 VMD 和 GRNN 的混沌时间序列预测[J]. 计算机仿真,2019,36(3):454-458.

[3] 黄飞江,陈演羽,李廷会,等. 基于灰色模型和混沌时间序列的卫星钟差预测算法[J]. 电子学报,2019,47(7):1416-1424.

[4] 吴悦文,吴恒,任杰,等. 面向大数据分析作业的启发式云资源供给方法[J]. 软件学报,2020,31(6):280-294.

[5] 杨鹏,申洪涛,陶鹏,等. 云平台下时间序列数据并行化排列熵特征提取方法[J]. 电力自动化设备,2019,39(4):217-223.

[6] 吴佳懋,李艳,符一健. 基于粗糙集-混沌时间序列 Elman 神经网络的短期用电量预测[J]. 电力系统保护与控制,2019,47 (3):29-36.

[7] 陈海涛,邱林,王文川,等. 基于信息扩散和混沌理论的西安市玉米生育期旱涝特征[J]. 地理学报,2020,75(9):99-112.

[8] 吴林,吴超,吴娥. 大数据视域下安全信息资源管理模式研究[J]. 科技管理研究,2020,40(9):163-169.

[9] 杨俊艳,樊迪,黄国平. 自然资源管理背景下的时空大数据平台建设[J]. 测绘通报,2020,514(1):127-130.

[10] 马盛红. 大数据时代国有企业人力资源精细化管理模式的构建[J]. 领导科学,2020,781(20):97-99.

[11] 梁斌,仵晓娟,李继玲,等. 林果大数据分析应用平台设计研究:以新疆生产建设兵团为例[J]. 中南林业科技大学学报, 2020,40(9):178-187.

[责任编辑：刘志媛 英文编辑：刘彦哲]