

◎热点与综述◎

改进的卷积神经网络单幅图像超分辨率重建

曾接贤,倪申龙

南昌航空大学 江西省图像处理与模式识别重点实验室,南昌 330063

摘 要:针对经典的基于卷积神经网络的单幅图像超分辨率重建方法网络较浅、提取的特征少、重建图像模糊等问题,提出了一种改进的卷积神经网络的单幅图像超分辨率重建方法,设计了由密集残差网络和反卷积网络组成的新型深度卷积神经网络结构。原始低分辨率图像输入网络,利用密集残差学习网络获取更丰富的有效特征并加快特征梯度流动,其次通过反卷积层将图像特征上采样到目标图像大小,再利用密集残差学习高维特征,最后融合不同卷积核提取的特征得到最终的重建图像。在Set5和Set14数据集上进行了实验,并和Bicubic、K-SVD、SelfEx、SRCNN等经典重建方法进行了对比,重建出的图像在整体清晰度和边缘锐度方面更好,另外峰值信噪比(PSNR)平均分别提高了2.69 dB、1.68 dB、0.74 dB和0.61 dB。实验结果表明,该方法能够获取更丰富的细节信息,得到更好的视觉效果,达到了图像超分辨率的增强任务。

关键词:图像超分辨率重建;深度学习;卷积神经网络;密集残差学习;反卷积

文献标志码:A **中图分类号:**TP391.41 **doi:**10.3778/j.issn.1002-8331.1812-0315

曾接贤,倪申龙.改进的卷积神经网络单幅图像超分辨率重建.计算机工程与应用,2019,55(13):1-7.

ZENG Jiexian, NI Shenlong. Improved super-resolution reconstruction of single image based on convolution neural network. Computer Engineering and Applications, 2019, 55(13): 1-7.

Improved Super-Resolution Reconstruction of Single Image Based on Convolution Neural Network

ZENG Jiexian, NI Shenlong

Key Laboratory of Jiangxi Province for Image Processing and Pattern Recognition, Nanchang Hangkong University, Nanchang 330063, China

Abstract: Aiming at the problems of classical super-resolution reconstruction method based on convolutional neural network, such as shallow network, less extracted features and blurred image reconstruction, an improved single image super-resolution based on convolutional neural network is proposed. In this way, a novel deep convolutional neural network structure consisting of a dense residual network and a deconvolution network is designed. Firstly, the original low-resolution image input network uses the dense residual learning network to obtain richer effective features and accelerate the feature gradient flow. Secondly, the image features are up sampled to the target image size through the deconvolution layer, and then the dense residual learning is used to get high dimensional features. Finally, the features extracted by different convolution kernels are obtained to obtain the final reconstructed image. Experiments are performed on the Set5 and Set14 datasets and compared with classical reconstruction methods such as Bicubic, K-SVD, SelfEx and SRCNN. The reconstructed images are better in terms of overall sharpness and edge sharpness. In addition, the Peak Signal-to-Noise Ratio (PSNR) averaged by 2.69 dB, 1.68 dB, 0.74 dB and 0.61 dB, respectively. The experimental results show that the proposed method can obtain more detailed information, which get better visual effects and achieve the enhanced task of image super-resolution.

Key words: image super-resolution reconstruction; deep learning; convolutional neural network; dense residual learning; deconvolution

基金项目:国家自然科学基金(No.61763033)。

作者简介:曾接贤(1958—),男,教授,CCF会员,研究领域为计算机视觉、图像处理和模式识别,E-mail:zengjx58@163.com;倪申龙(1992—),男,硕士研究生,CCF学生会会员,研究领域为计算机视觉、图像处理和模式识别。

收稿日期:2018-12-25 **修回日期:**2019-02-27 **文章编号:**1002-8331(2019)13-0001-07

CNKI网络出版:2019-03-11, <http://kns.cnki.net/kcms/detail/11.2127.tp.20190308.0941.002.html>

1 引言

图像超分辨率重建尤其是单幅图像超分辨率重建是计算机视觉领域中一个最经典的底层视觉问题。分辨率高的图像意味着图像很清晰,具有丰富的细节信息,能满足人们对图像信息的正确理解。然而在获取图像的过程中,由于受摄像设备、摄像角度、光线、天气和外界噪声等影响,往往获取到分辨率比较低的模糊图像,这些分辨率较低的图像不仅影响视觉上的美观而且严重阻碍了人类对图像信息的识别能力。因此,在这种情况下,图像超分辨率重建^[1-2]技术应运而生。图像超分辨率重建技术是指采用信号处理和图像处理的方法,在不增加硬件成本的前提下通过软件算法的方式从一幅或多幅低分辨率(Low-Resolution, LR)图像中尽可能重建出一幅高分辨率(High-Resolution, HR)图像的一种图像处理技术。随着图像超分辨率重建理论和技术的日益成熟,该技术已经广泛应用于卫星遥感、军事侦察、医学影像、视频监控和数字电视等领域,取得了显著成果。目前,超分辨率重建已然成为了一个热门的研究热点。

目前经典的超分辨率重建方法主要有3种:基于插值的方法^[3-4]、基于重建的方法^[5-6]和基于学习的方法^[7-10]。其中,基于插值的方法主要通过图像的先验知识在待插入位置插入像素值来获得较高分辨率的图像。经典的插值方法有最近邻插值法、双线性插值法和双3次插值法等,虽然插值方法计算简单,速度快,但视觉效果比较差,重建后的图像边缘和纹理细节等处通常存在模糊和明显的人为痕迹。基于重建的方法主要是根据图像的退化模型,利用相同场景下的序列图像之间的互补信息重建出对应的高分辨率图像。常用的基于重建的方法主要有凸集投影法(Projection onto Convex Sets, POCS)、迭代反投影法(Iterative Back-Projection, IBP)和最大后验概率估计法(Application of Maximum a Posteriori, MAP)等。传统的超分辨率重建方法虽然在一定程度上提高了图像的分辨率,改善了图像质量,但远远不能满足人眼对图像视觉信息的理解,而且整个重建过程需要消耗大量的计算量。

近几年随着机器学习和计算机视觉的迅猛发展,基于学习的方法成为了研究图像超分辨率重建的热门方法。该方法主要通过学习大量的高分辨率图像和对应

的低分辨率图像之间的映射,然后利用所学习到的映射关系重建出高分辨率图像。Dong等人^[11]受深度学习在目标识别、目标检测和跟踪等领域成功应用的启发,在超分辨率重建领域利用卷积神经网络(Convolutional Neural Network, CNN)进行图像重建(Super Resolution Convolutional Neural Network, SRCNN),通过简单的堆叠3层卷积层实现了图像超分辨率重建。但由于SRCNN网络结构只用了3层卷积层,结构过于简单,没有充分提取到图像的细节特征,重建后的图像还是存在模糊等问题。随后Kim等人^[12]加深了网络深度,提出了使用20层的卷积神经网络结构,为了防止因网络深度过大导致梯度爆炸等问题,采用跳过连接的方式将第一层卷积层的输出添加到网络的最后一层,提高了图像重建精度。但Kim提出的网络只是将第一层输出连接到最后一层,图像的有效特征可能会在中间层的流动过程中丢失。针对上述超分辨率重建算法的不足,本文提出了一种基于改进的卷积神经网络的超分辨率重建网络结构,在增加网络深度的同时将密集残差网络和反卷积层^[13]添加到网络模型中。密集残差网络是以多个小的基本残差学习单元通过密集连接的方式组合成一个大的残差网络,不仅能学习到更多丰富的高频信息,同时还避免了有效特征在网络传输过程中丢失的问题。利用反卷积层代替传统的双3次插值法进行图像上采样,减轻了网络的计算复杂度。网络以原始低分辨率图像作为输入,通过密集残差网络和反卷积层的学习,实现图像超分辨率重建精度的提升。

2 本文方法

为了获取更多的图像高频特征,有效提升单幅图像超分辨率重建精度,本文设计的网络并不是简单地堆叠卷积层,而是受He^[14]的影响,在网络中引入了密集残差网络结构,并采用反卷积代替双3次插值对图像进行上采样。设计的增强型的卷积神经网络图像超分辨率重建的网络结构如图1所示,图中的淡蓝色卷积层代表所提出的密集残差网络单元,将在2.1节详细介绍。整个网络结构主要包括特征映射、反卷积上采样和图像重建等三部分。首先将低分辨率图像输入网络,通过第一层卷积层提取图像的低级特征;然后利用密集残差学习模块进行特征非线性映射;再利用反卷积将映射后的特征




图1 改进后的重建网络结构

图上采样到目标重建大小;最后对上采样后的图像特征再次进行密集残差网络学习得到重建后的图像。每一个卷积层和反卷积层后面都需要一个激活函数^[15],本文选用ReLU^[16]作为网络的激活函数,因为ReLU激活函数计算量小,计算简便,加快了网络收敛速度,另外ReLU梯度一般是常数,能在一定程度上避免了梯度消失的问题,激活函数ReLU数学计算如公式(1)所示。下面将对整个网络的重建流程进行详细介绍。

$$f(x)=\max(0,x)=\begin{cases} x, & x\geq 0 \\ 0, & x<0 \end{cases} \tag{1}$$

2.1 特征非线性映射

在传统重建方法中,为了获取输入图像,利用双3次插值法对原始的高分辨率图像先进行预定尺度插值下采样,然后再按相同尺度插值上采样到目标图像大小,得到的插值图像即为重建网络的输入图像。这种利用双3次插值法获取到的输入图像存在两点不足之处:(1)因为在超分辨率重建领域中,单幅图像超分辨率重建旨在从一幅丢失了高频信息的低分辨率图像中恢复出一幅高分辨率图像,低分辨率图像和对应的高分辨率图像共享低频信息,以原始低分辨率图像作为网络输入,能够有效保留原始图像中的低频信息,有利于重建得到更精准的高分辨率图像。由于双3次插值是在像素域中进行,可能会破坏原始低分辨率图像中一些重要的低频信息,在超分辨率重建领域中,以低分辨率图像经过双3次插值上采样后的图像作为网络输入,不是特别适合图像重建。(2)先进行双3次插值放大操作使得图像计算由低频转向高频,显著增加了网络的计算复杂度,加重网络的训练难度。为了缓减上述问题并提高图像重建质量,本文直接以原始低分辨率图像作为网络的输入图像,经过第一层卷积层卷积后获得64通道的特征图。

针对图像超分辨率重建问题的特殊性,需要提取更多的特征信息以恢复丢失的高频信息,使得重建图像越接近真实的高分辨率图像。有研究认为,在卷积神经网络中,网络越深,提取到的特征信息越丰富。但是,随着网络深度的增加,一方面学习到的有效特征在网络传输过程中可能会丢失,另一方面可能导致网络在训练过程中会出现梯度消失等问题。因此,本文受He^[14]的启发,在网络中应用密集残差网络结构学习所丢失的高频细节信息。

He^[14]提出的残差网络主要是由卷积层、批归一化层BN(Batch Normalization)和激活函数堆叠而成,结构单元如图2所示。本文提出的残差学习模块与He提出的原始残差单元有两点不同;(1)本文提出的残差学习结构去除了原始残差单元中的批归一化层BN,因为超分辨率重建的目的是在不改变图像原有信息的情况下只改变分辨率大小,而BN层是将数据归一化到均值为0、方差为1的范围,改变了图像的原本信息。同时,在网络中添加BN层会占用网络的存储空间,增加网络的训练难度,因此本文在残差网络设计时去除了BN层。(2)本文提出的密集残差学习单元模块由两个基本残差学习单元以密集连接的方式组成,如图3所示。简单堆叠残差学习单元组成一个链式结构,每一个残差单元的输入都不同,在深度网络传输过程中可能会丢失学习到的有效特征信息,不能很好地学习更丰富复杂的特征。而本文提出的密集残差网络采用多路径密集连接的方式,为了让网络能够学习并保存更丰富复杂的图像特征,然后利用这些有效信息更好地重建出高质量的图像。与简单堆叠残差学习单元的链式结构相比,一方面,密集连接的引入改善了通过网络的信息流,缓解了梯度消失的问题;另一方面,每一个密集残差单元都共享同一个输入,允许重用前一个残差映射,避免重新学习冗余特征,为后面层提供丰富的图像细节。此外,本文提出的密集残差网络利用密集连接组合低级特征和高级特征,有利于学习复杂的特征,为SR重建提供更丰富的信息,有助于重建精度的提升,并且这种连接方式使得网络不容易过度拟合,促进了网络的稳定性。




图2 原始残差单元

以原始低分辨率图像 Y_i 作为网络的输入图像,经过第一个卷积层提取低级特征 $F(Y_i)$,将提取到的特征 $F(Y_i)$ 输入到密集残差学习单元。首先 $F(Y_i)$ 经过第一个基本残差学习单元学习到一个残差图像 $f_1(Y_i)$;然后 $f_1(Y_i)$ 再加上该残差学习单元的输入作为第二个基本残差学习单元的输入 $\delta(F(Y_i)+f_1(Y_i))$ 。第一个残差学习单元的输出经过第二个残差学习单元学习后得到的残差图像 $f_2(Y_i)$ 加上该残差单元的输入即前一个基本




图3 本文提出的密集残差学习单元

残差学习单元的输出,得到第二个基本残差学习单元的输出残差 $\delta(\delta(F(Y_i) + f_1(Y_i)) + f_2(Y_i))$,然后采用跳层连接将输入图像的特征连接到第二个基本残差单元的输出,得到第一个密集残差学习单元的输出 $F_1(Y_i) = \delta(\delta(\delta(F(Y_i) + f_1(Y_i)) + f_2(Y_i)) + F(Y_i))$ 。第一个密集残差学习单元的输出作为第二个密集残差学习单元的输入,通过密集残差学习得到第二个密集残差学习单元的输出 $F_2(Y_i) = \delta(\delta(\delta(F_1(Y_i) + f_3(Y_i)) + f_4(Y_i)) + F_1(Y_i))$ 。以此类推,得到第 n 个密集残差学习单元的输出 $F_n(Y_i) = \delta(\delta(\delta(F_{n-1}(Y_i) + f_{2n-1}(Y_i)) + f_{2n}(Y_i)) + F_{n-1}(Y_i))$,其中 n 表示密集残差学习单元的个数, $\delta(\cdot)$ 表示激活函数。最后,利用跳层连接的方式将输入图像特征连接到最后一个密集残差学习单元的输出,得到最终的整个密集残差学习模块的输出特征如公式(2):

$$G_n(Y_i) = \delta(\delta(\delta(F_{n-1}(Y_i) + f_{2n-1}(Y_i)) + f_{2n}(Y_i)) + F_{n-1}(Y_i)) + F(Y_i) \quad (2)$$

2.2 反卷积上采样

通过密集残差学习模块提取特征图之后,需要将提取到的低维特征图上采样到所需要重建的高维特征图。本文在网络中间采用反卷积层代替传统的手工设计的插值方法实现上采样操作。反卷积又叫转置卷积,其实可以看做是卷积的逆过程,卷积和反卷积操作过程如图4所示。




图4 卷积和反卷积

假设一个卷积层表示如下:卷积核大小为 $k \times k$,步长为 s ,零填充数为 p ,输入该卷积层的图像大小为 $i \times i$ 。该卷积层有一个对应的反卷积层:反卷积核大小为 $k'=k$,步长 $s'=1$,零填充数 $p'=k-p-1$ 。

反卷积层的输出大小可表示为:

$$o' = s(i' - 1) + k - 2p \quad (3)$$

反卷积滤波上采样不同于传统的双3次插值上采样,是一种在图像特征空间进行的自主学习的上采样操作,而双3次插值上采样则是一种手工设计的并在图像像素域中进行的上采样操作,针对超分辨率的特殊性,

这种在像素域中进行的上采样可能会破坏原始低分辨率图像中的一些重要信息,同时还会增加网络的计算复杂度,不利于图像精准重建。本文提出的反卷积滤波上采样则是在网络中进行,与特征映射和重建等模块共同优化学习,使得重建网络完全是一种端到端的自主学习的过程,有利于图像重建精度的提升。为了证实反卷积上采样重建效果优于手工设计的双3次插值上采样效果,本文对比了两组对比实验:一组是本文采用的反卷积滤波上采样模块,另一组是去除反卷积上采样模块,采用传统的双3次插值法将原始低分辨率图像上采样到目标图像大小,并以此图像作为网络的输入图像。表1表示在上采样倍数为3的情况下,对基准测试数据集采用不同上采样方式得到的平均PSNR值。

表1 不同上采样方式得到的平均PSNR值/dB

数据集	反卷积上采样	双3次插值上采样
Set5	33.40	33.21
Set14	29.62	29.49

从表1结果可以看出,采用反卷积上采样效果优于传统的双3次插值上采样。本文在反卷积层之前和之后分别进行一次 1×1 卷积,以进一步降低计算复杂度,其中第一个 1×1 卷积层通过将64通道输入特征图映射到4通道输出特征图执行降维。然后通过反卷积进行上采样,最后一个 1×1 卷积层将上采样特征图恢复到64个通道。以这种方式,达到以减小的尺寸执行反卷积操作,极大地降低了网络的计算复杂度,加快了网络的训练速度。

2.3 图像重建

通过反卷积层得到的图像再次通过密集残差模块学习更加丰富的高维特征信息,增强反卷积后的图像特征,有益于图像重建。该过程与前文2.1节的密集残差模块内容一致,此处不再累述。将获取到的64维残差输出输入到卷积核为 1×1 的卷积层,将特征维度降低到16维。在网络重建的最后,本文采用了多尺度重建的策略,将维度降低后的特征图输入到由4种不同卷积核大小组成的卷积层,利用不同卷积核对应不同范围的图像区域并融合不同区域的特征信息。卷积核大小分别为 $1 \times 1, 3 \times 3, 5 \times 5$ 和 7×7 ,多尺度卷积层表示如下:

$$F_{ij}(Y) = \text{ReLU}(W_{ij} * F_{l-1}(Y) + B_l) \quad (4)$$

式中, W_{ij} 表示4种不同的卷积核, $j=1, 2, 3, 4$ 。每一种卷积核输出4维的特征图,最后将融合后的16维特征图输入到卷积核为 1×1 的卷积层,获得最终的重建图像。

2.4 损失函数

超分辨率重建的目的是期望获得的重建图像 $F(Y_i)$ 和原始高分辨率图像 X_i 越接近越好,即它们之间的差值(损失函数)越小越好,由以上分析可知,学习到的端对端映射函数 F 需要学习各层中的网络参数 W 和

B 。整个网络的训练就是对这些参数 $\Theta = \{W_i, B_i\}$ 的估计与优化,通过最小化 $F(Y_i; \Theta)$ 和 X_i 之间的差值得到参数最优解。本文仍然选用均方误差MSE作为网络的损失函数:

$$L(\Theta) = MSE = \frac{1}{n} \sum_{i=1}^n \|F(Y_i; \Theta) - X_i\|^2 \tag{5}$$

相比于选用其他损失函数,选用MSE为超分辨率重建的损失函数能够让重建图像得到一个较高的峰值信噪比(PSNR)。在图像的质量评价指标中显示PSNR值越大,通常表明重建后的图像越接近原始高分辨率图像,即图像的重建质量越好。

3 实验结果与分析

3.1 训练数据集和测试数据集

为了与现有方法进行比较,本文采用相同的训练集和测试集。具体来说,模型使用标准的91幅图像^[17]进行训练,在网络训练过程中为了避免过度拟合同时进一步提高图像重建的准确性,采用数据增强技术对91幅图像进行数据扩充,对所有图像分别缩放0.9倍、0.8倍、0.7倍和0.6倍,同时每张图像按照90°、180°、270°进行旋转,使得训练图像扩充了 $5 \times 4 - 1 = 19$ 倍,共计 $91 \times 19 = 1\,729$ 幅训练图像。在网络训练之前,本文首先对原始训练高分辨率图像按步长为12将图像裁剪成一组 96×96 的高分辨率图像块HR,然后将所获得的高分辨率图像块先利用核大小为 7×7 ,标准差为1.6的高斯核模糊,尽可能模拟真实的自然模糊图像。接着采用双3次插值法按照所需缩放尺度(例如3倍)进行下采样,得到对应的低分辨率图像块LR(大小为 32×32)。

本文选用常用的标准数据库Set5^[18]和Set14^[19]作为网络的测试数据集,部分测试数据集如图5所示。



图5 部分测试数据集

3.2 实验设置

本文提出的网络模型直接对原始的低分辨率图像进行重建。网络中的每一层卷积层都由卷积核大小为 3×3 ,64个通道组成。在具有Intel 3.6 GHz CPU和GTX980 GPU的工作站上使用Pytorch软件包训练所提出的模型。经实验比较,选用两个密集残差学习单元组成的密集残差模块学习图像特征,对于网络优化问题,

本文采用Adam^[20]优化算法使损失最小化。在训练阶段,动量参数 β 设置为0.9,学习率 lr 设置为0.000 3,批大小 $Batch-size$ 设置为128,利用均值为0,标准差为0.01的高斯分布随机初始化卷积滤波器。

针对输入的彩色RGB图像,本文首先将图像从RGB颜色空间转换到YCbCr颜色空间上,并且只对亮度通道Y进行超分辨率重建,因为人类视觉对亮度比对颜色更加敏感。剩下的两个通道Cb、Cr均采用双3次插值法缩放到目标尺寸大小,最后将这3个通道组合成最终的重建图像。

在本文中,仍然主要采用峰值信噪比PSNR和结构相似度SSIM作为重建图像的质量评价指标。原始高分辨率图像 Y 和重建图像 \hat{Y} 对应的PSNR和SSIM计算公式如下:

$$PSNR = 10 \times \lg(255^2 / MSE) \tag{6}$$

$$SSIM = \frac{(2\mu_Y \mu_{\hat{Y}} + C_1)(\sigma_{Y\hat{Y}} + C_2)}{(\mu_Y^2 + \mu_{\hat{Y}}^2 + C_1)(\sigma_Y^2 + \sigma_{\hat{Y}}^2 + C_2)} \tag{7}$$

式中, μ_Y 和 σ_Y 分别表示原始高分辨率图像的平均灰度值和方差, $\mu_{\hat{Y}}$ 和 $\sigma_{\hat{Y}}$ 分别表示重建图像的灰度平均值和方差, $\sigma_{Y\hat{Y}}$ 表示为原始高分辨率图像和重建图像的协方差, C_1 、 C_2 表示为常数。PSNR值越大,说明重建图像效果越好;同样地,SSIM值越大,重建后的图像质量越高。

3.3 实验结果

本文实验结果与双3次插值法Bicubic、K-SVD^[21]、SelfEx^[22]和SRCNN等方法进行了比较,这些对比方法的实验结果图均由所公开的源代码测试得到。在实验过程中,进行了2倍、3倍和4倍的重建,选取Set5、Set14数据集中的图像作为测试对比结果。本文从客观角度对实验结果进行了定量对比分析,表2、表3分别表示数据集Set5在放大倍数为3时,不同超分辨率重建算法的PSNR值和数据集Set5、Set14在放大2倍、3倍、4倍条件下的平均PSNR值的比较。从实验结果可以看出,本文算法得到的PSNR值均高于其他算法,PSNR值越高,重建效果越好。由此可见,低分辨率图像通过本文算法得到的重建效果整体优于所对比的重建算法。

表2 数据集Set5在放大倍数为3时不同分辨率重建算法的PSNR值

图像	分辨率重建算法的PSNR值				dB
	Bicubic	K-SVD	SelfEx	SRCNN	本文算法
butterfly	24.04	25.94	26.65	27.68	28.91
baby	33.91	34.38	34.76	34.98	35.10
bird	32.58	33.57	34.23	35.12	36.62
head	32.88	33.16	33.35	33.51	34.85
woman	28.56	29.37	30.13	30.97	33.32

由于图像超分辨率重建最终很大部分是为为人眼服务的,因此本文又选取Set5和Set14中的几幅图像针对不同算法进行了3倍重建,更加直观清晰地比较本文算

表3 数据集Set5、Set14在放大2倍、3倍、4倍条件下的平均PSNR值

数据集	放大倍数	Bicubic	K-SVD	SelfEx	SRCNN	本文算法
Set5	2 ×	33.65	34.84	36.49	36.66	28.72
	3 ×	30.39	31.90	32.58	32.67	37.11
	4 ×	28.42	29.11	30.31	30.48	33.32
Set14	2 ×	30.34	31.05	32.22	32.29	30.25
	3 ×	27.55	28.67	29.16	29.28	32.82
	4 ×	26.09	26.95	27.40	27.59	30.41

法跟其他算法的差异性。不同重建算法视觉效果图展示如图6~10所示。

本文分别对 butterfly 的翅膀、head 的鬃毛、bird 的嘴线、Lenna 的眼睛以及 zebra 的斑纹等部位,以局部放大的方式,直观对比不同重建方法得到的重建效果。从主观角度分析可以看出 Bicubic 算法得到的重建图像非常不清晰,较为模糊,细节不明显,重建图像整体较为平滑。K-SVD 和 SelfEx 重建得到的图像一些细节信息没有较好恢复出来,图像的边缘处容易产生伪影和振铃现象。SRCNN 算法获得的重建效果相比前面3种算法有所提升,但由于 SRCNN 只采用3层卷积层的浅层网络,没能提取到更丰富的图像特征,因此,得到的重建图像的边缘和细节部分依然不清晰,并且边缘仍然存在振铃现象,重建效果有待进一步提升。本文提出的方法以原



图6 butterfly 超分辨率图像重建结果




图7 head 超分辨率图像重建结果




图8 bird 超分辨率图像重建结果



图9 Lenna 超分辨率图像重建结果




图10 zebra 超分辨率图像重建结果

始低分辨率图像作为网络输入,利用提出的密集连接的残差网络在网络中重用前层学习到的特征并组合底层和高层特征,学习到了更丰富复杂的图像特征,同时利用反卷积进行特征上采样,能够较好地恢复出更多的图像细节信息,使得重建后图像的边缘锐度和纹理清晰度方面都有了一定的改善,整体视觉效果更接近于原始高分辨率图像。综上所述,本文提出的方法获得的重建效果整体优于其他对比算法。

4 结论

本文提出了一种结合密集残差学习模块和反卷积神经网络实现单幅图像超分辨率重建的改进方法,所提出的密集残差学习模块是对多个小的残差网络以密集连接的方式构成一个大的残差网络,在特征映射和图像重建阶段均采用了这种密集连接的残差网络,能够更有效地学习到更丰富的图像细节特征。同时,在网络中采用反卷积代替双3次插值法的方式对重建图像进行上采样,加快了网络的重建速度。实验结果表明,本文算法得到的重建结果在主观和客观质量评价标准上跟其他算法相比都具有更好的表现。虽然本文提出的网络结构能有效提高图像的重建质量,但有些重建图像的边缘等细节部分仍有待提高,尤其是重建倍数越大,重建效果越不好,一方面可能是由于网络中只使用一个反卷积层很难重建出较好效果的大尺度重建图像,接下来考虑利用多个反卷积层,以由粗到精的方式逐渐重建图像;另一方面考虑在增加训练数据集的同时采用分辨率为2K的数据集DIV2K进行网络训练,原始高分辨率图像分辨率越高,在优化损失函数的过程中,使得重建图像越接近2K高分辨率图像,从而获得效果更好的重建图像。

参考文献:

- [1] 苏衡,周杰,张志浩.超分辨率图像重建方法综述[J].自动化学报,2013,39(8):1202-1213.
- [2] 曾凯,丁世飞.图像超分辨率重建的研究进展[J].计算机工程与应用,2017,53(16):29-35.
- [3] Ji Chengtao, He Xiaohai, Fu Yaoqing, et al. An edge-oriented interpolation algorithm based on regularization[J]. Journal of Electronic Information, 2014, 36(2): 293-297.
- [4] Wei D. Image super resolution reconstruction using the high order derivative interpolation associated with fractional filter functions[J]. IET Signal Processing, 2017, 10(9): 1052-1061.
- [5] Pappayan V, Elad M. Multi-scale patch-based image restoration[J]. IEEE Transactions on Image Processing, 2016, 25(1): 249-261.
- [6] 孙京,袁强强,李冀玮,等.亮度-梯度联合约束的车牌图像超分辨率重建[J].中国图象图形学报,2018,23(6): 802-813.
- [7] Yang J, Wright J, Huang T S, et al. Image super-resolution via sparse representation[J]. IEEE Transactions on Image Processing, 2010, 19(11): 2861-2873.
- [8] 孙毅堂,宋慧慧,张开华,等.基于极深卷积神经网络的人脸超分辨率重建算法[J].计算机应用,2018,38(4):1141-1145.
- [9] Timofte R, Smet V D, Gool L V A+. Adjusted anchored neighborhood regression for fast super-resolution[C]//Proceedings of Asian Conference on Computer Vision, 2014: 111-126.
- [10] 邢晓羊,魏敏,符颖.基于特征损失的医学图像超分辨率重建[J].计算机工程与应用,2018,54(20):202-207.
- [11] Dong C, Loy C C, He K, et al. Image super-resolution using deep convolutional networks[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2016, 38(2): 295-307.
- [12] Kim J, Lee J K, Lee K M. Accurate image super-resolution using very deep convolutional networks[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2016: 1637-1645.
- [13] Zeiler M D, Fergus R. Visualizing and understanding convolutional networks[C]//Proceedings of 2014 European Conference on Computer Vision, 2014: 818-833.
- [14] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.
- [15] Tian Juan, Li Yingxiang, Li Yanyan. Comparative study of activation functions in convolutional neural networks[J]. Computer Systems and Applications, 2018, 27(7): 43-49.
- [16] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]//Proceedings of International Conference on Solar Information Processing Systems, 2012: 1097-1105.
- [17] Yang J, Wright J, Huang T S, et al. Image super-resolution via sparse representation[J]. IEEE Transactions on Image Process, 2010, 19(11): 2861-2873.
- [18] Bevilacqua M, Roumy A, Guillemot C, et al. Low-complexity single-image super-resolution based on non-negative neighbor embedding[J]. BMVC, 2012, 10(9): 1-10.
- [19] Zeyde R, Elad M, Protter M. On single image scale-up using sparse-representations[C]//Proceedings of International Conference on Curves and Surfaces, 2012: 711-730.
- [20] Kingma D, Ba J. Adam: A method for stochastic optimization[J]. arXiv: 1412.6980, 2014.
- [21] Aharon M, Elad M, Bruckstein A. K-SVD: An algorithm for designing over complete dictionaries for sparse representation[J]. IEEE Transactions on Signal Processing, 2006, 54(11): 4311-4322.
- [22] Huang J B, Singh A, Ahuja N. Single image super-resolution from transformed self-exemplars[C]//Proceedings of 2015 IEEE Conference on Computer Vision and Pattern Recognition, 2015: 5197-5206.