

# 用于图像超分辨的密集跳跃注意连接网络

吴荣贵<sup>1,2</sup>, 蒋平<sup>1†</sup>

(1. 中国科学院光电技术研究所, 成都 610209; 2. 中国科学院大学, 北京 100049)

**摘要:** 为解决现有基于深度学习的超分辨算法模型没有充分利用各个层次的特征信息导致重建精度不高、参数量大的问题,提出了一个内外双重密集连接结构——密集跳跃注意连接网络。内层结构中,对原始密集级联结构进行改进,提出了通道可分密集级联块;外层结构采用密集残差连接结合注意力机制将由密集块提取的特征进行融合,从而达到更少卷积层、更高精度的效果。在多个基准数据集上测试,提出的网络较其他网络层数体量相近的算法精度更高、参数量更少。

**关键词:** 深度学习; 图像超分辨; 密集连接; 注意力机制

**中图分类号:** TP391.41

**文献标志码:** A

**文章编号:** 1001-3695(2020)12-055-3788-04

doi:10.19734/j.issn.1001-3695.2019.05.0240

## Densely channel attention skip connection network for image super-resolution

Wu Ronggui<sup>1,2</sup>, Jiang Ping<sup>1†</sup>

(1. Institute of Optics & Electronics, Chinese Academy of Sciences, Chengdu 610209, China; 2. University of Chinese Academy of Sciences, Beijing 100049, China)

**Abstract:** In order to solve the problem that the existing super-resolution algorithm based on deep learning didn't make full use of the feature information of each level, resulting in low reconstruction accuracy and large parameter quantity, this paper proposed a double dense connection structure named densely channel attention skip connection network. In the inner structure of the network, it improved the original dense cascade block to generate a channel separable dense cascade block. The outer structure adopted a densely residual connection and attention mechanism to fuse the features extracted by the dense block to achieve the goal that less convolution layer and higher precision effect. This paper tested the network models on several benchmark datasets. The results show the proposed model has higher accuracy and fewer parameters than the other models.

**Key words:** deep learning; image super-resolution; dense skip connection; attention mechanism

## 0 引言

图像超分辨率重建技术(SR)<sup>[1]</sup>作为图像复原中的一个分支,在不增加硬件成本的前提下,从已知的低分辨率图像(LR)通过软件的方法重建出高分辨率的图像(HR)。在包括高清电视<sup>[2]</sup>、医学成像<sup>[3,4]</sup>、航空及其卫星成像<sup>[5]</sup>、遥感图像等领域具有十分重要的应用价值和广阔的应用前景。

首次将卷积神经网络(CNN)技术<sup>[6]</sup>运用到SR领域中去的工作是由Dong等人<sup>[7]</sup>提出的SRCNN算法,该算法的性能远远超过了此前的算法。但由于其网络层过少、网络的感受野小,导致重建的图像依然存在着很多细节上的缺失,并且SRCNN并不是一个真正意义上端到端处理的方法,它在LR图像输入网络之前需要对LR图像先进行插值放大到目标图像大小,这个过程会使得SRCNN需要在高分辨率空间上对图像进行处理,从而导致计算量的增加。Dong等人<sup>[8]</sup>把反卷积层<sup>[9]</sup>用到SR中提出了FSRCNN算法,实现了对图像端对端的重建。文献[10,11]利用跳跃连接(skip connection)加深了网络的卷积层数,提出了VDSR、RED30算法,增大了网络的感受野和拟合能力,取得了很好的重建效果,但这些算法都缺乏对各个卷积层次特征的融合利用。He等人<sup>[12]</sup>提出了ResNet,采用较为保守的方式加深网络的深度,在深层网络中取得了很好的效果。一般对残差结构的理解认为每个残差块是在尽量保持原来特征的基础上学到新的信息。但Chen等人<sup>[13]</sup>在DPN

中指出,ResNet结构与密集连接结构(DenseNet<sup>[14]</sup>)类似,都能对各个层次的卷积层特征进行复用,并且在特征复用的过程中并不会增加复用层的参数量。Huang等人<sup>[14]</sup>提出的DenseNet结构在特征复用的过程中相较ResNet能更有效地探索新的特征,但是DenseNet这种级联的形式会使得网络随着层数的增多参数量激增,不利于构建实用的网络结构。显然,如果能将这两种复用策略结合,对提升网络的重建精度同时不引起参数量激增是有积极意义的。

本文算法基于上述分析,针对超分辨率算法中没能充分利用各个层次卷积提取的信息导致重建精度不高以及参数量过大的问题,结合ResNet中跳跃连接特征复用不增加网络参数和DenseNet能更好地探索出新的特征信息的特点提出了一个轻量高性能的算法。本文对密集连接块进行改进,提出了通道可分密集块,既提升了网络的重建精度,也拓展了密集连接网络中复用特征的灵活性;在密集连接块中引入注意力机制,同时从宏观和微观上调整网络参数,使得网络能拟合出更复杂的特征。将提出的网络命名为密集跳跃注意连接网络,简称为DCSN(densely channel attention skip connection network)。DCSN较目前网络层数相近的算法,在基准数据集上测试,峰值信噪比(PSNR)和结构相似性(SSIM)表现更好。

## 1 本文算法

本文算法是一个端对端的算法,目的是通过监督学习的方

收稿日期: 2019-05-24; 修回日期: 2019-07-13

作者简介: 吴荣贵(1993-),男,广西浦北人,硕士研究生,主要研究方向为图像处理; 蒋平(1976-),男(通信作者),四川成都人,研究员,博士,主要研究方向为图像处理(554854063@qq.com)。

法找到低分辨率图像  $I_L$  到高分辨率图像  $I_H$  之间的映射关系  $F$ 。它的网络结构如图 1 所示,主要由三部分组成,即接收输入  $I_L$  并提取其特征的浅层特征层 conv1;在浅层特征层之后提取更高级特征的非线性映射层,该部分由六个密集块和通道注意力机制组成;最后是用于上采样的反卷积层(deconv)和输出最终  $I_H$  的重建层(conv end)。网络采用了双重密集连接的方式,外层采用加和的形式保证了特征的复用也不会造成参数数量的激增,内层采用级联的形式,有效挖掘来自各个密集块的特征信息并在此基础上融合出更多有用的信息。




图 1 DCSN 算法框架  
Fig. 1 Framework of DCSN algorithm

### 1.1 密集加和连接

DCSN 的外层采用的是密集加和连接的形式,其形式体现在图 1 中非线性映射层的六个密集连接块的连接形式。设 dense block( $i$ ) CA 的输出为  $out(i)$ ,输入为  $in(i)$ ,以第  $i$  个密集连接块为例,它的输入  $in(i) = out(1) + out(2) + \dots + out(i-1)$ 。采用这种连接形式让来自不同深度的密集块提取的信息都能得到更充分的挖掘,并且避免了浅层提取的信息随着网络的加深造成的损耗。此前产生的特征都参与之后密集连接块的输入中,能使得各个层次的密集块分担了当前密集块提取特征的难度;同时,后面的层与前面的层之间相连,也防止由于导数链式法则带来的梯度消失和梯度爆炸的问题。

为了进一步利用浅层信息,将非线性映射层最后的输出与浅层特征提取层的输出进行加和,让反卷积上采样层能够利用网络中所有深度卷积层提取的信息完成最后的图像重建。

### 1.2 密集连接块

图 2 中的 dense block( $i$ ) (密集块)由四个卷积层密集连接组成,传统的密集连接块对特征的复用形式如图 2(a)所示,采用级联的方式进行全通道特征密集连接;本文提出的密集块采用的是只复用一半特征的策略,如图 2(b)所示,这样做的目的是进一步提高特征输出的通道数,输出通道数的增加代表着网络提取信息能力的增强,并且这个过程不会使得密集块最终输出的通道数过高,导致参数数量激增。




图 2 原始密集连接结构与提出的密集连接结构  
Fig. 2 Structure of original and proposed dense cascade block

由图 2(a)可以看出,在原始的密集块中,后面卷积层的输入来自前面各个卷积层的输出。以 conv  $i$  为例,设 conv  $i$  的输出为  $S_i$ ,输入为  $S^{li}$ ,则  $S^{li} = \text{concat}(S_1, S_2, \dots, S_{i-1})$ ,其中 concat 表示级联操作。这样的特征复用策略可以有效地复用每个密集块中卷积层提取的特征信息。但这种复用方式存在着两个问题:a)在 SR 中,为了进一步提取到更有用的信息进行重建,增加特征的通道是有效的,但原始的密集连接形式过于单一,增大密集块的生长率会造成最终输出的特征通道数急剧增加,破坏网络的整体性;b)原始密集块中卷积层输出的所有特征都用于其后卷积层的复用,而当前层更可能只有部

分通道的特征信息是对后面卷积层是有用的,即这种做法可能存在冗余。

为了进一步增强网络的特征表达能力,同时不破坏网络整体性(破坏外层密集加和结构),保持密集连接块中复用各个卷积层输出特征信息的特点,提出了通道可分离的密集块结构(图 2(b))。其中:conv  $i$  的输出特征通道数为  $S_{2i} + S_{2i-1}$ 。在其后的特征复用过程中,conv  $i$  输出的特征图序列一分为二,交替作为其后卷积层输入的一部分,以 conv1 为例, $S_1$  分别作为 conv2 和 conv4 的一部分, $S_2$  作为 conv3 和密集块输出的一部分。这样的安排是为了每个卷积层输出的特征块可以分别去适应更少的卷积层,从而减轻了网络拟合特征的难度。同时,虽然每个密集块的输出包含各个层次不同的特征,但缺乏把这些特征的融合操作,所以在每一个密集块的末端加一层  $1 \times 1$  的卷积层融合不同通道的特征。

### 1.3 注意力机制

注意力机制首先在 SENet<sup>[15]</sup> 网络中被提出,目的是让网络在训练的过程中学习特征图序列中哪些特征图更重要,顾名思义就是为特征图序列加权重。其具体的实现形式如图 3 所示。设卷积层输出的特征图序列为  $X$ , $X$  为  $C$  张  $H \times W$  的特征图,首先对  $X$  进行 global average pooling 的操作,得到一个长度为  $C$  的一维序列。之后再对这个一维序列进行非线性化处理,即输入两个卷积层,这里与原始的注意力机制不同,并没有采用对  $C$  维序列先降低特征维度再恢复的策略,目的是更多的参数能训练出更好的特征图权重序列。最后采用一个 sigmoid 函数使得最终得到的系数限定在  $0 \sim 1$ 。




图 3 注意力机制示意图  
Fig. 3 Framework of attention mechanism

结合 1.1 节的密集加和结构进行分析,采用注意力机制能使得网络能更有效地提取各个密集块输出的信息进行之后密集块以及重建层的输入,它的意义主要体现在以下两点:a)从 1.1 节中可知第  $i$  个密集连接块的输出为  $in(i) = out(1) + out(2) + \dots + out(i-1)$ ,假设将注意力机制去掉,这种加和的方式会使得输入的数值过大,不利于密集块的训练,而加上注意力机制就相当于在需要加和的特征图上乘以一个  $0 \sim 1$  的系数,减轻了网络的训练难度;b)引入了注意力机制相当于让算法能在更宏观(特征图的维度)的角度上对网络对应的参数进行调整。在本文提出的密集加和结构中,每个  $in(i)$  的子项  $out(j)$  ( $j < i$ ) 都能同时调节特征图和特征点对应的卷积核数更有效地拟合出所需要的参数。

### 1.4 实现细节与训练

本算法选用的卷积核大小和相应参数的设置如表 1 所示。其中,number 表示每个卷积层的输出通道数大小,除最后的卷积层之外,算法中所有的层都跟着 ReLU 作为激活函数。从表中可以看出,本文采用的卷积网络的卷积层层数为 35,是一个较为轻量的网络,其中卷积层都采用  $3 \times 3$  的卷积核。反卷积上采样层的卷积核尺寸针对  $\times 2$ 、 $\times 3$ 、 $\times 4$  图像放大任务分别采用  $4 \times 4$ 、 $9 \times 9$ 、 $4 \times 4$  的卷积核,其中 4 倍放大采用两个反卷积层,各自对应的网络参数数量为 329k、595k、526k。

在实验阶段,上述提到的模型均在 291 幅图像数据上进行训练,该数据集包括 91 幅图像<sup>[16]</sup>和来自伯克利分割数据集<sup>[17]</sup>的 200 张图像,测试集采用 Set5<sup>[18]</sup>、Set14<sup>[19]</sup>和 B100<sup>[17]</sup>这三个最为常用的 SR 基准数据集。将训练集的 RGB 图像转

成 YCbCr 格式提取其中的亮度通道作为数据进行训练,这是因为人眼对亮度通道更加敏感。采用 PSNR(峰值信噪比)和 SSIM(结构相似性)作为算法结果的评价标准。为了和训练时数据处理保持一致,模型测试中的 PSNR 和 SSIM 也是在 YCbCr 空间上的亮度通道进行计算的。

表 1 网络各层参数设置

Tab. 1 Different network layer parameter setting				
name	kernel size		number	
conv1	3×3		64	
dense block <i>i</i> (×6)	name	number		
	conv1	32	3×3	64
	conv2	32	3×3	
	conv3	32	3×3	
	conv4	16	3×3	
	conv5	64	1×1	64
deconv	9×9/4×4		64	
conv	3×3		1	

为了提高网络超分辨的效果,对标准的 291 幅图像训练集进行了扩充。对原始的 291 幅图像进行了旋转(90°、180°和 270°)以及缩小(0.5~0.9)处理,经过多角度转换增强了样本的多样性。同时,通过对数据增强后得到的每一张图像进行一定步长的切割处理,得到相应的图像块作为训练中的真值,定义为  $I_s$ 。对得到的  $I_s$  进行 3 倍双线性插值下采样得到对应的低分辨率图像  $I_L$  作为网络的输入。由此得到训练集  $\langle I_L, I_s \rangle$ 。

表 2 基准数据集上的评价结果(PSNR(dB)/SSIM)  
Tab. 2 Public benchmark test results (PSNR(dB)/SSIM)

dataset	scale	(a)	(b)	(c)	(d)	(e)
Set5	×3	33.91/0.9231	33.87/0.9223	33.88/0.9226	33.83/0.9220	34.04/0.9240
Set14	×3	29.85/0.8338	29.84/0.8333	29.83/0.8334	29.83/0.8331	29.91/0.8348
B100	×3	28.87/0.8008	28.85/0.8003	28.84/0.7999	28.84/0.7998	28.89/0.8013

从表 2 中,对比(b)与(a)的结果,证明了提出密集加和结构比残差结构更有效;(d)与(a)的结果证明了提出的通道可分密集连接结构比原始的密集连接更有效;(c)与(a)的结果说明通道注意力机制在本文算法中的有效性;(e)与(a)的结果说明了特征融合层的有效性。

## 2.2 与其他算法比较

如表 3 所示(加粗为最优结果),本文在多个基准数据集上进行定量比较,可以看出本文算法在不同的放大倍数上相较其他方法总体上有较大提升。DRCN<sup>[21]</sup>、VDSR<sup>[10]</sup>将全局残差结构应用

在训练中, $L_1$  型损失函数具有稀疏化的效果,在 SR 这种像素级的任务中,稀疏化的效果能减少重建图像的冗余信息,同时又具有保持边缘的优点。所以在实验中采用  $L_1$  型损失函数进行训练。定义  $\theta = \{W_i, B_i\}, i = 1, 2, \dots, 29$  为网络所有参数。

训练的过程就是最小化  $L_1$  函数的损失: $l(\theta) = \frac{1}{N} \sum_{k=1}^N \|F(I_L^k, \theta) - I_s^k\|_1$  的过程。采用 Adam 优化方法<sup>[20]</sup>进行迭代优化,优化器对应的设计为  $\beta_1 = 0.9, \beta_2 = 0.999, \varepsilon = 10^{-8}$ 。本文的 minibatch 设置为 64,初始学习率设置为  $1E-3$ ,每经过 25 个 epochs 后学习率衰减为 10 倍,迭代 80 个 epochs 后网络的性能不再提升,停止迭代。本文所有的实验都是在 Pytorch 1.0 上实现,采用 NVIDIA Titan Pascal GPU。

## 2 实验结果与分析

### 2.1 烧灼实验

为了验证上述算法的有效性,设置了不同的对照实验,如表 2 所示(加粗为最优结果)。其中:(a)为去掉密集块中的特征融合结构(conv5);(b)为在(a)的基础上将密集加和替换成 ResNet 的连接形式(如图 4 所示);(c)为在(a)的基础上不注意力机制;(d)为在(a)的基础上将通道可分密集连接结构替换成原始的密集连接结构;(e)为提出的完整网络结构。

到网络的最终重建层;LapSRN<sup>[23]</sup>和 DSRN<sup>[24]</sup>在网络中从不同的分辨率空间对所需的特征进行提取,并且 DSRN 把原始的残差结构运用到网络当中,但是,这些算法都缺乏对网络中各个卷积层输出特征更细粒度的利用。对于图像超分辨这个需要密集预测出每一个像素点值的任务来说,从原始图像中提取更多的信息是至关重要的。而本文的算法采用双层密集连接把级联和残差结构结合,充分利用了每个深度的卷积提取的特征,并且引入了注意力机制,从宏观和微观两个角度对网络进行调节,从而能从原始图像中提取更丰富的信息,适应更复杂的情况。

表 3 基准数据集上的评价结果(PSNR(dB)/SSIM)  
Tab. 3 Public benchmark test results (PSNR(dB)/SSIM)

dataset	scale	bicubic	SRCNN <sup>[7]</sup>	VDSR <sup>[10]</sup>	DRCN <sup>[21]</sup>	DnCNN <sup>[22]</sup>	LapSRN <sup>[23]</sup>	DSRN <sup>[24]</sup>	DCSN(this paper)
Set5	×2	33.66/0.9299	36.66/0.9544	37.53/0.9587	37.63/0.9588	37.58/0.9590	37.52/0.9591	37.66/0.9590	37.84/0.9603
	×3	30.39/0.8682	32.75/0.9090	33.66/0.9213	33.82/0.9226	33.75/0.9222	33.81/0.9220	33.88/0.9220	34.04/0.9240
	×4	28.42/0.8104	30.48/0.8628	31.35/0.8838	31.53/0.8854	31.40/0.8845	31.54/0.8852	31.40/0.8830	31.68/0.8854
Set14	×2	30.24/0.8688	32.42/0.9063	33.03/0.9124	33.04/0.9118	33.03/0.9128	32.99/0.9118	33.15/0.9130	33.23/0.9149
	×3	27.55/0.7742	29.30/0.8215	29.77/0.8314	29.76/0.8311	29.81/0.8321	29.79/0.8325	30.26/0.8370	29.91/0.8348
	×4	26.00/0.6675	27.49/0.7503	28.01/0.7674	28.02/0.7670	28.04/0.7672	28.09/0.7700	28.07/0.77	28.17/0.7713
B100	×2	29.56/0.8431	31.36/0.8879	31.90/0.8960	31.85/0.8943	31.90/0.8961	31.80/0.8952	32.10/0.8978	32.04/0.8988
	×3	27.21/0.7385	28.41/0.7863	28.82/0.7976	28.80/0.7963	28.85/0.7981	28.82/0.7980	28.81/0.7970	28.89/0.8013
	×4	25.96/0.6675	26.90/0.7101	27.29/0.7251	27.23/0.7233	27.29/0.7253	27.32/0.7275	27.25/0.724	27.34/0.7295

将本文算法与其他算法在网络的参数量和性能上进行对照,具体如图 5 所示。




图 4 密集残差结构

Fig. 4 Dense residual structure




图 5 参数量与精度的关系

Fig. 5 Relationship between number of parameters and accuracy

图 5 为在基准测试集 Set5 上 ×3 放大的测试结果,其中“+”代表本文算法,蓝色的点从左到右分别为 SRCNN、ESPCN<sup>[25]</sup>、VDSR、DSRN、DRCN 以及 RED30<sup>[11]</sup>。从图 5 可以看出,本文算法精度高、量级小,更有利于工程上的运用。

### 2.3 主观效果

图 6 为在基准测试集 Set5 上 ×3 放大的部分测试结果,从上到下的重建结果分别为原图、双线性三次插值和本文算法 DCSN。从图中可以看出,本文算法可以准确重建出图像丰富的细节信息。



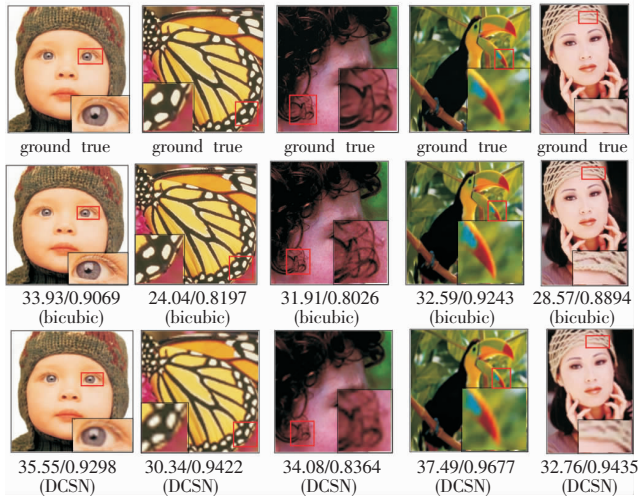


图6 Set5上的重建结果  
Fig 6 The SR result in Set5

### 3 结束语

结合残差网络和密集连接网络的特征复用特点,本文提出了一个轻量的SR网络。网络对密集连接网络的密集连接形式进行扩展,采用了一个形式更加多样,可塑性更强的特征复用可选密集连接结构。同时采用注意力机制使得网络能在宏观和微观的角度上对参数进行调节。该算法在多个数据集上与其他常见的超分辨算法进行比较,在PSNR和SSIM上都表现出更好的重建精度。并且与其他工作相比,本文算法参数量更少、更轻量,易于在工程中实现。

#### 参考文献:

- [1] 南方哲,钱育蓉,行艳妮,等. 基于深度学习的单图像超分辨率重建研究综述[J]. 计算机应用研究, 2020, 37(2): 321-326. (Nan Fangzhe, Qian Yurong, Xing Yanni, et al. Survey of single image super resolution based on deep learning [J]. *Application Research of Computers*, 2020, 37(2): 321-326.)
- [2] Goto T, Fukuoka T, Nagashima F, et al. Super-resolution system for 4K-HDTV[C]//Proc of the 22nd International Conference on Pattern Recognition. Piscataway, NJ: IEEE Press, 2014: 4453-4458.
- [3] Peled S, Yeshurun Y. Super-resolution in MRI: application to human white matter fiber tract visualization by diffusion tensor imaging[J]. *Magnetic Resonance in Medicine*, 2001, 45(1): 29-35.
- [4] Shi Wenzhe, Caballero J, Ledig C, et al. Cardiac image super-resolution with global correspondence using multi-atlas patchmatch[C]//Proc of the 16th International Conference on Medical Image Computing and Computer-Assisted Intervention. Berlin: Springer, 2013: 9-16.
- [5] Thornton M W, Atkinson P M, Holland D A. Sub-pixel mapping of rural land cover objects from fine spatial resolution satellite sensor imagery using super-resolution pixel-swapping [J]. *International Journal of Remote Sensing*, 2006, 27(3): 473-491.
- [6] 张军阳,王慧丽,郭阳,等. 深度学习相关研究综述[J]. 计算机应用研究, 2018, 35(7): 1921-1928, 1936. (Zhang Junyang, Wang Huili, Guo Yang, et al. Review of deep learning [J]. *Application Research of Computers*, 2018, 35(7): 1921-1928, 1936.)
- [7] Dong Chao, Loy C C, He Kaiming, et al. Learning a deep convolutional network for image super-resolution[C]//Proc of the 12th European Conference on Computer Vision. Cham: Springer, 2014: 184-199.
- [8] Dong Chao, Loy C C, Tang Xiao'ou. Accelerating the super-resolution convolutional neural network[C]//Proc of the 14th European Conference on Computer Vision. Cham: Springer, 2016: 391-407.
- [9] Zeiler M D, Taylor G W, Fergus R. Adaptive deconvolutional networks

for mid and high level feature learning [C]//Proc of International Conference on Computer Vision. Piscataway, NJ: IEEE Press, 2011: 2018-2025.

- [10] Kim J, Lee J K, Lee K M. Accurate image super-resolution using very deep convolutional networks [C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2016: 1646-1654.
- [11] Mao Xiaojiao, Shen Chunhua, Yang Yubin. Image restoration using very deep convolutional encoder-decoder networks with symmetric skip connections[C]//Proc of the 30th International Conference on Neural Information Processing Systems. Red Hook, NY: Curran Associates Inc., 2016: 2802-2810.
- [12] He Kaiming, Zhang Xiangyu, Ren Shaoqing, et al. Deep residual learning for image recognition[C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2016: 770-778.
- [13] Chen Yunpeng, Li Jianan, Xiao Huaxin, et al. Dual path networks [EB/OL]. (2017-08-01). <https://arxiv.org/pdf/1707.01629.pdf>.
- [14] Huang Gao, Liu Zhuang, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. 2017: 4700-4708.
- [15] Hu Jie, Shen Li, Albanie S, et al. Squeeze-and-excitation networks [J]. *IEEE Trans on Pattern Analysis and Machine Intelligence*, 2020, 42(8): 2011-2023.
- [16] Yang Jianchao, Wright J, Huang T S, et al. Image super-resolution via sparse representation[J]. *IEEE Trans on Image Processing*, 2010, 19(11): 2861-2873.
- [17] Martin D, Fowlkes C, Tal D, et al. A database of human segmented natural images and its application to evaluating segmentation algorithms and measuring ecological statistics[C]//Proc of International Conference on Computer Vision. Washington DC: IEEE Computer Society, 2001: 1-11.
- [18] Bevilacqua M, Roumy A, Guillemot C, et al. Low-complexity single-image super-resolution based on nonnegative neighbor embedding [C]//Proc of the British Machine Vision Conference. 2012: 135. 1-135. 10.
- [19] Zeyde R, Elad M, Protter M. On single image scale-up using sparse-representations [C]//Proc of the 7th International Conference on Curves and Surfaces. Berlin: Springer-Verlag, 2010: 711-730.
- [20] Kingma D P, Ba J. Adam: a method for stochastic optimization [EB/OL]. (2017-01-30). <https://arxiv.org/pdf/1412.6980.pdf>.
- [21] Kim J, Lee J K, Lee K M. Deeply-recursive convolutional network for image super-resolution[C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2016: 1637-1645.
- [22] Zhang Kaibing, Zuo Wangmeng, Chen Yunjin, et al. Beyond a Gaussian denoiser: residual learning of deep CNN for image denoising[J]. *IEEE Trans on Image Processing*, 2017, 26(7): 3142-3155.
- [23] Lai Weisheng, Huang Jiabin, Ahuja N, et al. Deep Laplacian pyramid networks for fast and accurate super-resolution [C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2017: 624-632.
- [24] Han Wei, Chang Shiyu, Liu Ding, et al. Image super-resolution via dual-state recurrent networks[C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2018: 1654-1663.
- [25] Shi Wenzhe, Caballero J, Huszar F, et al. Real-time single image and video super-resolution using an efficient sub-pixel convolutional neural network[C]//Proc of IEEE Conference on Computer Vision and Pattern Recognition. Washington DC: IEEE Computer Society, 2016: 1874-1883.